

UNIVERSITÀ DEGLI STUDI DI NAPOLI FEDERICO II

Scuola Politecnica e delle Scienze di Base
Corso di Laurea Magistrale in Informatica

Classificazione della Leucemia Mieloide Acuta da immagini

Anno Accademico 2025/2026

Relatore :
Francesco Isgrò

Correlatore:
Andrea Calì

Candidata :
Fabiola Salomone
Matr. N97/457

23 Ottobre 2026

Contenuti

Introduzione

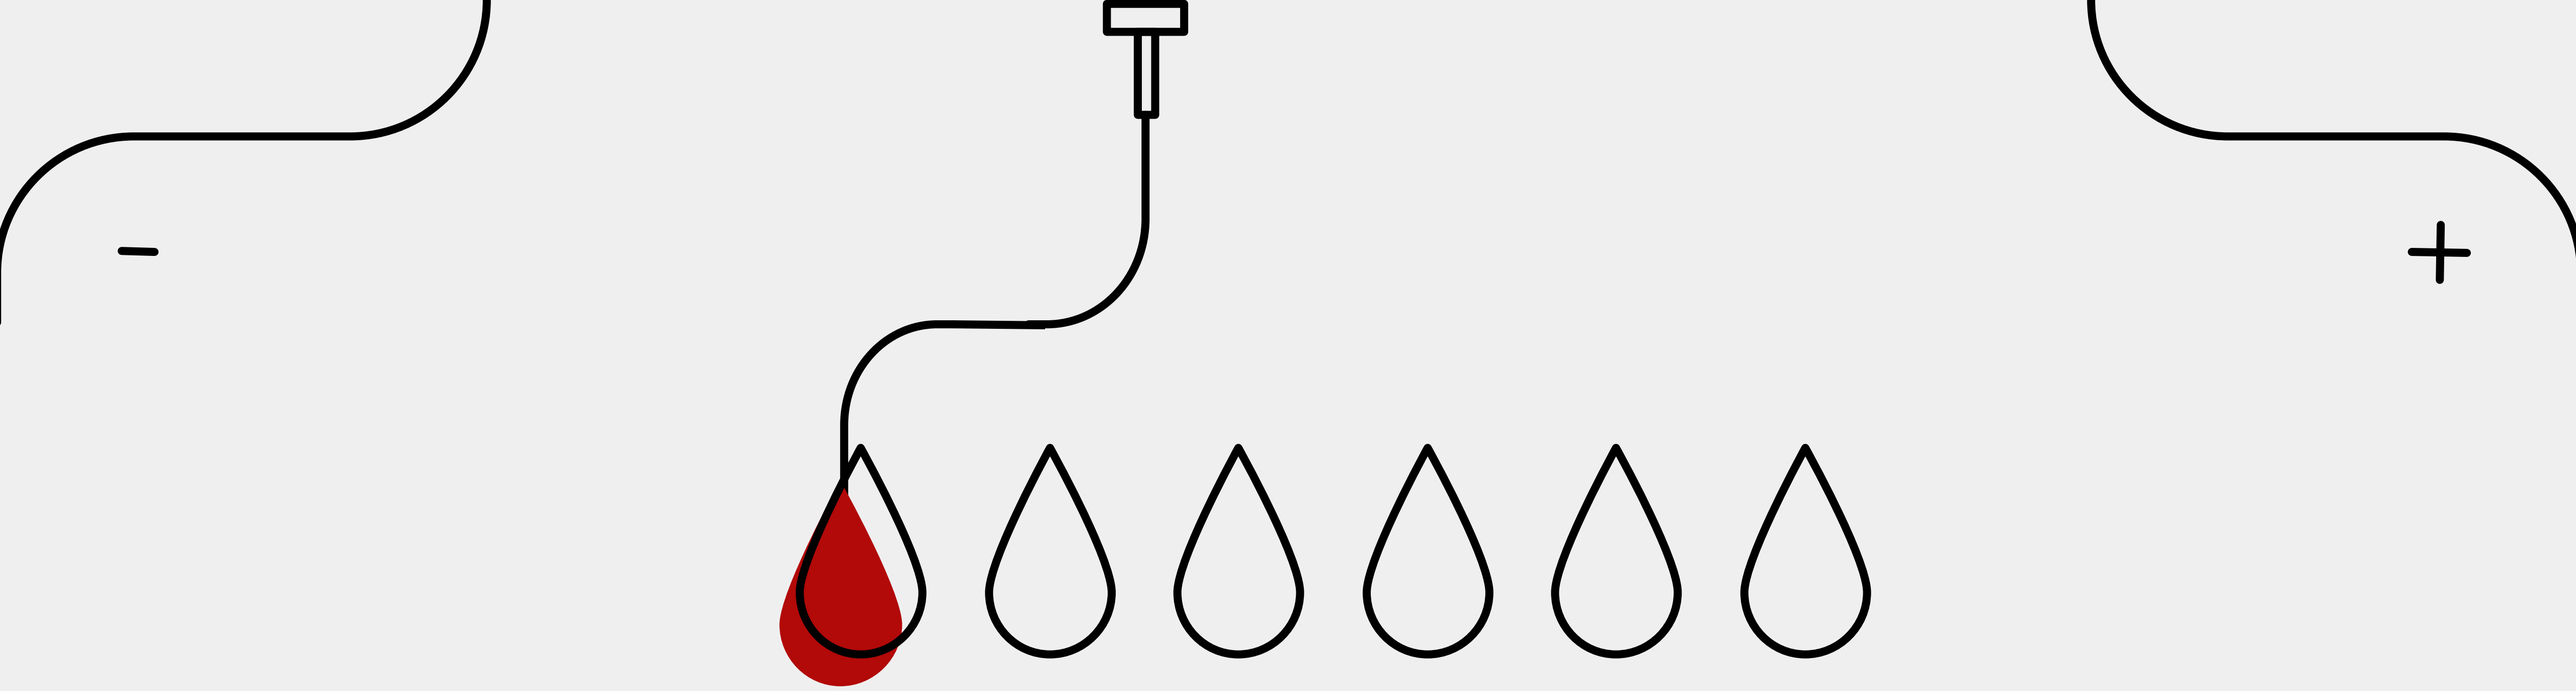
Dataset e
Partizionamento dei Dati

Architettura
del Modello

Addestramento

Risultati & Valutazione
del
modello

Sviluppi
Futuri



Introduzione

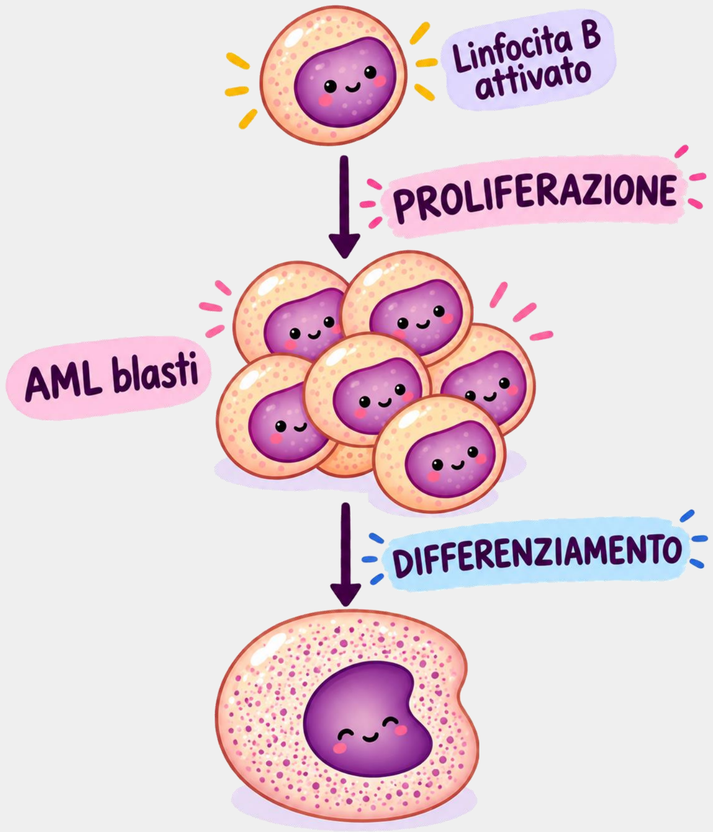
Il Contesto Clinico

→ **Patologia aggressiva**: è un tumore del sangue aggressivo che si sviluppa da alcune alterazioni/mutazioni del DNA nel midollo osseo.

→ **Problematiche :**

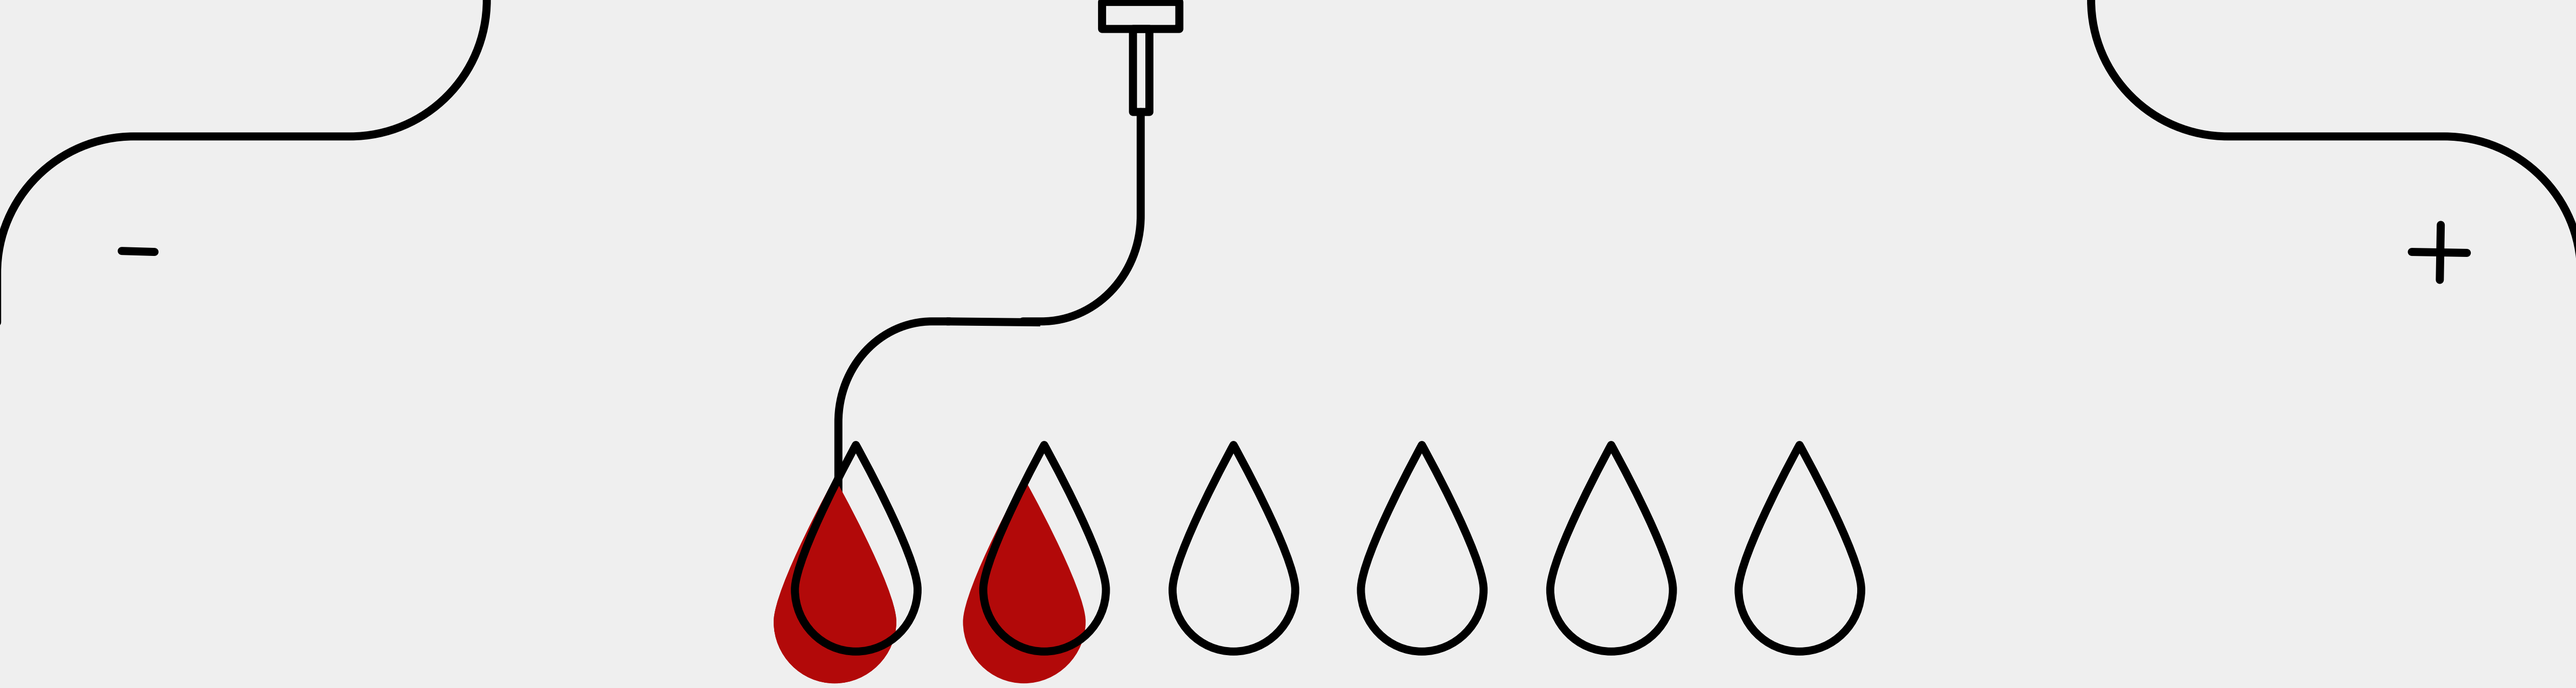
- La proliferazione incontrollata.
- Blocco di differenziazione.

→ **Limiti** Morfologia Tradizionale



1ª Linea

Necessità critica di formulare una diagnosi rapida e precisa per avviare immediatamente il protocollo terapeutico corretto.



Dataset &
Partizionamento dei Dati

Il Dataset



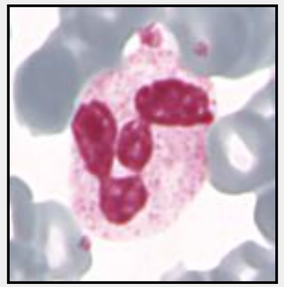
189 vetrini di sangue periferico

4 Sottotipi genetici

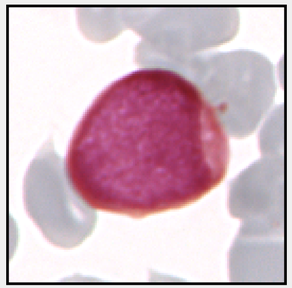
CBFB_MYH11, NPM1,
PML_RARA, RUNX1_RUNX1T1
+ Controlli sani

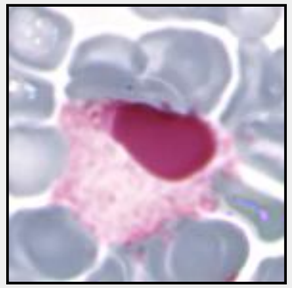
144×144 RGB

https://www.cancerimagingarchive.net/collection/aml-cytomorphology_mll_helmholtz/

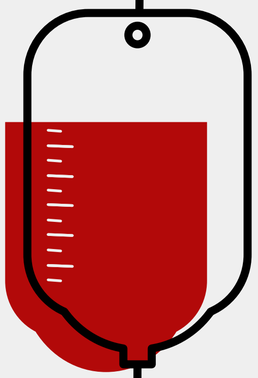








Cellule Pazienti Sani



- Forma cellulare tondeggiante, simmetrica e regolare.
- Assenza di crepe o screpolature
- Pochi vacuoli
- Nucleoli omogenei

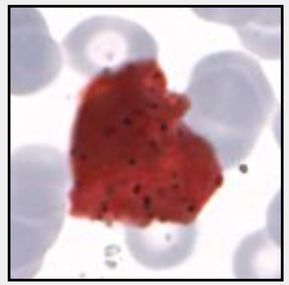
Cellule Pazienti Malati



CBFB_MYH11



NPM1



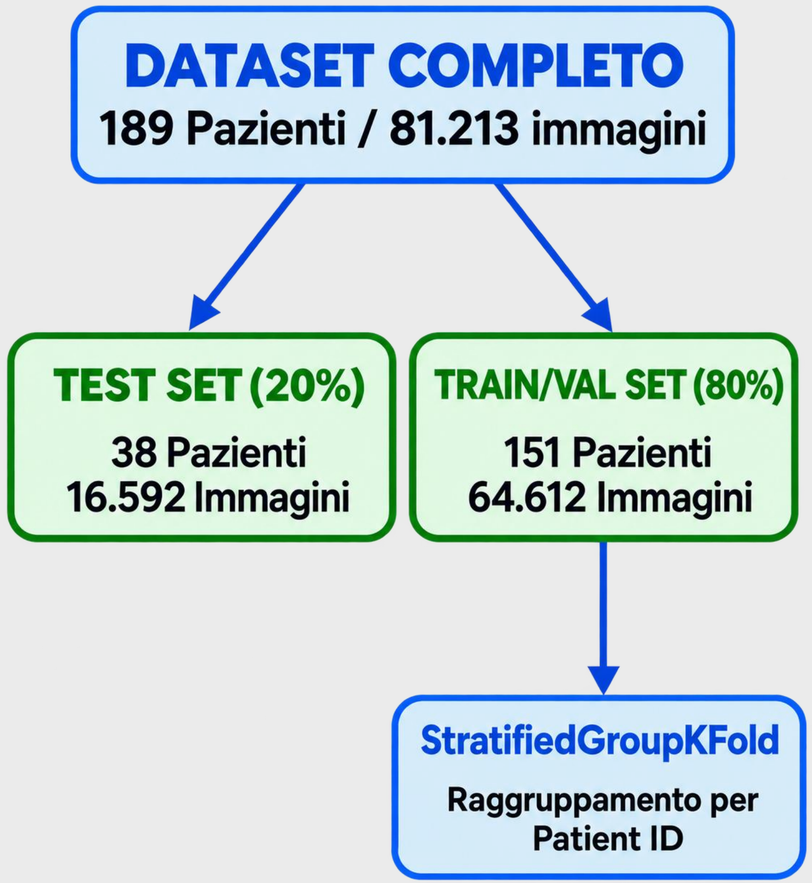
PML_RARA



RUNX1_RUNX1T1

Partizionamento e Prevenzione del Data Leakage

- **Il Rischio (Patient-Level Leakage)**
  - Vetrini dello stesso paziente condividono tratti tecnici comuni (colorazione, spessore).
  - Rischio *:* La rete memorizza l'impronta cromatica invece della patologia.
- **Suddivisione del Dataset (189 Pazienti / 81.213 Immagini)**
  - Test Set (20%)
  - Train/Val (80%)
- **Validazione (StratifiedGroupKFold)**
  - Raggruppamento rigoroso per Patient_ID.
  - Totale segregazione dei dati e azzeramento dei bias.

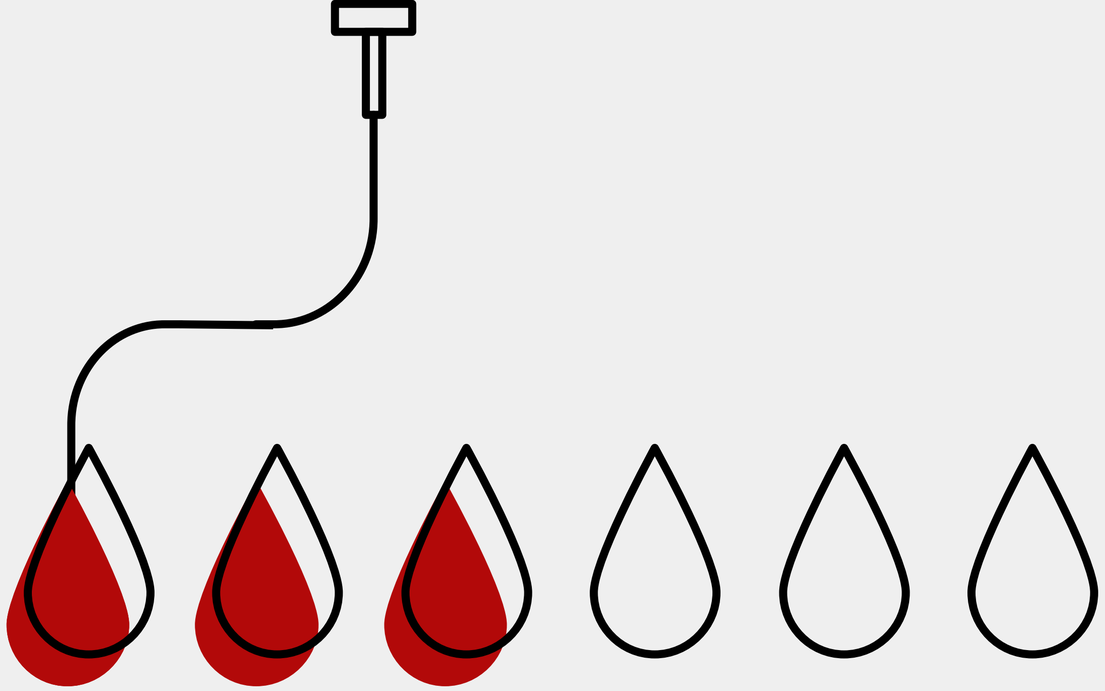


Campionamento Bilanciato a Livello Paziente

0%

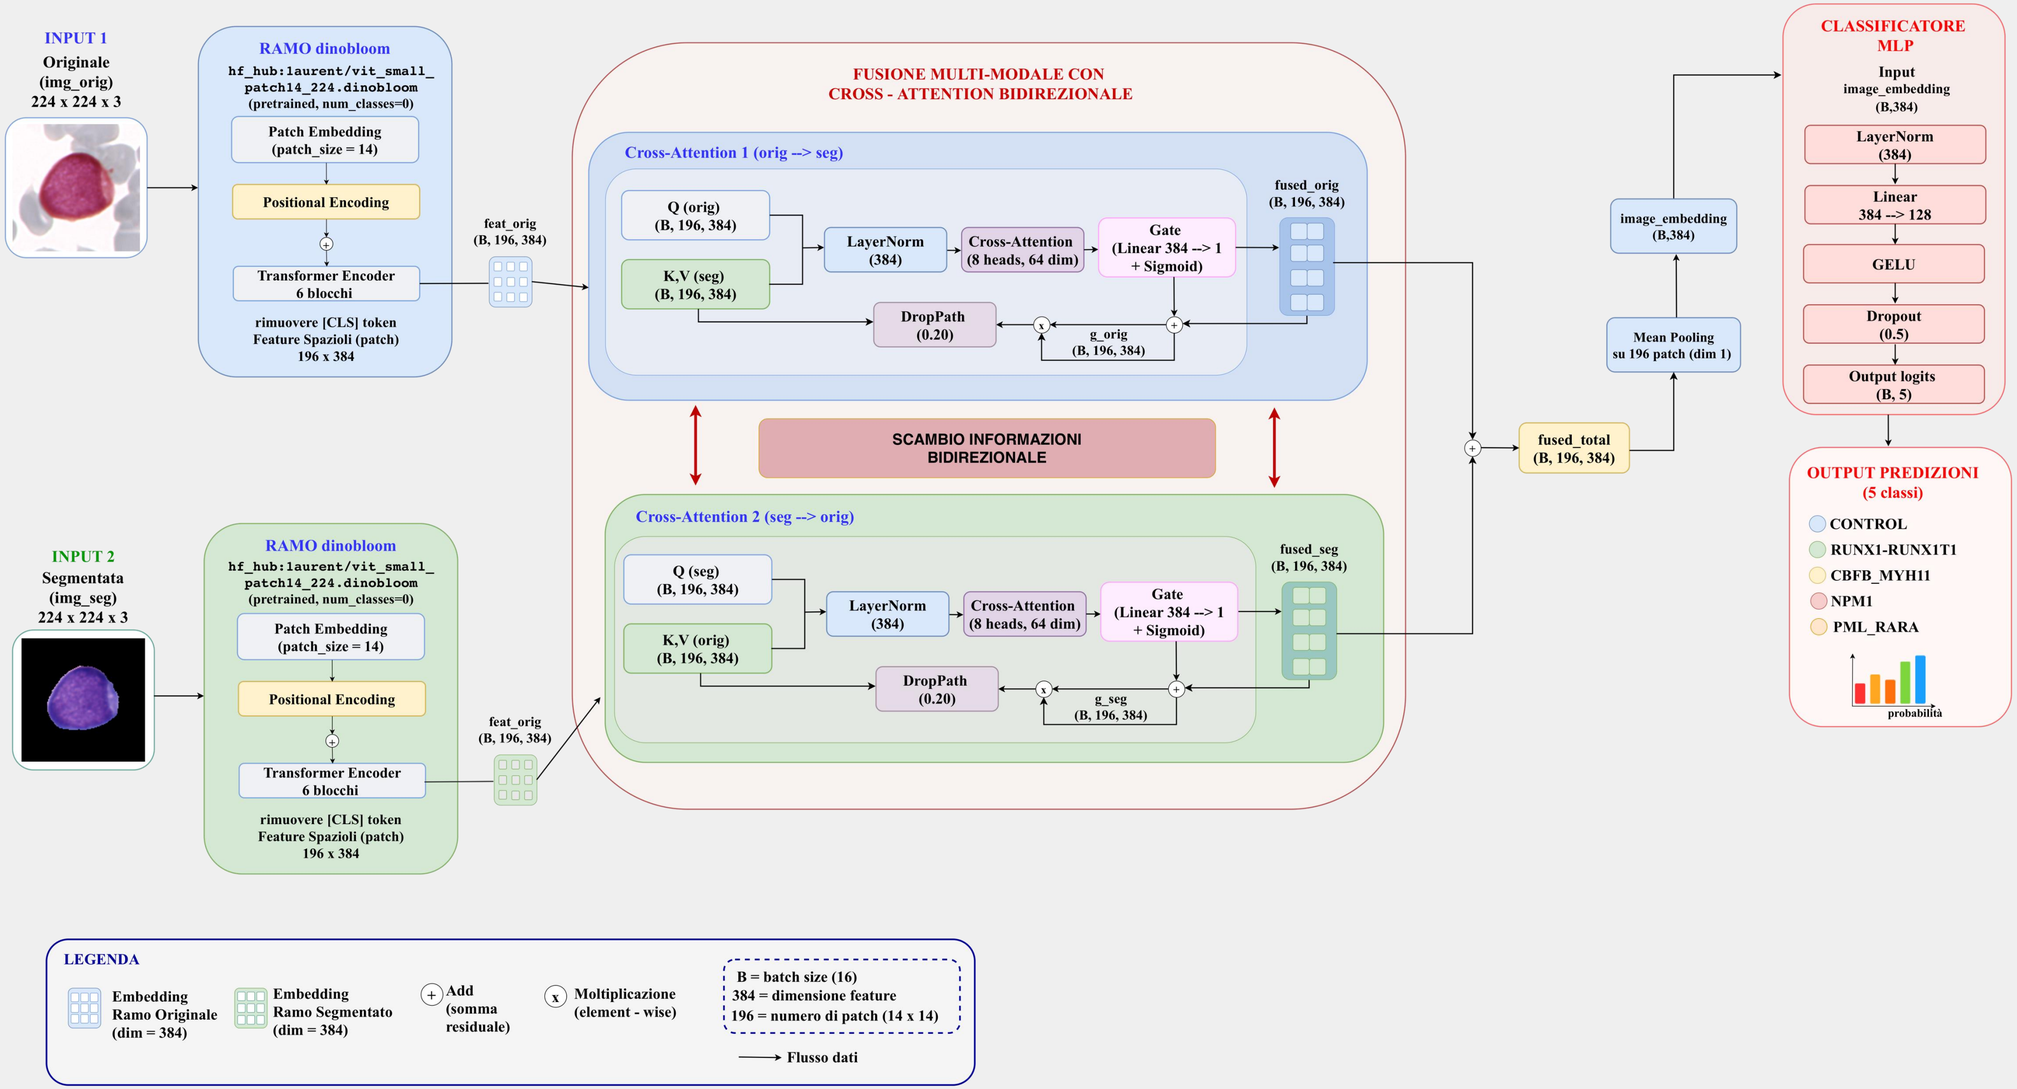
Data Leakage tra Training e Validation

Partizionamento a livello paziente: tutte le cellule dello stesso individuo sono vincolate esclusivamente ad un singolo fold, evitando che il modello impari caratteristiche peculiari del singolo paziente come cromatina del vetrino anziché i reali pattern patologici.



Architettura del Modello

Il Modello


INPUT 1
Originale
(img_orig)
224 x 224 x 3
RAMO dinobloom
hf_hub:laurent/vit_small_patch14_224.dinobloom
(pretrained, num_classes=0)
Patch Embedding
(patch_size = 14)
Positional Encoding
Transformer Encoder
6 blocchi
rimuovere [CLS] token
Feature Spazioli (patch)
196 x 384
feat_orig
(B, 196, 384)
FUSIONE MULTI-MODALE CON
CROSS - ATTENTION BIDIREZIONALE
Cross-Attention 1 (orig --> seg)
Q (orig)
(B, 196, 384)
K,V (seg)
(B, 196, 384)
LayerNorm
(384)
Cross-Attention
(8 heads, 64 dim)
Gate
(Linear 384 --> 1
+ Sigmoid)
fused_orig
(B, 196, 384)
DropPath
(0.20)
g_orig
(B, 196, 384)
SCAMBIO INFORMAZIONI
BIDIREZIONALE
Cross-Attention 2 (seg --> orig)
Q (seg)
(B, 196, 384)
K,V (orig)
(B, 196, 384)
LayerNorm
(384)
Cross-Attention
(8 heads, 64 dim)
Gate
(Linear 384 --> 1
+ Sigmoid)
fused_seg
(B, 196, 384)
DropPath
(0.20)
g_seg
(B, 196, 384)
INPUT 2
Segmentata
(img_seg)
224 x 224 x 3
RAMO dinobloom
hf_hub:laurent/vit_small_patch14_224.dinobloom
(pretrained, num_classes=0)
Patch Embedding
(patch_size = 14)
Positional Encoding
Transformer Encoder
6 blocchi
rimuovere [CLS] token
Feature Spazioli (patch)
196 x 384
feat_orig
(B, 196, 384)
fused_total
(B, 196, 384)
Mean Pooling
su 196 patch (dim 1)
image_embedding
(B,384)
CLASSIFICATORE
MLP
Input
image_embedding
(B,384)
LayerNorm
(384)
Linear
384 --> 128
GELU
Dropout
(0.5)
Output logits
(B, 5)
OUTPUT PREDIZIONI
(5 classi)
CONTROL
RUNX1-RUNX1T1
CBFB_MYH11
NPM1
PML_RARA
probabilità
LEGENDA
Embedding
Ramo Originale
(dim = 384)
Embedding
Ramo Segmentato
(dim = 384)
Add
(somma
residuale)
Moltiplicazione
(element - wise)
B = batch size (16)
384 = dimensione feature
196 = numero di patch (14 x 14)
Flusso dati

Perche ViT Dual Stream ?

1. Vision Transformer

Superamento dei limiti delle CNN

- **Self-Attention:** Analisi globale dell'immagine cellulare.
- Correlazione diretta tra nucleo e citoplasma.

2. Flussi Complementari

Integrazione Multi-Input

- **Ramo Originale:** Preserva contesto e fondo.
- **Ramo Segmentato:** Isola il target cellulare.

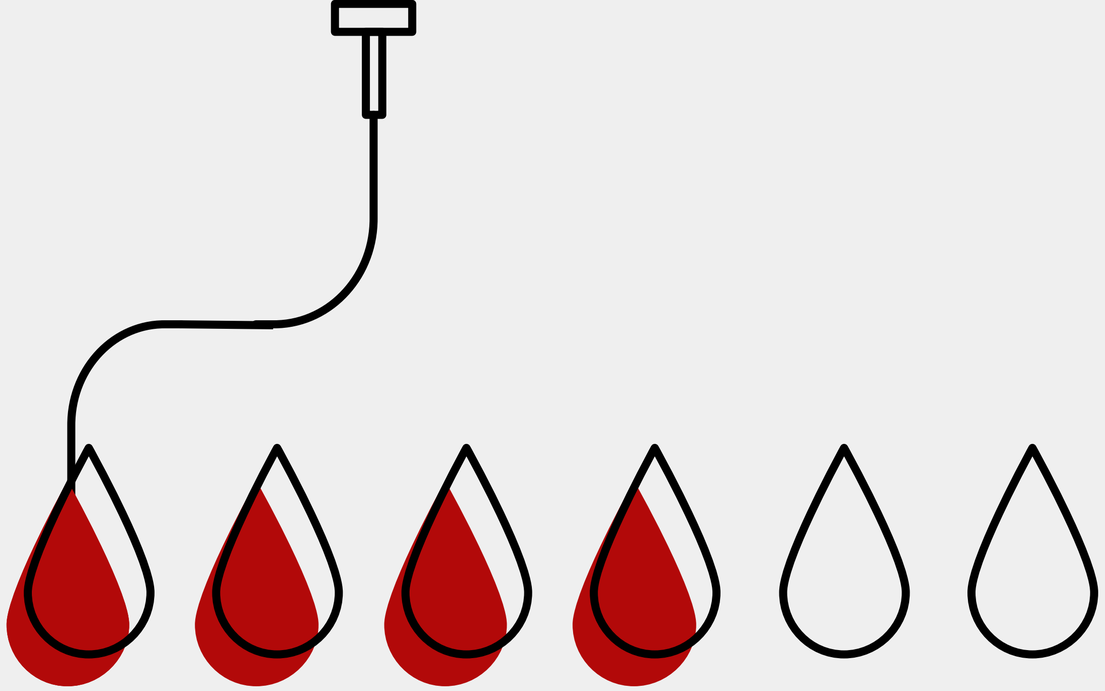
3. Cross-Attention

Interazione Dinamica

- Dialogo continuo tra i due flussi.
- Arricchimento e correzione reciproca.

Analogia Clinica: Il modello replica il processo visivo dell'ematologo

Integra continuamente il panorama visivo globale con il dettaglio diagnostico focalizzato, garantendo una classificazione precisa e robusta.



Addestramento

Preprocessing e Data Augmentation

Rotazioni & Flip

Rotazioni con scelta da [0, 90, 180, 270] gradi, olio orizzontali e verticali.

Preprocessing e Data Augmentation

Rotazioni & Flip

Rotazioni con scelta da [0, 90, 180, 270] gradi, olio orizzontali e verticali.

Color Jittering

Alterazioni stocastiche di luminosità, contrasto, saturazione e tonalità.

Preprocessing e Data Augmentation

Rotazioni & Flip

Rotazioni con scelta da [0, 90, 180, 270] gradi, olio orizzontali e verticali.

Color Jittering

Alterazioni stocastiche di luminosità, contrasto, saturazione e tonalità.

Random Erasure

Cancellazione stocastica di porzioni della maschera segmentata su per prevenire l'overfitting topologico.

Preprocessing e Data Augmentation

Rotazioni & Flip

Rotazioni con scelta da [0, 90, 180, 270] gradi, olio orizzontali e verticali.

Color Jittering

Alterazioni stocastiche di luminosità, contrasto, saturazione e tonalità.

Random Erasure

Cancellazione stocastica di porzioni della maschera segmentata su per prevenire l'overfitting topologico.

Loss Function & Regolarizzazione

Cross-Entropy Pesata

$$\mathscr{L}_{\mathbf{CE}}(\hat{y}, y) = -\sum_{c=0}^{C-1} w_c \cdot q_c \log(\sigma(\hat{y})_c)$$

Pesi Asimmetrici: bilanciamento ponderato sulle frequenze reali delle 5 classi.

Compensazione Classi: penalizzazione maggiorata sulle mutazioni rare.

Loss Function & Regolarizzazione

Cross-Entropy Pesata

$$\mathscr{L}_{\mathbf{CE}}(\hat{y}, y) = -\sum_{c=0}^{C-1} w_c \cdot q_c \log(\sigma(\hat{y})_c)$$

Pesi Asimmetrici: bilanciamento ponderato sulle frequenze reali delle 5 classi.

Compensazione Classi: penalizzazione maggiorata sulle mutazioni rare.

Label Smoothing (0.30)

- **Riduzione Overconfidence:** ammorbidimento dei target binari a probabilità distribuite.
- **Generalizzabilità:** calibrazione predittiva ottimizzata sui confini di classe.

Gestione del gradiente

0.20

DropPath Rate

Stochastic Depth nei blocchi Cross-Attention

Gestione del gradiente

0.20

DropPath Rate

Stochastic Depth nei blocchi Cross-Attention

4 Step

Gradient Accumulation

Simulazione di batch size estesi su GPU

Gestione del gradiente

0.20

DropPath Rate

Stochastic Depth nei blocchi Cross-Attention

4 Step

Gradient Accumulation

Simulazione di batch size estesi su GPU

1.0

Gradient Clipping

Per prevenire correzioni troppo aggressive ed evitare che il modello vada in tilt.

Gestione del gradiente

0.20

DropPath Rate

Stochastic Depth nei blocchi Cross-Attention

4 Step

Gradient Accumulation

Simulazione di batch size estesi su GPU

1.0

Gradient Clipping

Per prevenire correzioni troppo aggressive ed evitare che il modello vada in tilt.

Dynamic Learning Rate & Early Stopping

- **ReduceLROnPlateau**

  → **Decadimento Dinamico**: riduce dinamicamente il Learning Rate quando l'errore di validazione si stabilizza, permettendo alla rete di accorciare il passo e rifinire la ricerca della soluzione migliore.

- **Regola di Early Stopping**

  → **Interruzione Precoce**: interrompe l'addestramento se non si registrano miglioramenti per un numero prefissato di epoche, evitando la memorizzazione del rumore e il fenomeno dell'overfitting.

Aggregazione Logits & Soglie Adattive

Confidence-Weighted Pooling

Media Pesata Cellulare: aggregazione dei logit di ogni singola cellula ponderata dalla confidenza relativa prima del verdetto sul paziente.

Aggregazione Logits & Soglie Adattive

Confidence-Weighted Pooling

Media Pesata Cellulare: aggregazione dei logit di ogni singola cellula ponderata dalla confidenza relativa prima del verdetto sul paziente.

Soglie Adattive per Classe

Calibrazione Sensibilità: soglie decisionali personalizzate sulle traslocazioni critiche (es. CBFB_MYH11) per ridurre i falsi negativi.

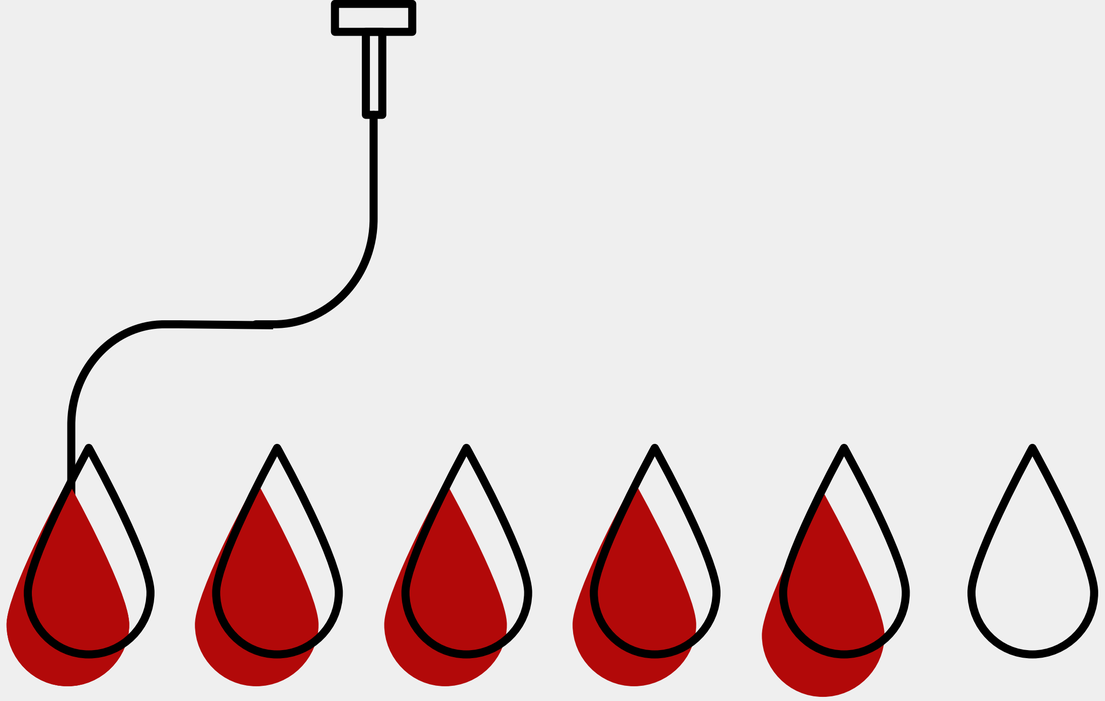
Aggregazione Logits & Soglie Adattive

Confidence-Weighted Pooling

Media Pesata Cellulare: aggregazione dei logit di ogni singola cellula ponderata dalla confidenza relativa prima del verdetto sul paziente.

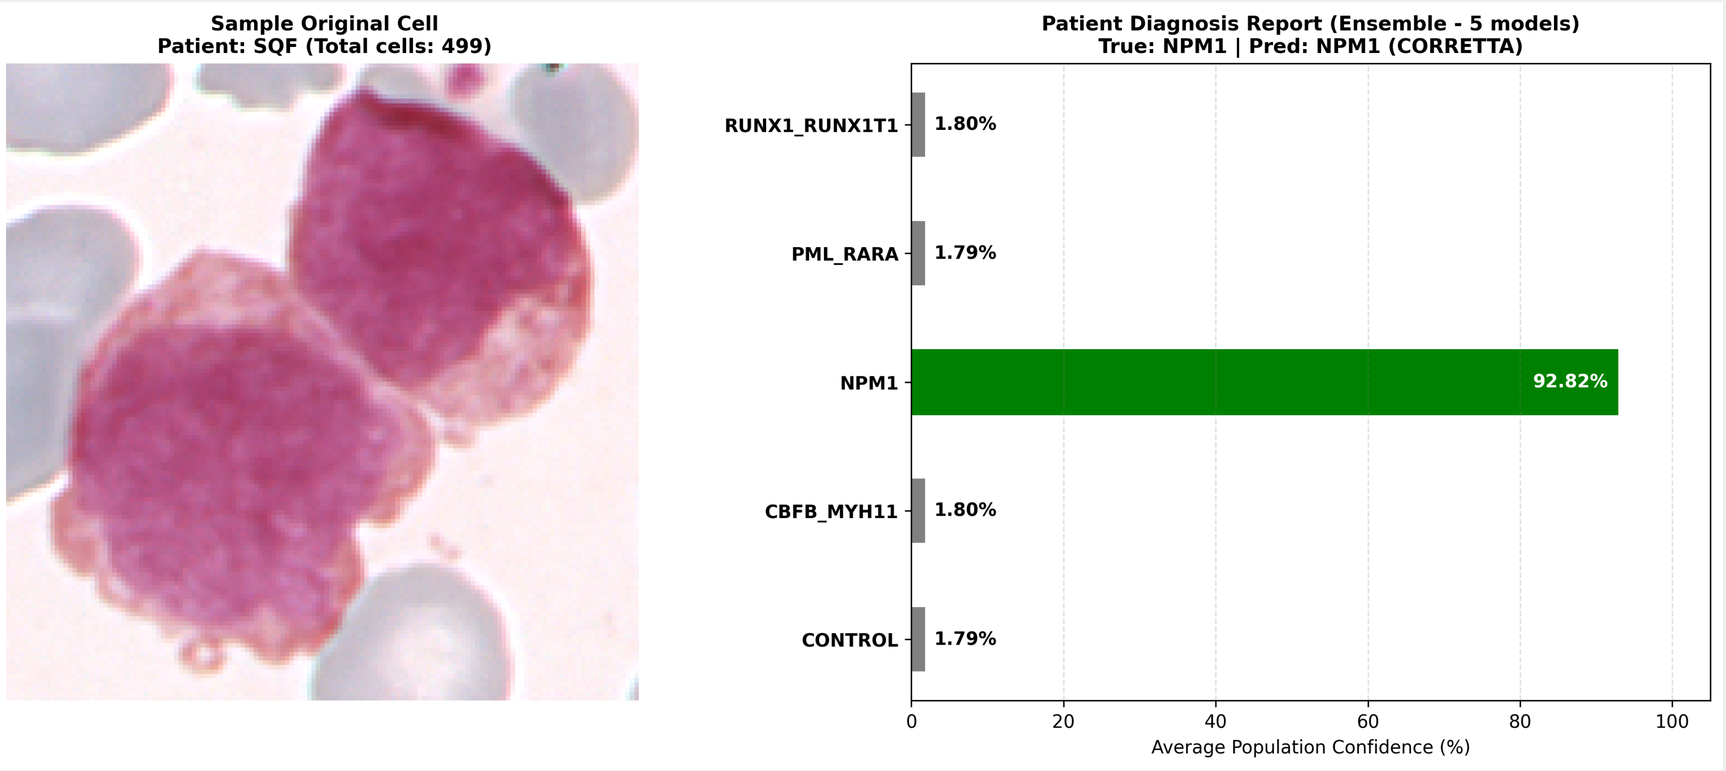
Soglie Adattive per Classe

Calibrazione Sensibilità: soglie decisionali personalizzate sulle traslocazioni critiche (es. CBFB_MYH11) per ridurre i falsi negativi.



Risultati e Valutazione del Modello

Reportistica diagnostica



Pipeline di Inferenza e Diagnostica Clinica

FASE 01

Filtraggio

Combiniamo i 3 modelli e scartiamo le cellule con confidenza inferiore al 20%, perché troppo incerte o rovinate.

Pipeline di Inferenza e Diagnostica Clinica

FASE 01

Filtraggio

Combiniamo i 3 modelli e scartiamo le cellule con confidenza inferiore al 20%, perché troppo incerte o rovinate.

FASE 02

Calibrazione

Temperature Scaling per smussare le probabilità ed evitare che la rete sia troppo ‘overconfident'.

Pipeline di Inferenza e Diagnostica Clinica

FASE 01

Filtraggio

Combiniamo i 3 modelli e scartiamo le cellule con confidenza inferiore al 20%, perché troppo incerte o rovinate.

FASE 02

Calibrazione

Temperature Scaling per smussare le probabilità ed evitare che la rete sia troppo overconfident.

FASE 03

Diagnosi Paziente

Calcoliamo la media delle cellule rimaste: la classe con la probabilità media più alta diventa la diagnosi del paziente.

Pipeline di Inferenza e Diagnostica Clinica

FASE 01

Filtraggio

Combiniamo i 3 modelli e scartiamo le cellule con confidenza inferiore al 20%, perché troppo incerte o rovinate.

FASE 02

Calibrazione

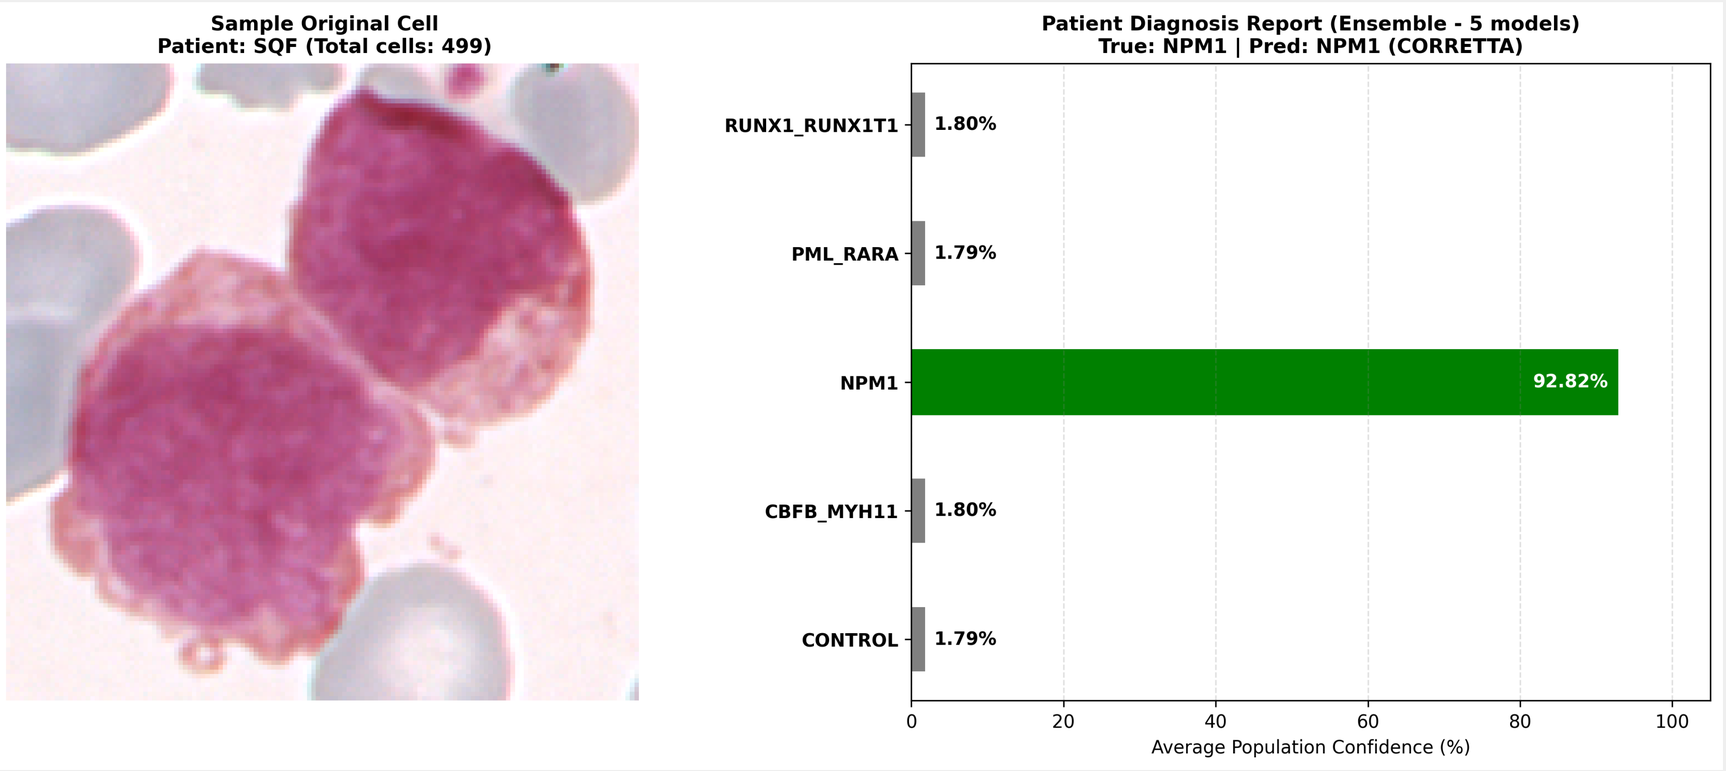
Temperature Scaling per smussare le probabilità ed evitare che la rete sia troppo overconfident.

FASE 03

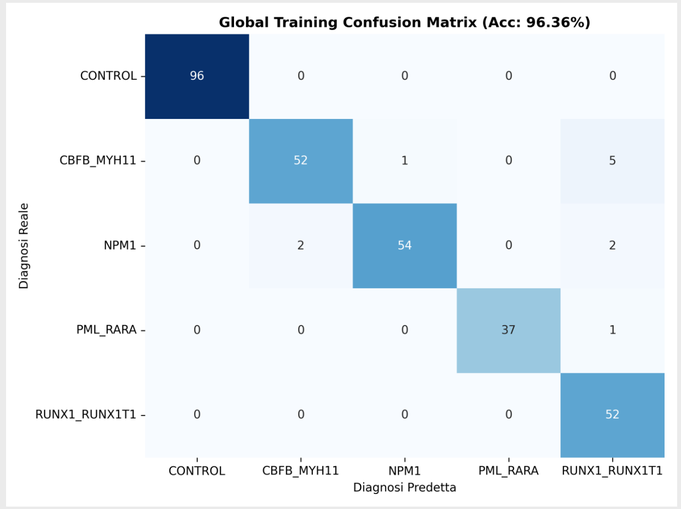
Diagnosi Paziente

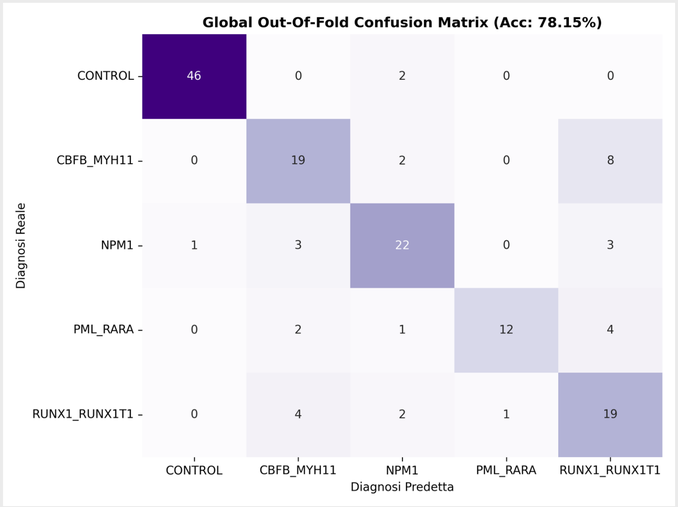
Calcoliamo la media delle cellule rimaste: la classe con la probabilità media più alta diventa la diagnosi del paziente.

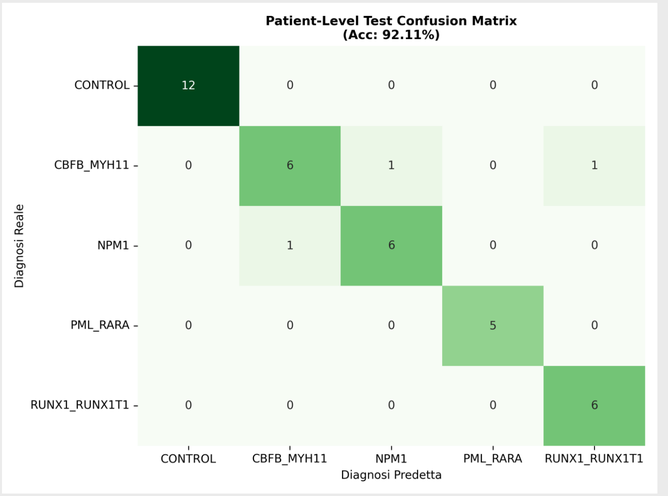
Reportistica diagnostica

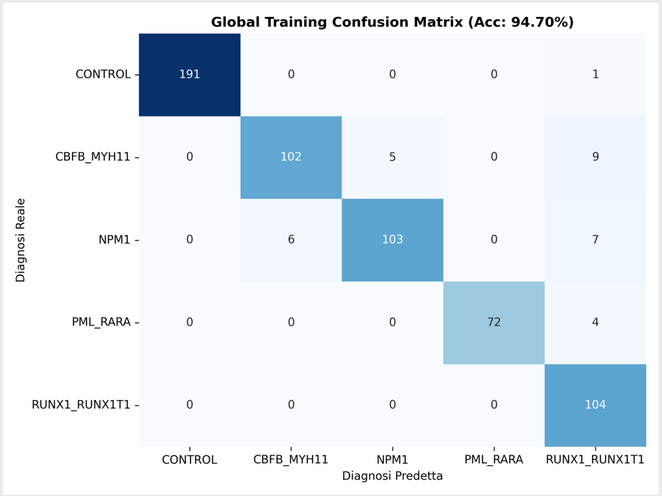


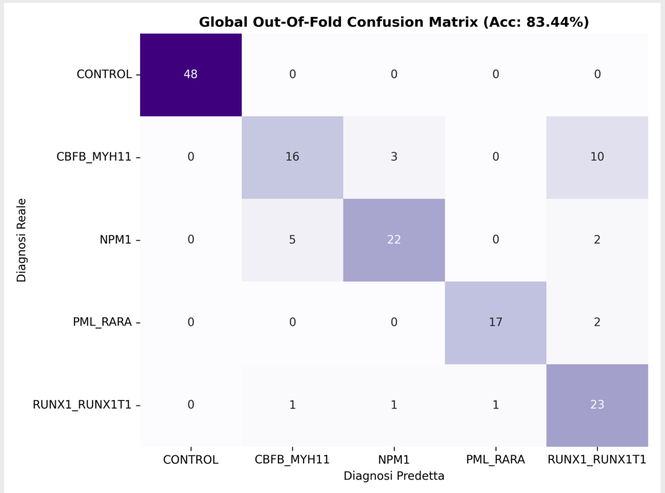
Esperimenti k=3 & k=5

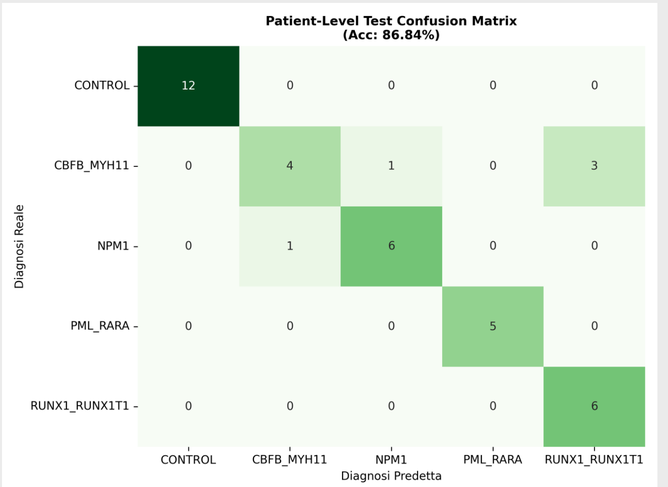




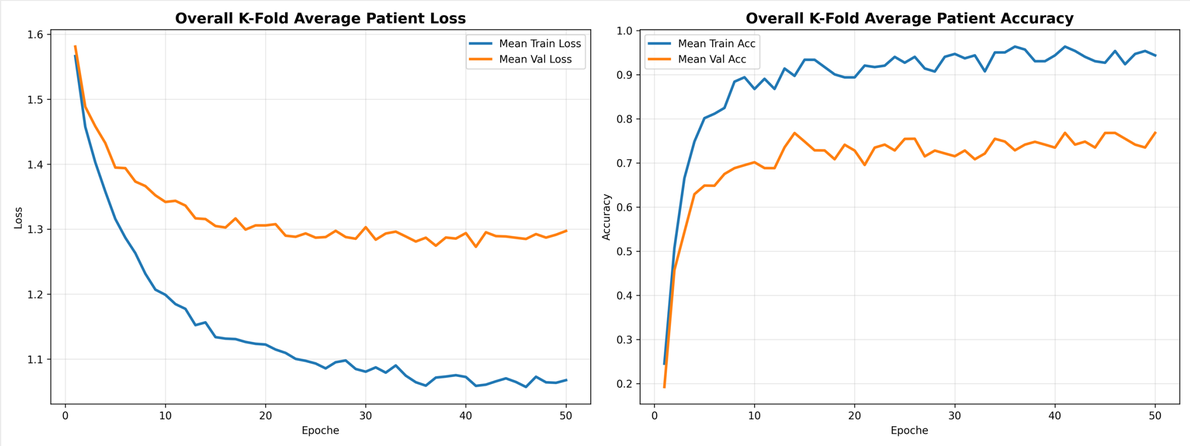






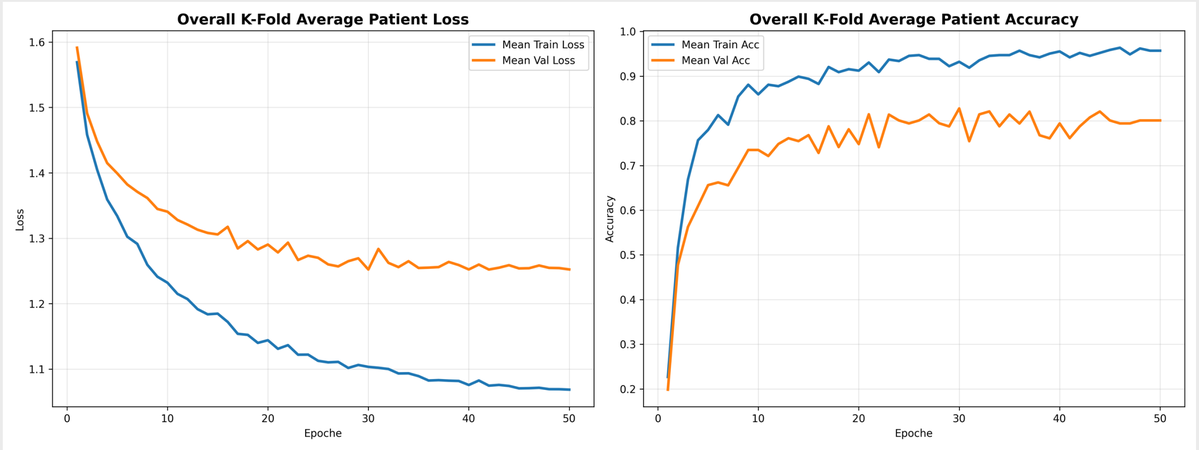


Curve Loss e Accuracy



(K=3)

(K=5)



Altre Metriche di Valutazione



Metrica 1

F1-Score

Combiniamo Precision e Recall in una singola metrica utilizzando la media armonica per dare una misura globale di accuratezza.



Metrica 2

ROC-AUC (Spec + Sens)

Valuta quanto il modello è affidabile nel distinguere lo stato patologico da quello sano, indipendentemente dalla soglia scelta



Metrica 3

PR-AUC (Prec + Rec)

Valuta l'affidabilità delle predizioni positive, particolarmente cruciale quando gestiamo classi sbilanciate

Confronto con SCEMILA

SCEMILA : Stato dell'arte



PLOS DIGITAL HEALTH

RESEARCH ARTICLE

Explainable AI identifies diagnostic cells of genetic AML subtypes

Matthias Hehr[1,2,3], **Ario Sadafi**[1,2,4], **Christian Matek**[1,2,3], **Peter Lienemann**[1,3], **Christian Pohlkamp**[5], **Torsten Haferlach**[5], **Karsten Spiekermann**[3,6,7], **Carsten Marr**[1,2,*]

1 Institute of AI for Health, Helmholtz Zentrum München–German Research Center for Environmental Health, Neuherberg, Germany, **2** Institute of Computational Biology, Helmholtz Zentrum München–German Research Center for Environmental Health, Neuherberg, Germany, **3** Laboratory of Leukemia Diagnostics, Department of Medicine III, University Hospital, LMU Munich, Munich, Germany, **4** Computer Aided Medical Procedures, Technical University of Munich, Munich, Germany, **5** Munich Leukemia Laboratory, Munich, Germany, **6** German Cancer Consortium (DKTK), Heidelberg, Germany, **7** German Cancer Research Center (DKFZ), Heidelberg, Germany

* carsten.marr@helmholtz-muenchen.de

Abstract

Explainable AI is deemed essential for clinical applications as it allows rationalizing model predictions, helping to build trust between clinicians and automated decision support tools. We developed an inherently explainable AI model for the classification of acute myeloid leukemia subtypes from blood smears and found that high-attention cells identified by the model coincide with those labeled as diagnostically relevant by human experts. Based on over 80,000 single white blood cell images from digitized blood smears of 129 patients diagnosed with one of four WHO-defined genetic AML subtypes and 60 healthy controls, we trained SCEMILA, a single-cell based explainable multiple instance learning algorithm. SCEMILA could perfectly discriminate between AML patients and healthy controls and detected the APL subtype with an F1 score of 0.86±0.05 (means±s.d., 5-fold cross-validation). Analyzing a novel multi-attention module, we confirmed that our algorithm focused with high concordance on the same AML-specific cells as human experts do. Applied to classify single cells, it is able to highlight subtype specific cells and deconvolve the composition of a patient's blood smear without the need of single-cell annotation of the training data. Our large AML genetic subtype dataset is publicly available, and an interactive online tool facilitates the exploration of data and predictions. SCEMILA enables a comparison of algorithmic and expert decision criteria and can present a detailed analysis of individual patient data, paving the way to deploy AI in the routine diagnostics for identifying hematopoietic neoplasms.

Author summary

The analysis of blood and bone marrow smear microscopy by trained human experts remains an essential cornerstone of the diagnostic workup for severe blood diseases, like acute myeloid leukemia. While this step yields insight into a patient's blood system composition, it is also tedious, time consuming and not standardized. Here, we present

OPEN ACCESS

Citation: Hehr M, Sadafi A, Matek C, Lienemann P, Pohlkamp C, Haferlach T, et al. (2023) Explainable AI identifies diagnostic cells of genetic AML subtypes. PLOS Digit Health 2(3): e0000187. https://doi.org/10.1371/journal.pdig.0000187

Editor: Heather Mattie, Harvard University T H Chan School of Public Health, UNITED STATES

Received: May 26, 2022

Accepted: December 19, 2022

Published: March 15, 2023

Copyright: © 2023 Hehr et al. This is an open access article distributed under the terms of the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original author and source are credited.

Data Availability Statement: The data used to train this model has been published at The Cancer Imaging Archive (TCIA) and can be downloaded at https://doi.org/10.7937/6ppe-#020.

Funding: M.H. acknowledges support from Deutsche José Carreras-Leukämie Stiftung. C.M. has received funding from the European Research Council (ERC) under the European Union's Horizon 2020 research and innovation program (Grant agreement No. 866411). The funders had no role in study design, data collection and analysis, decision to publish, or preparation of the manuscript.

Titolo

Explainable AI identifies diagnostic cells of genetic AML subtypes

Rivista

PLOS DIGITAL HEALTH

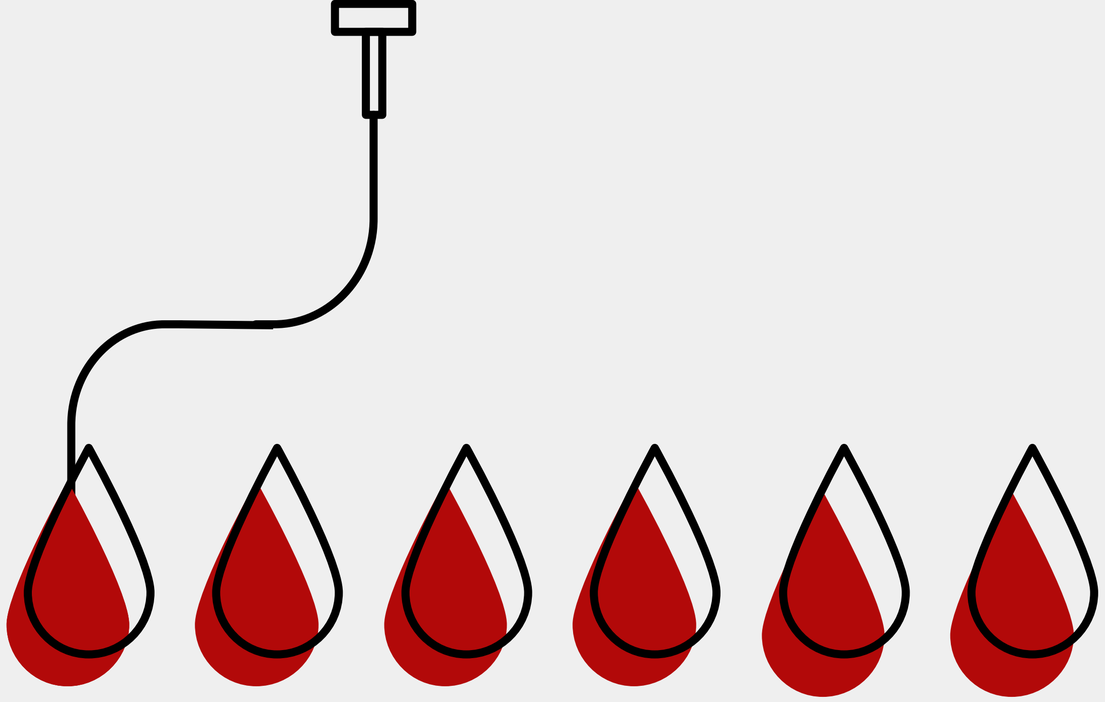
Autori

Hehr M. et al.

Parametro/Metrica	SCEMILA	Modello Tesi
F1-score		
PML::RARA	0.86	1.00
NPM1	0.75	0.86
CBFB::MYH11	0.69	0.80
RUNX1::RUNX1T1	0.75	0.92
Control	1.00	1.00
Macro	0.81	0.92

Parametro/Metrica	SCEMILA	Modello Tesi
ROC-AUC (Spec + Sens)		
PML::RARA	0.941	1.0000
NPM1	0.927	0.9724
CBFB::MYH11	0.945	0.9625
RUNX1::RUNX1T1	0.932	0.9792
Control	1.000	1.0000
Macro	0.953	0.9828

Parametro/Metrica	SCEMILA	Modello Tesi
PR-AUC (Prec + Rec)		
PML::RARA	0.920	1.0000
NPM1	0.819	0.8844
CBFB::MYH11	0.716	0.8726
RUNX1::RUNX1T1	0.736	0.9333
Control	1.000	1.0000
Macro	0.838	0.9381



Sviluppi Futuri

Sviluppi Futuri

- **Ampliamento del Dataset e Reclutamento di Nuove Classi di Pazienti**
- **Ottimizzazione del Modello & ottimizzazione iper-parametri**
- **Spiegabilità e Interpretabilità Clinica (XAI)**

Grazie per l’Attenzione