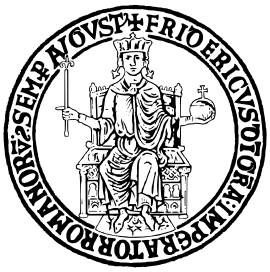
Università degli Studi di Napoli Federico II



Scuola Politecnica e delle Scienze di Base

Dipartimento di Ingegneria Elettrica e Tecnologie dell'Informazione

Corso di Laurea Magistrale in Informatica

Classificazione della Leucemia Mieloide Acuta da immagini

Relatore
Prof. Francesco Isgrò

Correlatore
Prof. Andrea Calì

Candidato
Fabiola Salomone
N97/457

Anno Accademico 2025–2026

Università degli Studi di Napoli Federico II

Scuola Politecnica e delle Scienze di Base

Dipartimento di Ingegneria Elettrica e Tecnologie dell'Informazione

Corso di Laurea Magistrale in Informatica

Classificazione della Leucemia Mieloide Acuta da immagini

Relatore
Prof. Francesco Isgrò

Correlatore
Prof. Andrea Calì

Candidato
Fabiola Salomone
N97/457

Anno Accademico 2025–2026

Sommario

La **Leucemia Mieloide Acuta** (AML) è una patologia caratterizzata da un'elevata eterogeneità genetica e fenotipica, la cui tempestiva e accurata caratterizzazione rappresenta un requisito fondamentale per la definizione dei protocolli terapeutici. Tuttavia, la diagnosi tradizionale basata su microscopia ottica presenta significative criticità operative, dovute principalmente alle sottili variazioni strutturali e alla marcata sovrapposizione morfologica tra i diversi sottotipi genetici. Per superare tali limitazioni, il presente lavoro di tesi propone un framework basato sul Deep Learning per la classificazione automatica di cinque classi di rilevanza clinica: *CONTROL*, *CBFB_MYH11*, *NPM1*, *PML_RARA* e *RUNX1_RUNX1T1*.

L'architettura proposta si basa su un modello **Multi-Modal Cross-ViT (Dual-Stream)**, progettato per estrarre e fondere in modo bidirezionale le rappresentazioni visive delle immagini a microscopia ottica (Original Stream) e delle relative maschere di segmentazione (*Segmented Stream*). L'interazione tra i due flussi è regolata da un modulo di Gated Cross-Attention che, tramite un'attivazione sigmoidea, adatta dinamicamente l'apporto della rappresentazione combinata pesandone l'affidabilità in base alla qualità strutturale della segmentazione del nucleo blastico.

La validazione è stata condotta sul dataset citomorfologico **AML - Cytomorphology (MLL)** attraverso un rigoroso schema di addestramento, validazione e testing. Per garantire la generalizzabilità del modello ed evitare fenomeni di *data leakage*, la suddivisione dei dati è stata effettuata a livello di singolo paziente.I risultati ottenuti sul set di test dimostrano l'efficacia del meccanismo di fusione nel discriminare con elevata accuratezza i diversi sottotipi/morfologie di AML.

In conclusione, il framework si configura come un solido e accurato strumento computazionale a supporto della diagnosi ematologica, capace di coniugare un'elevata capacità discriminativa con una spiccata robustezza d'analisi, ponendo le basi per un'efficace integrazione nel workflow clinico.

Indice

1 Introduzione **1**
- 1.1 Contesto Clinico della Leucemia Mieloide Acuta . . . 1
  - 1.1.1 Descrizione dei Sottotipi Molecolari di AML . . . 2
- 1.2 Limiti della Citomorfologia Manuale Tradizionale . . . 3
- 1.3 L'Evoluzione dell'IA: Dalle Feature Handcrafted ai ViT . . . 4
- 1.4 Obiettivi della Tesi e Contributi Originali . . . 6
  - 1.4.1 Obiettivi Specifici . . . 6
  - 1.4.2 Contributi Originali . . . 7

2 Stato dell'Arte e Fondamenti Teorici **9**
- 2.1 Fondamenti di Apprendimento Profondo e Valutazione delle Prestazioni 9
  - 2.1.1 Reti Neurali Artificiali e Modelli di Apprendimento . . . 10
  - 2.1.2 Processo di Addestramento e Retropropagazione . . . 10
  - 2.1.3 Strategie di Partizionamento del Dataset e Validazione . . . 11
  - 2.1.4 Metriche di Valutazione delle Prestazioni . . . 11
- 2.2 Vision Transformers in Medicina . . . 12
  - 2.2.1 Architettura e Elaborazione dell'Immagine . . . 13
  - 2.2.2 Il Meccanismo di Self-Attention Scaled Dot-Product . . . 13
  - 2.2.3 Vantaggi Rispetto alle CNN nell'Analisi del Contesto Globale . . 15
- 2.3 Fusione Multimodale e Meccanismi di Cross Attention . . . 16
  - 2.3.1 Stato dell'Arte sulle Strategie di Fusione . . . 16
  - 2.3.2 Modellazione Computazionale della Cross-Attention . . . 17
- 2.4 Architetture Dual-Stream RGB-Segmentation nei Vision Transformers . 18
  - 2.4.1 Formalizzazione del Disaccoppiamento Bi-Ramo . . . 19
  - 2.4.2 Interazione Cross-Modale Intermedia . . . 20
  - 2.4.3 Proiezione e Fusione nello Spazio Latente . . . 20
  - 2.4.4 Vantaggi e Svantaggi del Paradigma Dual-Stream . . . 21

3 Architettura del Modello Proposto **22**
- 3.1 Introduzione al Framework Dual-Stream . . . 22
- 3.2 Dettaglio Funzionale dei Singoli Moduli . . . 24
  - 3.2.1 Backbone Custom DinoBloom-S e Congelamento Integrale . . . 24
  - 3.2.2 Modulo di Gated Cross-Attention . . . 26

3.2.3 Blocco Transformer con DropPath . . . 27
3.2.4 Fusione Additiva Diretta e Aggregazione Spaziale . . . 29
3.2.5 Testa di Classificazione Finale . . . 29
3.3 Motivazione dell'architettura proposta . . . 32
3.4 Ambiente di Sviluppo e Strumenti Software . . . 35
3.5 Conclusioni . . . 36

4 Caratterizzazione del Dataset e Gestione dei Dati 37
4.1 Introduzione al Dataset . . . 37
4.1.1 Inquadramento Cito-Morfologico dei Sottotipi Genotipici . . . 38
4.1.2 Protocollo di Digitalizzazione e Specifiche Ottico-Spaziali . . . 38
4.2 Pipeline di Pre-Elaborazione e Segmentazione . . . 39
4.2.1 Isolamento Cromatico nello Spazio CIE Lab . . . 39
4.3 Gestione del Data Leakage e Split per Pazienti . . . 40
4.3.1 Definizione Teorica del Patient-Level Data Leakage . . . 40
4.3.2 Test Set Esterno Indipendente (Holdout) . . . 41
4.3.3 Struttura dei 3 Folds di Cross-Validation . . . 41
4.3.4 Verifica della Coerenza e Integrità . . . 42

5 Pipeline di Addestramento 43
5.1 Introduzione al Processo del Training . . . 43
5.2 Gestione del Dataset, Preprocessing e Data Augmentation . . . 44
5.2.1 Strutturazione del Dataset Custom . . . 44
5.2.2 Normalizzazione e Trasformazioni Spaziali/Cromatiche . . . 45
5.3 Campionamento Bilanciato a Livello Paziente (Patient-Aware Subsampling) 46
5.4 Ingegnerizzazione dell'Addestramento e Funzioni di Costo . . . 46
5.4.1 Configurazione degli Iperparametri . . . 46
5.4.2 Cross-Entropy Pesata con Label Smoothing e Class Weights Asimmetrici . . . 47
5.4.3 Accumulo dei Gradienti e Gradient Clipping . . . 48
5.5 Modello di Valutazione e Aggregazione dei Logits a Livello Paziente . . . 48
5.5.1 Aggregazione Pesata per la Confidenza (Confidence-Weighted Pooling) . . . 49
5.5.2 Decisore con Soglie Adattive per Classe (*Adaptive Class Thresholds*) 49
5.6 Strategie di Controllo, Dynamic Learning Rate ed Early Stopping . . . 51
5.6.1 Decadimento del Learning Rate (`ReduceLROnPlateau`) . . . 51
5.6.2 Regola di Early Stopping . . . 51
5.7 K-Cross Validation a Livello Paziente . . . 52
5.8 Ensemble Inferenziale sul Test Set Esterno . . . 52

6 Pipeline di Classificazione 54
6.1 Gestione delle Risorse Computazionali e Inizializzazione . . . 54
6.2 Architettura di Ensemble Cross-Validation . . . 55

6.2.1 Caricamento dei Modelli e Meccanismi di Ridondanza 55
6.2.2 Normalizzazione Dual-Stream 56
6.2.3 Predizione d'Insieme (Ensemble Averaging) 56
6.3 Pipeline di Diagnosi a Livello di Paziente 56
6.3.1 Gestione Dinamica dell'Input Dual-Stream e Meccanismo di Fallback 56
6.3.2 Aggregazione della Popolazione Cellulare 57
6.4 Algoritmo di Calibrazione Dinamica della Confidenza 59
6.4.1 Estrazione della Probabilità Grezza di Popolazione 59
6.4.2 Mappatura dell'Intervallo Target di Confidenza 59
6.4.3 Ottimizzazione Iterativa della Temperatura sui Logit 60
6.4.4 Ridistribuzione delle Probabilità Residue 61
6.5 Gestione dello Stato e Riproducibilità dei Test 62
6.5.1 Registro dei Pazienti Analizzati 62
6.6 Generazione del Report Diagnostico Grafico 62
6.7 Considerazioni sulle Prestazioni di Classificazione 63

7 Risultati e Discussione Critica 65
7.1 Valutazione delle Curve di Apprendimento e Convergenza 65
7.2 Analisi Approfondita delle Matrici di Confusione 67
7.2.1 Matrice di Confusione Complessiva - Training Set 67
7.2.2 Matrice di Confusione - Validation Set 69
7.2.3 Matrice di Confusione - Test Set 71
7.2.4 Analisi delle Metriche ROC-AUC e Precision-Recall - Test Set Esterno 73
7.3 Confronto con lo Stato dell'Arte: SCEMILA 74
7.3.1 Dettaglio del Confronto Critico 76
7.4 Valutazione dell'Affidabilità Predittiva e Incertezza 77
7.5 Discussione Critica 77
7.5.1 Analisi tra Partizionamento a $K = 3$ e $K = 5$ Fold Cross-Validation 78
7.5.2 Analisi Comparativa delle Curve di Apprendimento 83
7.5.3 Analisi delle Metriche ROC-AUC e Precision-Recall sul Test Set Esterno: Confronto $K = 3$ vs $K = 5$ 85
7.5.4 Conclusioni del Capitolo 88

8 Conclusioni e Sviluppi Futuri 89
8.1 Sintesi del Lavoro e Contributi Principali 89
8.2 Impatto Clinico e Traslazionale 90
8.3 Limiti dello Studio 91
8.4 Sviluppi Futuri 92
8.4.1 Ampliamento del Dataset e Reclutamento di Nuove Classi di Pazienti 92
8.4.2 Ottimizzazione del Modello e Affinamento degli Iperparametri . 93
8.4.3 Spiegabilità e Interpretabilità Clinica (XAI) 93

Bibliografia 95

–1–
Introduzione

Contents: **1.1 Contesto Clinico della Leucemia Mieloide Acuta.** 1.1.1 Descrizione dei Sottotipi Molecolari di AML. **1.2 Limiti della Citomorfologia Manuale Tradizionale. 1.3 L'Evoluzione dell'IA: Dalle Feature Handcrafted ai ViT. 1.4 Obiettivi della Tesi e Contributi Originali.** 1.4.1 Obiettivi Specifici – 1.4.2 Contributi Originali.

Nel presente capitolo vengono delineati i fondamenti clinici, metodologici e tecnologici che guidano la tesi. Viene introdotto il contesto della Leucemia Mieloide Acuta (AML) e la sua evoluzione diagnostica dai criteri morfologici a quelli molecolari, seguita da un'analisi dei limiti operativi e della soggettività della citomorfologia manuale tradizionale. Viene poi ripercorsa l'evoluzione dell'Intelligenza Artificiale applicata all'ematologia, documentando il passaggio dai descrittori geometrici classici (*handcrafted feature*) ai Vision Transformers basati sull'attenzione globale. Il capitolo si conclude definendo gli obiettivi dello studio e presentando i quattro contributi originali introdotti da questo lavoro di tesi.

1.1 Contesto Clinico della Leucemia Mieloide Acuta

La Leucemia Mieloide Acuta (AML, dall'inglese *Acute Myeloid Leukemia*) è un tumore del sangue molto aggressivo che colpisce soprattutto gli adulti e si sviluppa in tempi rapidi. Dal punto di vista biologico, la malattia nasce nel midollo osseo a causa di alcune mutazioni nel DNA delle cellule staminali o dei precursori dei globuli bianchi. Queste alterazioni genetiche causano due problemi principali : bloccano la normale maturazione delle cellule e, allo stesso tempo, le fanno moltiplicare senza controllo. Le cellule immature che si accumulano vengono chiamate blasti leucemici. Con il progredire della malattia, i blasti invadono il midollo osseo e passano nel sangue, ostacolando la produzione delle cellule sane. Questo meccanismo provoca sintomi gravi e immediati, come febbri e infezioni dovute alla mancanza di globuli bianchi efficaci, stanchezza severa legata all'anemia ed emorragie causate dalla carenza di piastrine [1, 2].

Storicamente, la classificazione diagnostica dell'AML si è basata sul sistema franco-americano-britannico (*FAB*), introdotto negli anni '70. Tale approccio suddivideva la patologia in otto sottoclassi distinte (da M0 a M7) basandosi su criteri puramente morfologici e citochimici analizzati al microscopio ottico. Sebbene lo schema FAB abbia rivestito un ruolo fondamentale nell'evoluzione dell'ematologia oncologica, l'avvento delle moderne tecniche di sequenziamento di nuova generazione del DNA (*Next-Generation Sequencing*, NGS) ne ha determinato il definitivo superamento. La letteratura scientifica recente ha infatti ampiamente dimostrato come l'AML non sia un'entità clinica distinta, bensì un insieme eterogeneo di disordini molecolari. Di conseguenza, la prognosi e la pianificazione di strategie terapeutiche mirate sono oggi governate dal profilo genetico profondo dei cloni leucemici, prescindendo dalle caratteristiche puramente morfologiche macroscopiche della cellula [3, 4].

Per questo motivo, le linee guida internazionali più recenti — come quelle dell'*International Consensus Classification (ICC)* e dell'*European LeukemiaNet (ELN)* — mettono al centro della diagnosi le caratteristiche molecolari e le anonimie genetiche dei cromosomi. Oggi, se si individua una specifica mutazione genetica, si può diagnosticare l'AML anche se la percentuale di blasti nel midollo è inferiore alla storica soglia numerica del 20%. In questo panorama, il lavoro di questa tesi si concentra sulla classificazione e sull'analisi morfologica di quattro importanti sottotipi genetici di AML, confrontati con un gruppo di cellule sane. In quanto, riconoscere con precisione le cellule sane è un passaggio decisivo per evitare che i sistemi software di screening generino falsi positivi, garantendo la massima affidabilità per l'uso in ambito clinico ed ospedaliero [5].

1.1.1 Descrizione dei Sottotipi Molecolari di AML

Vengono di seguito descritti i sottotipi molecolari presi in considerazione nello studio :

1. **Sottotipo CBFB-MYH11 :** Questo sottotipo biologico coincide storicamente con la variante FAB M4eo ed è causato da un'alterazione strutturale del cromosoma 16 (un'inversione o una traslocazione) [1]. Questo difetto unisce il gene *CBFB* con il gene $MYH11$, creando una proteina di fusione anomala. Tale proteina blocca l'attività del *Core-Binding Factor* (CBF), un complesso proteico essenziale per la normale maturazione dei globuli bianchi. Dal punto di vista clinico, i pazienti con questa mutazione hanno una prognosi favorevole: mostrano infatti ottimi tassi di guarigione e di guarigione completa se trattati con chemioterapia intensiva a base di citarabina ad alte dosi, come confermato dagli standard terapeutici correnti [4].

2. **Sottotipo con Mutazione di NPM1 :** È la mutazione genetica singola più comune nell'AML dell'adulto, presente in circa il 30% dei casi [1]. Il gene $NPM1$ produce una proteina che si sposta normalmente tra il nucleo e il citoplasma per mantenere stabile il DNA cellulare. Le mutazioni a carico di questo gene alterano la struttura della proteina, causandone un accumulo anomalo e tipico all'interno del citoplasma (fenotipo $NPM1$c+). Dal punto di vista clinico, questa forma ha una prognosi

favorevole, a patto che non sia presente anche una seconda mutazione ad alto rischio nel gene *FLT*3 (*FLT*3-ITD), in linea con i criteri di stratificazione correnti [4].

3. **Sottotipo PML-RARA :** Questa anomalia cromosomica causa la Leucemia Promielocitica Acuta (APL). La fusione unisce il gene PML (sul cromosoma 15) con il gene RARA (sul cromosoma 17), creando una proteina anomala che interrompe lo sviluppo delle cellule del sangue a metà percorso. Clinicamente è una grave emergenza: le cellule accumulano granuli che possono scatenare problemi di coagulazione e gravi emorragie fin dalle prime ore dall'esordio. Tuttavia, se diagnosticata tempestivamente, è la forma di AML con le più alte probabilità di guarigione grazie a trattamenti mirati (senza chemioterapia classica) capaci di distruggere la proteina mutata e far ripartire la normale maturazione delle cellule[1].

4. **Sottotipo RUNX1-RUNX1T1 :** Questo anomalia cromosomica unisce il gene *RUNX*1 (sul cromosoma 21) con il gene *RUNX*1*T*1 (sul cromosoma 8), creando una proteina di fusione che blocca l'attivazione dei geni necessari allo sviluppo delle cellule sane [1]. Si associa tipicamente alla variante morfologica FAB M2 ed è classificato tra i sottotipi a prognosi favorevole all'interno del gruppo CBF-AML. Tuttavia, la presenza di mutazioni secondarie nel gene *KIT* può peggiorare il quadro clinico, aumentando in modo significativo il rischio che la malattia si ripresenti secondo i correnti criteri di stratificazione [4].

Il presupposto metodologico alla base dell'applicazione di modelli di Deep Learning in questo contesto risiede nell'esistenza di un solido legame tra il genotipo (il difetto molecolare profondo) e il fenotipo (l'espressione visibile della cellula). Le mutazioni genetiche si riflettono direttamente sull'aspetto strutturale della cellula: la densità della cromatina, le introflessioni del nucleo, il volume del citoplasma e la presenza di granuli o inclusioni cristalline (come i corpi di Auer) sono la conseguenza geometrica visibile dell'alterazione molecolare. Pertanto, addestrare reti neurali a riconoscere in modo automatico queste complesse configurazioni visive offre un'opportunità diagnostica straordinaria per supportare lo screening clinico preliminare e avviare tempestivamente i trattamenti salvavita[5].

1.2 Limiti della Citomorfologia Manuale Tradizionale

Nonostante i rapidi progressi delle tecniche di biologia molecolare e dell'analisi cellulare a flusso multiparametrica, l'esame morfologico al microscopio ottico degli strisci di sangue periferico o di aspirato midollare costituisce tuttora l'indispensabile primo step diagnostico dinanzi al sospetto clinico di una leucemia acuta [1]. Tale procedura consente al clinico di formulare un orientamento preliminare immediato e di stimare la percentuale quantitativa di blasti, verificando il superamento della soglia del 20% richiesta dalle linee guida internazionali per la diagnosi formale di AML [4].

Tuttavia, l'approccio manuale tradizionale soffre di severi limiti operativi intrinseci, ampiamente descritti nella letteratura medica e computazionale, legati sia alla natura soggettiva della percezione visiva umana sia alla complessità delle preparazioni di laboratorio:

1. **Variabilità inter-operatore e intra-operatore :** La classificazione di parametri citologici microscopici e sfumati, quali la fine granularità del citoplasma o il grado di condensazione della cromatina, risente inevitabilmente dell'esperienza soggettiva dell'osservatore. Studi clinici recenti evidenziano tassi di discordanza significativi tra morfologi differenti che esaminano il medesimo campione (variabilità inter-operatore), con scostamenti che possono superare il 15% nella quantificazione dei blasti, in particolare nei casi diagnostici limite [1]. Analogamente, si riscontra una variabilità intra-operatore laddove lo stesso specialista fornisca valutazioni non perfettamente riproducibili sul medesimo vetrino a distanza di tempo.

2. **Impatto dell'affaticamento cognitivo :** L'analisi microscopica manuale impone un carico cognitivo e un livello di attenzione prolungato. Nel corso di routine di laboratorio ad alta densità di campioni, l'affaticamento visivo riduce l'accuratezza nel rilevare anomalie rare o inclusioni citoplasmatiche sub-microscopiche (come i corpi di Auer), incrementando il rischio latente di falsi positivi, falsi negativi o di sotto-classificazioni diagnostiche.

3. **Eterogeneità e mancanza di standardizzazione tecnica :** L'aspetto cromatico e strutturale delle cellule è fortemente influenzato da variabili pre-analitiche, quali l'efficacia della colorazione, lo spessore dell'estensione dello striscio e la taratura ottica del microscopio. Sebbene l'apparato visivo umano sia in grado di compensare parzialmente tali variazioni a livello qualitativo, risulta impossibile definire metriche numeriche universali e oggettive che siano direttamente riproducibili tra laboratori differenti.

A fronte di tali limiti legati alla logistica ospedaliera e dei flussi di lavoro clinici, l'analisi manuale al microscopio si configura come un processo lento, costoso e non scalabile. In oltre, in scenari clinici critici d'urgenza, l'attesa dei risultati dei test genetici e di citogenetica tradizionali (come la FISH o la RT-PCR) può estendersi da diverse ore a molti giorni. Pertano, l'introduzione di sistemi intelligenti e automatizzati per standardizzare e velocizzare lo screening morfologico preliminare risponde a una stringente necessità clinica [5]. L'ottimizzazione computazionale di questa fase consente infatti di abbattere i tempi di latenza terapeutica, ottimizzando la gestione dei flussi di laboratorio e accelerando l'impostazione di protocolli salvavita mirati.

1.3 L'Evoluzione dell'IA: Dalle Feature Handcrafted ai ViT

L'introduzione della patologia digitale e lo sviluppo su vasta scala degli scanner *Whole Slide Imaging* (WSI) hanno consentito la digitalizzazione sistematica dei campioni

biologici, traducendoli in pool di immagini ad altissima risoluzione spaziale. Questa transizione tecnologica ha reso possibile l'applicazione metodica della Computer Vision all'ematologia oncologica, tracciando un percorso evolutivo che ha attraversato distinte ere metodologiche contrassegnate da un profondo cambio di paradigma computazionale [6, 7].

La prima fase, sviluppatasi a partire dagli anni '90, si rifaceva ai paradigmi del Machine Learning classico e all'estrazione manuale delle caratteristiche, un approccio noto in letteratura come *Handcrafted Feature Extraction* o morfometria computazionale [8]. Questo workflow standardizzato prevedeva una pipeline rigida articolata in tre macro-fasi sequenziali:

1. **Segmentazione dei contorni:** Separazione precisa della cellula e del nucleo dallo sfondo dello striscio di sangue, ottenuta tramite algoritmi di rilevamento dei bordi (come i filtri di Sobel o Canny) o modelli di contorno attivo [9].

2. **Estrazione dei descrittori:** Calcolo matematico delle caratteristiche geometriche della cellula (area, perimetro, forma) e della tessitura nucleare tramite matrici di co-occorrenza (GLCM) [10], utili a valutare la struttura della cromatina.

3. **Classificazione:** Inserimento dei dati estratti all'interno di algoritmi di Machine Learning tradizionali, come Support Vector Machines (SVM) o Random Forest, per ottenere la diagnosi [8].

Sebbene questi sistemi garantissero una chiara interpretabilità (essendo basati su formule geometriche note), essi mostravano una spiccata fragilità e una scarsa capacità di generalizzazione: minime variazioni nella luce o la presenza di artefatti sul vetrino causavano un drastico crollo dell'accuratezza predittiva del modello al di fuori del dataset di sviluppo originario.

La reale svolta metodologica si è compiuta con l'affermazione del Deep Learning e l'avvento delle Reti Neurali Convoluzionali (CNN). Le CNN hanno introdotto il concetto di apprendimento delle rappresentazioni (*Representation Learning*), all'interno del quale l'architettura apprende autonomamente a estrarre una gerarchia di feature direttamente dai pixel grezzi durante l'addestramento. Gli strati iniziali codificano primitive geometriche locali (bordi, angoli), mentre i livelli profondi combinano tali informazioni per sintetizzare pattern morfologici complessi ad alto livello di astrazione. Architetture consolidate quali ResNet o EfficientNet hanno dimostrato in molteplici studi la capacità di eguagliare o superare l'accuratezza dei morfologi esperti nella classificazione delle sottopopolazioni cellulari del sangue [6].

Tuttavia, le CNN convenzionali presentano un limite strutturale intrinseco legato alla natura locale dell'operazione di convoluzione, il cui campo ricettivo è strettamente confinato dalle dimensioni del *kernel* (tipicamente 3×3 o 5×5 pixel). Per catturare dipendenze globali e relazioni contestuali a lungo raggio, le CNN necessitano dell'accumulazione di

numerosi layer convoluzionali e di riduzione spaziale (*pooling*), rischiando di attenuare o smarrire le feature geometriche ad alta frequenza spaziale più fini.

Per superare tale vincolo, la ricerca contemporanea ha introdotto con successo i *Vision Transformers (ViT)*, mutuando i meccanismi di attenzione dal processamento del linguaggio naturale [11]. Nei ViT, l'immagine citologica viene suddivisa in una sequenza ordinata di tasselli spaziali disgiunti (*patch*), proiettati linearmente in vettori di embedding ed elaborati da blocchi di *Self-Attention*. Questo meccanismo consente a ciascuna patch dell'immagine di interagire e computare la propria relazione con ogni altra patch simultaneamente, indipendentemente dalla loro distanza spaziale all'interno del fotogramma.

Nell'ambito della citopatologia, i Vision Transformers offrono il vantaggio computazionale critico di saper modellare simultaneamente sia i dettagli ultrastrutturali confinati localmente (come la granularità fine o la presenza di piccoli corpi di Auer) sia il contesto topologico globale dell'intera cellula (come il rapporto nucleo-citoplasma) [12]. L'integrazione dei ViT e dei modelli da essi derivati rappresenta oggi lo stato dell'arte per decodificare fenotipi complessi e sottotipi molecolari ad altissima precisione direttamente dall'analisi morfologica digitale [13].

1.4 Obiettivi della Tesi e Contributi Originali

Il presente lavoro di tesi si colloca nel'intersezione tra l'Intelligenza Artificiale applicata alla medicina e la biologia computazionale. L'obiettivo principale consiste nello sviluppo e nella validazione di un framework di Deep Learning, progettato per identificare in modo accurato e trasparente quattro sottotipi genetici di Leucemia Mieloide Acuta (AML) e i relativi controlli sani.

L'obiettivo primario risiede nel superamento dei limiti strutturali manifestati dai tradizionali modelli di classificazione guidati esclusivamente da singole immagini di cellule ematiche. In particolare, l'architettura proposta affronta la complessa variabilità interpaziente e l'elevata sovrapposizione morfologica tra distinti sottotipi citogenetici (quali *CBFB_MYH11* e *RUNX1_RUNX1T1*) attraverso una rappresentazione arricchita a doppio flusso e un'aggregazione ponderata delle predizioni a livello di paziente.

1.4.1 Obiettivi Specifici

Per raggiungere l'obiettivo primario prefissato, la metodologia sviluppata articola il processo di ricerca e modellazione attraverso i seguenti traguardi specifici:

- **Protocollo di Validazione e Prevenzione del Data Leakage**: Definizione di uno schema di valutazione rigoroso basato su K-Fold Cross-Validation vincolato agli identificativi univoci dei pazienti. Tale approccio garantisce la rigorosa segregazione dei pazienti tra i set di addestramento e validazione, prevenendo il *data leakage* e

garantendo la reale generalizzabilità clinica del modello sia su dati out-of-fold che su un Test Set esterno indipendente.

- **Caratterizzazione Cellulare tramite Architettura Dual-Stream**: Progettazione di un modulo di estrazione delle caratteristiche basato sull'architettura *Vision Transformer* specialistica DinoBloom-S pre-addestrata. La rete elabora in parallelo l'immagine nativa del campo cellulare e la relativa maschera di segmentazione (*Original* e *Segmented*), consentendo di preservare simultaneamente le peculiarità cromatico-strutturali intracellulari (nucleo e citoplasma) e le proprietà geometrico-perimetrali della singola cellula.

- **Fusione di Feature tramite Gated Cross-Attention Bidirezionale**: Implementazione di blocchi di trasformazione basati su meccanismi di *Cross-Attention* dotati di porte logiche (*Gating*) e *DropPath*. Questo modulo consente ai due flussi di informazione (immagine nativa e maschera) di interagire reciprocamente, arricchendo contestualmente i descrittori spaziali prima della fase di pooling.

- **Aggregazione Spaziale e Decisionale a Livello di Paziente**: Sviluppo di un modulo di *Mean Pooling* per estrarre una rappresentazione vettoriale globale (384 dimensioni) da ciascun campione cellulare, integrato da un algoritmo di aggregazione a livello di paziente basato sulla media dei *logits* pesata per la confidenza di predizione.

- **Classificazione a 5 Classi con Calibrazione Adattiva**: Progettazione di un classificatore *end-to-end* addestrato tramite strategie di bilanciamento delle classi e ottimizzato mediante soglie decisionali adattive specifiche per ciascun sottotipo, al fine di ridurre la quota di falsi positivi e garantire un'elevata sensibilità sulle classi patologiche.

1.4.2 Contributi Originali

I principali elementi di novità metodologica e gli apporti scientifici originali introdotti da questo lavoro di tesi si sintetizzano nei seguenti punti:

1. **Estrattore Dual-Stream basato su DinoBloom-S Congelato**: L'integrazione del *backbone* specialistico DinoBloom-S (ridotto a 6 blocchi di attenzione e interamente congelato per garantire stabilità ed efficienza computazionale) all'interno di una doppia linea di elaborazione parallela con meccanismo di *Gated Cross-Attention* per la fusione inter-modale.

2. **Campionamento Bilanciato e Aggregazione Ponderata basata su Confidenza**: Introduzione di uno schema di campionamento stratificato per paziente con limite massimo di immagini per soggetto, abbinato al *Mean Pooling* spaziale dei token e a un'aggregazione dei *logits patient-level* guidata dalla confidenza delle predizioni, garantendo una diagnosi robusta rispetto all'eterogeneità del campione ematico.

3. **Regolarizzazione e Loss Pesata con Augmentation Selettiva**: Definizione di un regime di addestramento basato su *Cross-Entropy Loss* con pesi asimmetrici per classe e *Label Smoothing* (0.30), affiancato da una tecnica di *Random Erasing* applicata in modo mirato sulle maschere di segmentazione per addestrare il modello a gestire la presenza di rumore o artefatti visivi.

4. **Ottimizzazione della Decisione Clinica tramite Soglie Adattive**: Introduzione di una fase di post-elaborazione e calibrazione delle probabilità del paziente mediante soglie decisionali calibrate sulle specifiche criticità diagnostiche di ciascun sottotipo (es. *CBFB_MYH11* e *RUNX1_RUNX1T1*), minimizzando l'incidenza dei falsi positivi e negativi nell'output finale.

–2–
Stato dell'Arte e Fondamenti Teorici

Contents: **2.1 Fondamenti di Apprendimento Profondo e Valutazione delle Prestazioni.** 2.1.1 Reti Neurali Artificiali e Modelli di Apprendimento – 2.1.2 Processo di Addestramento e Retropropagazione – 2.1.3 Strategie di Partizionamento del Dataset e Validazione – 2.1.4 Metriche di Valutazione delle Prestazioni. **2.2 Vision Transformers in Medicina.** 2.2.1 Architettura e Elaborazione dell'Immagine – 2.2.2 Il Meccanismo di Self-Attention Scaled Dot-Product – 2.2.3 Vantaggi Rispetto alle CNN nell'Analisi del Contesto Globale. **2.3 Fusione Multimodale e Meccanismi di Cross Attention.** 2.3.1 Stato dell'Arte sulle Strategie di Fusione – 2.3.2 Modellazione Computazionale della Cross-Attention. **2.4 Architetture Dual-Stream RGB-Segmentation nei Vision Transformers.** 2.4.1 Formalizzazione del Disaccoppiamento Bi-Ramo – 2.4.2 Interazione Cross-Modale Intermedia – 2.4.3 Proiezione e Fusione nello Spazio Latente – 2.4.4 Vantaggi e Svantaggi del Paradigma Dual-Stream.

Nel presente capitolo vengono esaminati i fondamenti teorici e lo stato dell'arte alla base del framework computazionale proposto. La prima sezione introduce i concetti generali relativi alle reti neurali artificiali, al processo di addestramento mediante retropropagazione dell'errore, alla suddivisione del dataset e al rigore delle metriche di valutazione e stabilità dei modelli. La seconda sezione approfondisce l'architettura dei Vision Transformers (ViT) e i meccanismi di *Self-Attention* per la modellazione del contesto spaziale globale nelle immagini citologiche. Successivamente, la terza sezione descrive la fusione multimodale, illustrando l'interazione geometrico-semantica tra l'immagine nativa e la maschera di segmentazione mediante moduli di *Cross-Attention* bidirezionale. Il capitolo si conclude con l'analisi delle architetture *Dual-Stream*, evidenziando i vantaggi del processamento parallelo di flussi informativi complementari.

2.1 Fondamenti di Apprendimento Profondo e Valutazione delle Prestazioni

L'apprendimento automatico (*Machine Learning*) e, in particolare, l'apprendimento profondo (*Deep Learning*) costituiscono il paradigma teorico essenziale per la costruzione

di sistemi di ausilio alla diagnosi biomedica. Nel contesto della classificazione citomorfologica, l'obiettivo fondamentale risiede nella costruzione di un modello matematico in grado di approssimare una funzione incognita $f^* : \mathcal{X} \to \mathcal{Y}$, mappando uno spazio campionario ad alta dimensione $\mathcal{X}$ (es. immagini di cellule leucemiche) in un insieme discreto di categorie diagnostiche $\mathcal{Y}$.

2.1.1 Reti Neurali Artificiali e Modelli di Apprendimento

Una Rete Neurale Artificiale (*Artificial Neural Network*, ANN) è composta da unità computazionali elementari (neuroni artificiali) organizzate in strati sequenziali. Ciascun neurone riceve un vettore di input $\mathbf{x} \in \mathbb{R}^d$, ne calcola una combinazione lineare pesata mediante un vettore di pesi $\mathbf{w} \in \mathbb{R}^d$ e un termine di bias $b \in \mathbb{R}$, e applica una funzione di attivazione non lineare $\sigma(\cdot)$:

$$y = \sigma\left(\mathbf{w}^T\mathbf{x} + b\right) \tag{2.1}$$

L'introduzione delle funzioni di attivazione non lineari (quali *ReLU*, *GELU* o *Softmax*) garantisce alla rete la proprietà di approssimatore universale, consentendole di apprendere frontiere di decisione complesse e non lineari.

Nel caso di problemi di classificazione multi-classe con C categorie disgiunte, lo strato finale della rete emette un vettore di logit $\mathbf{z} \in \mathbb{R}^C$. Tale vettore viene convertito in una distribuzione di probabilità categorica mediante la funzione *Softmax*:

$$P(Y = c \mid \mathbf{x}) = \frac{e^{z_c}}{\sum_{j=1}^{C} e^{z_j}} \quad \text{per } c = 1, \ldots, C \tag{2.2}$$

2.1.2 Processo di Addestramento e Retropropagazione

L'addestramento della rete consiste nel risolvere un problema di ottimizzazione per identificare l'insieme dei parametri $\boldsymbol{\Theta} = \{\mathbf{W}, \mathbf{b}\}$ che minimizza la discrepanza tra le predizioni del modello e le etichette reali (*ground truth*). Tale discrepanza è formalizzata attraverso una funzione di perdita (*Loss Function*).

Per compiti di classificazione multi-classe, la funzione di perdita standard è la *Categorical Cross-Entropy* ($\mathcal{L}_{CE}$):

$$\mathcal{L}_{CE} = -\sum_{i=1}^{C} y_i \log(\hat{y}_i) \tag{2.3}$$

dove $y_i \in \{0, 1\}$ è l'indicatore binario dell'etichetta reale per la classe i, e $\hat{y}_i = P(Y = i \mid \mathbf{x})$ è la probabilità predetta.

L'aggiornamento dei parametri avviene iterativamente mediante algoritmi di discesa del gradiente (*Stochastic Gradient Descent* o varianti adattive come *AdamW*). I gradienti della funzione di perdita rispetto a tutti i parametri della rete vengono calcolati in modo efficiente sfruttando l'algoritmo di *Backpropagation* (retropropagazione dell'errore), basato sulla regola di derivazione delle funzioni composte (*chain rule*).

2.1.3 Strategie di Partizionamento del Dataset e Validazione

Per garantire che il modello apprenda pattern biologici generalizzabili ed evitare il fenomeno del sovraadattamento (*overfitting*) — in cui la rete memorizza il rumore specifico dei dati di training a scapito della capacità di generalizzazione —, il dataset complessivo viene suddiviso in tre sottoinsiemi disgiunti:

- **Training Set:** Utilizzato dall'algoritmo di ottimizzazione per calcolare i gradienti e aggiornare direttamente i pesi della rete.
- **Validation Set:** Impiegato durante la fase di addestramento per valutare periodicamente le prestazioni su dati non visti per l'aggiornamento dei pesi. Serve per la sintonizzazione degli iperparametri, per l'applicazione di strategie di arresto precoce (*Early Stopping*) e per prevenire l'overfitting.
- **Test Set Esterno:** Un insieme di dati completamente indipendente e "cieco", riservato esclusivamente alla valutazione finale delle prestazioni generali del modello ottimizzato.

Nelle applicazioni mediche caratterizzate da classi campionarie limitate o sbilanciate, la semplice suddivisione in un singolo split può introdurre bias di selezione. Per ovviare a ciò, si adotta la strategia della *K-Fold Cross-Validation*. Il dataset viene partizionato in K sottoinsiemi (fold) di uguali dimensioni; a rotazione, $K-1$ fold vengono usati per l'addestramento e il rimanente fold funge da validazione. L'aggregazione delle predizioni di validazione generata da tutti i K cicli costituisce la valutazione *Global Out-Of-Fold* (OOF).

2.1.4 Metriche di Valutazione delle Prestazioni

La bontà e l'affidabilità clinica di un modello di classificazione non possono essere misurate unicamente mediante l'accuratezza globale, specialmente in presenza di classi clinicamente sbilanciate. Vengono pertanto impiegate diverse metriche derivate dalla matrice di confusione, costituita da Falsi Positivi (FP), Falsi Negativi (FN), Veri Positivi (VP) e Veri Negativi (VN).

- **Accuracy (Accurabilità):** Rapporto tra le predizioni corrette e il totale dei campioni esaminati N:

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN} \tag{2.4}$$

- **Precision (Valore Predittivo Positivo):** Proporzione di casi positivi correttamente identificati rispetto a tutti quelli predetti come positivi dal modello:

$$\text{Precision} = \frac{VP}{VP + FP} \tag{2.5}$$

- **Recall / Sensibilità (Richiamo):** Proporzione di casi positivi reali che il modello è stato in grado di rilevare. In ambito clinico-diagnostico, questa metrica misura la capacità di contenere i falsi negativi (mancata diagnosi di malattia):

$$\text{Recall} = \frac{VP}{VP + FN} \tag{2.6}$$

- **F1-Score:** Media armonica tra Precision e Recall, utile per sintetizzare il bilanciamento tra specificità e sensibilità in un singolo valore:

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{2.7}$$

- **Metriche basate su Soglia Probabilistica (ROC-AUC e PR-AUC):**
  - **ROC-AUC (Area Under the Receiver Operating Characteristic Curve):** Valuta la capacità del modello di ordinare correttamente le probabilità assegnate, tracciando la Sensibilità in funzione del Tasso di Falsi Positivi (1−Specificità) al variare della soglia decisionale.
  - **PR-AUC / Average Precision (AP):** Calcola l'area sottesa alla curva Precision-Recall. Risulta particolarmente informativa in presenza di forte sbilanciamento delle classi, misurando la tenuta della precisione a livelli di richiamo elevati.

2.2 Vision Transformers in Medicina

L'analisi computazionale di immagini citologiche in ematologia ha storicamente trovato nelle reti neurali convoluzionali (CNN) il proprio gold standard tecnologico. Le CNN, basandosi sui principi di invarianza per traslazione e località spaziale indotti dalle operazioni di convoluzione con filtri a recettore limitato, eccellono nella cattura di feature a bassa frequenza spaziale, quali texture citoplasmatiche, contrasti di membrana e granularità locali. Tuttavia, la diagnosi differenziale della Leucemia Mieloide Acuta (AML) basata sulla morfologia cellulare impone la valutazione di correlazioni spaziali a lungo raggio che superano i confini del recettore di una convoluzione standard. Parametri clinici determinanti, quali il rapporto nucleo-citoplasma, la distribuzione asimmetrica della cromatina e la disposizione spaziale dei corpi di Auer rispetto alla geometria della membrana, richiedono una modellazione globale dell'intera topologia cellulare[14, 15].

Per superare l'induttivo bias locale delle CNN, l'introduzione dei Vision Transformers (ViT), introdotto nel 2020 da un ricercatore di Google nel articolo "An Image is worth

16x16 words" [**gdosovitskiy2021**] ha rivoluzionato il paradigma della computer vision biomedica, estendendo l'architettura dei Transformer dall'elaborazione del linguaggio naturale alla classificazione di immagini senza l'ausilio di operazioni convoluzionali dense [16, 17].

2.2.1 Architettura e Elaborazione dell'Immagine

Il principio cardine del Vision Transformer risiede nella scomposizione di un'immagine bidimensionale, come mostrato nella Figura 2.1, $X \in \mathbb{R}^{H \times W \times C}$ (dove H, W rappresentano le dimensioni spaziali e C il numero di canali, tipicamente $C = 3$ per immagini in spazio colore RGB) in una sequenza ordinata di patch bidimensionali appiattite $X_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$. In questo contesto, (P, P) rappresenta la risoluzione spaziale di ciascuna patch e

$$N = \frac{HW}{P^2} \tag{2.8}$$

corrisponde al numero totale di patch generate, ovvero alla lunghezza effettiva della sequenza che verrà iniettata nel modello.

Poiché l'architettura interna del Transformer opera su vettori a dimensione fissa D (denotata come dimensione latente o *embedding dimension*), ciascuna patch appiattita viene proiettata linearmente in uno spazio D-dimensionale tramite una matrice di proiezione apprendibile $E \in \mathbb{R}^{(P^2 \cdot C) \times D}$. Al fine di preservare l'informazione geometrico-spaziale nativa dell'immagine — intrinsecamente persa durante l'appiattimento delle patch — alla sequenza di patch proiettate viene sommato un embedding di posizione apprendibile $E_{pos} \in \mathbb{R}^{(N+1) \times D}$ [11, 17].

Similmente a quanto avviene nei modelli di linguaggio naturali, viene introdotto un token speciale apprendibile denominato *Classification Token* ($\mathbf{x}_{class}$), posizionato all'inizio della sequenza ($N + 1$). Lo stato latente associato a questo token all'uscita dell'ultimo blocco del Transformer fungerà da rappresentazione globale aggregata dell'immagine, sulla quale opererà il classificatore lineare finale (*MLP Head*). La sequenza di input iniziale $\mathbf{z}_0$ viene formata come segue:

$$\mathbf{z}_0 = [\mathbf{x}_{class}; X_p^1 E; X_p^2 E; \ldots; X_p^N E] + E_{pos} \tag{2.9}$$

2.2.2 Il Meccanismo di Self-Attention Scaled Dot-Product

Il motore computazionale del blocco Transformer è rappresentato dall'architettura di *Multi-Head Self-Attention* (MSA). Il meccanismo di attenzione consente a ciascun token (patch) di interagire dinamicamente con tutti gli altri token della sequenza, calcolando una mappa di attivazione basata sulla mutua rilevanza. Per una singola testa di attenzione, la sequenza di input $\mathbf{z} \in \mathbb{R}^{(N+1) \times D}$ viene proiettata linearmente in tre matrici distinte:

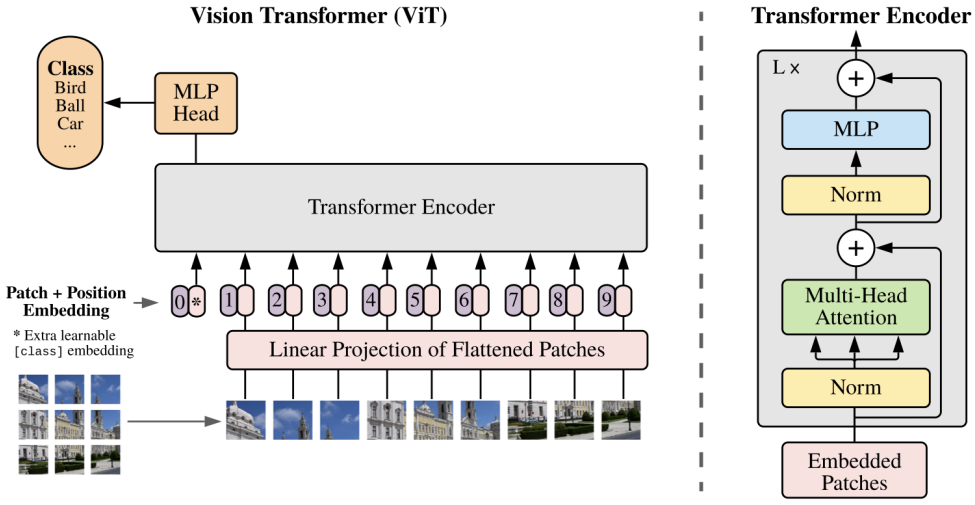


Figura 2.1: Panoramica del modello Vision Transformer (ViT). L'immagine viene suddivisa in patch di dimensione fissa, ciascuna delle quali viene proiettata tramite un embedding lineare; vengono quindi sommati gli embedding di posizione e la sequenza di vettori risultante viene data in input a un encoder Transformer standard. Per l'esecuzione del task di classificazione, viene adottato l'approccio standard che prevede l'aggiunta di un token di classificazione (*classification token*) apprendibile extra alla sequenza. L'illustrazione dell'encoder Transformer è ispirata al lavoro di Vaswani et al. [18]. Figura e didascalia riadattate da Dosovitskiy et al. [11].

Query (Q), Key (K) e Value (V), mediante l'utilizzo di tre matrici di pesi apprendibili $W_Q, W_K, W_V \in \mathbb{R}^{D \times d_k}$, dove $d_k = D/h$ (con h pari al numero di teste di attenzione):

$$Q = \mathbf{z}W_Q, \quad K = \mathbf{z}W_K, \quad V = \mathbf{z}W_V \tag{2.10}$$

Il calcolo della matrice di attenzione (*Scaled Dot-Product Attention*) avviene proiettando il prodotto scalare tra le Query e le Key, scalato rispetto alla radice quadrata della dimensione d_k per prevenire la saturazione del gradiente nelle regioni a derivata nulla della funzione Softmax:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.11}$$

La funzione Softmax viene applicata riga per riga, generando una matrice di transizione stocastica in cui l'elemento (i, j) esprime il peso (o focus attentivo) che il token i-esimo assegna al token j-esimo. Nell'estensione multi-testa (MSA), l'operazione viene eseguita in parallelo da h teste indipendenti [18]. I rispettivi output vengono concatenati e proiettati nuovamente tramite una matrice $W_O \in \mathbb{R}^{D \times D}$:

$$\text{MSA}(\mathbf{z}) = \text{Concat}(\text{head}_1, \ldots, \text{head}_h)W_O \tag{2.12}$$

$$\text{dove} \quad \text{head}_i = \text{Attention}(\mathbf{z}W_Q^i, \mathbf{z}W_K^i, \mathbf{z}W_V^i) \tag{2.13}$$

Ogni blocco del Transformer include, oltre al modulo MSA, una rete Feed-Forward (MLP) composta da due strati lineari con attivazione GELU, connessioni residue di tipo skip e moduli di *Layer Normalization* (LN) applicati prima dei blocchi di calcolo (*Pre-LN*):

$$\mathbf{z}'_l = \text{MSA}(\text{LN}(\mathbf{z}_{l-1})) + \mathbf{z}_{l-1} \tag{2.14}$$

$$\mathbf{z}_l = \text{MLP}(\text{LN}(\mathbf{z}'_l)) + \mathbf{z}'_l \tag{2.15}$$

2.2.3 Vantaggi Rispetto alle CNN nell'Analisi del Contesto Globale

Mentre le CNN possiedono un campo di ricezione che cresce solo linearmente o logaritmicamente con la profondità della rete attraverso la stratificazione di convoluzioni e pooling, i ViT esibiscono un campo di ricezione globale sin dal primissimo blocco di attenzione. Questo consente al modello di correlare istantaneamente pixel situati ai poli opposti della cellula leucemica, catturando relazioni spaziali complesse come le introflessioni della membrana nucleare rispetto alla distribuzione della cromatina [16, 15].

L'assenza di bias induttivi rigidi permette ai ViT, se addestrati su dataset di ampie dimensioni o regolarizzati opportunamente, di superare i limiti di saturazione delle performance tipici delle CNN. I vantaggi architetturali dei Vision Transformers (ViT) nell'ambito dell'ematopatologia computazionale applicata alla diagnosi differenziale della Leucemia Mieloide Acuta (AML) possono essere riassunti nei seguenti punti chiave:

- **Modellazione delle correlazioni spaziali a lungo raggio:** Le CNN elaborano l'immagine attraverso filtri locali, richiedendo il passaggio in strati molto profondi prima che due pixel distanti (es. i poli opposti della membrana cellulare o la distanza tra un corpo di Auer citoplasmatico e l'asse nucleare) possano interagire. Il meccanismo di *Self-Attention* dei ViT calcola invece la mutua rilevanza tra tutte le patch in un singolo step computazionale, catturando l'architettura globale del blasto leucemico ed evitando i limiti dei filtri convoluzionali localizzati [19].
- **Assenza di bias induttivi di località e invarianza:** Le CNN assumono intrinsecamente che le feature rilevanti siano locali e invarianti per traslazione. Sebbene questo sia vantaggioso in scenari di scarsità di dati, limita la capacità della rete di apprendere configurazioni geometriche arbitrarie o asimmetrie morfologiche complesse — come la distribuzione eterogenea della cromatina immatura — che i ViT riescono a mappare in modo dinamico e flessibile senza vincoli strutturali rigidi [15, 19].

- **Robustezza ad artefatti di colorazione inter-laboratorio:** Grazie alla capacità di estrarre rappresentazioni latenti basate sulla struttura geometrica globale e sulle relazioni reciproche delle componenti cellulari piuttosto che su pattern puramente pixel-level, i ViT dimostrano una tolleranza superiore alle variazioni cromatiche indotte dalle diverse tecniche di colorazione anche senza ricorrere a complessi algoritmi di normalizzazione delle tinte (*stain normalization*) [20].
- **Integrazione multimodale e interpretabilità nativa:** Le mappe di attenzione generate dai ViT consentono non solo di tracciare in modo trasparente le regioni subcellulari determinanti per il verdetto clinico, ma offrono un'interfaccia matematica ideale per la fusione di informazioni strutturali e cliniche eterogenee, superando la natura intrinsecamente "black-box" dei modelli convoluzionali densi [21, 20].
- **Maggiore scalabilità e saturazione delle performance:** A differenza delle CNN classiche, le cui prestazioni tendono a saturare anche all'aumentare dei dati di addestramento a causa dei limiti di capacità dei filtri, i ViT esibiscono proprietà di scalabilità quasi lineari. Beneficiano enormemente di strategie di pre-addestramento su larga scala o di dataset estesi, generando uno spazio latente più robusto e clinicamente discriminante per i sottotipi biologici più complessi [16, 22].

2.3 Fusione Multimodale e Meccanismi di Cross Attention

Nel dominio dell'oncologia computazionale e della morfologia cellulare, l'integrazione di flussi informativi eterogenei rappresenta una strategia consolidata per incrementare la robustezza dei sistemi di ausilio alla diagnosi. Nel contesto specifico di questa tesi, la multimodalità non si esprime attraverso sorgenti di dati dissimili (es. genomica e imaging), bensì mediante la scomposizione della medesima sorgente citologica in rappresentazioni geometriche e semantiche distinte: il canale globale dell'immagine originale e il canale morfometrico della maschera nucleare [14, 23].

2.3.1 Stato dell'Arte sulle Strategie di Fusione

La letteratura scientifica classifica le strategie di fusione delle feature in tre macrocategorie:

1. *Early Fusion* (Fusione precoce): I vettori di input vengono concatenati o sommati a livello di pixel o di patch prima dell'estrazione delle feature. In presenza di maschere binarie, ciò si traduce spesso nel concatenare la maschera come canale aggiuntivo ($RGB + M$). Tale approccio soffre di una forte rigidità, impedendo alla rete di apprendere feature estratte in modo indipendente dai singoli domini strutturali.

2. *Late Fusion* (Fusione tardiva): I flussi informativi vengono elaborati da network indipendenti e i rispettivi logit o vettori di classificazione finali vengono mediati o concatenati prima della Softmax. Questo paradigma preserva l'indipendenza estrattiva ma impedisce l'interazione tra le feature intermedie, precludendo la possibilità di correlare la tessitura globale con la geometria locale del nucleo durante le fasi di apprendimento profonde.

3. *Intermediate Fusion* (Fusione intermedia): Rappresenta lo stato dell'arte e viene implementata in questo lavoro. I flussi informativi interagiscono a livelli intermedi dell'architettura profonda, permettendo uno scambio continuo e dinamico di informazioni spaziali e strutturali [16, 23].

2.3.2 Modellazione Computazionale della Cross-Attention

Il meccanismo matematico preposto alla fusione intermedia in questo framework è la *Cross-Attention* bidirezionale. A differenza della Self-Attention, in cui Query, Key e Value derivano dalla medesima sequenza di input, la Cross-Attention mappa le relazioni tra due sequenze latenti distinte: la sequenza globale $\mathbf{z}_{glob}$ (estratta dal flusso dell'immagine intera) e la sequenza strutturale $\mathbf{z}_{strut}$ (derivante dalla maschera nucleare segmentata).

Formalmente, si definiscono due moduli di attenzione incrociata simmetrici, il cui schema logico e di flusso è illustrato nella Figura 2.2 [24]. Nel primo modulo, la sequenza globale assume il ruolo di Query, mentre la sequenza strutturale fornisce Key e Value:

$$Q_{glob} = \mathbf{z}_{glob} W_{Q_g}, \quad K_{strut} = \mathbf{z}_{strut} W_{K_s}, \quad V_{strut} = \mathbf{z}_{strut} W_{V_s} \tag{2.16}$$

$$\text{CrossAttn}_{g \to s} = \text{Softmax}\left(\frac{Q_{glob} K_{strut}^T}{\sqrt{d_k}} \right) V_{strut} \tag{2.17}$$

Specularmente, il secondo modulo scambia i ruoli per consentire al flusso strutturale di arricchirsi del contesto semantico globale dell'immagine:

$$Q_{strut} = \mathbf{z}_{strut} W_{Q_s}, \quad K_{glob} = \mathbf{z}_{glob} W_{K_g}, \quad V_{glob} = \mathbf{z}_{glob} W_{V_g} \tag{2.18}$$

$$\text{CrossAttn}_{s \to g} = \text{Softmax}\left(\frac{Q_{strut} K_{glob}^T}{\sqrt{d_k}} \right) V_{glob} \tag{2.19}$$

Questa interazione biunivoca consente alle patch dell'immagine originale di focalizzarsi selettivamente sulle deformazioni e sulle incisure del bordo nucleare, e simultaneamente permette alla maschera geometrica di acquisire informazioni sulla densità cromatinica interna, ottimizzando la separazione latente delle classi ematologiche [16, 23].

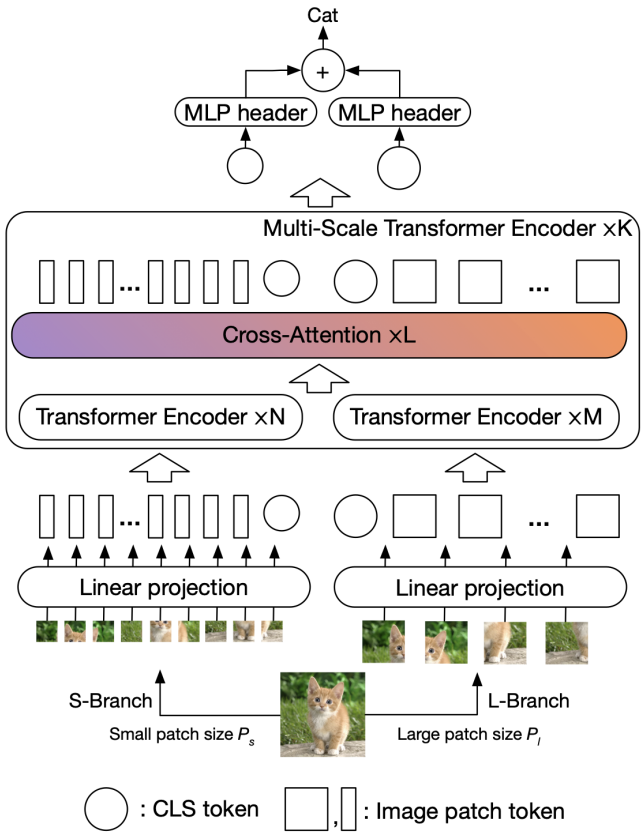


Figura 2.2: Meccanismo di fusione intermedia tramite Cross-Attention bidirezionale tra il flusso dell'immagine originale (*Global Stream*) e il flusso della maschera del nucleo (*Structural Stream*). Schema logico dei blocchi di interazione adattato dall'architettura CrossViT di Chen et al. [24].

2.4 Architetture Dual-Stream RGB-Segmentation nei Vision Transformers

L'analisi morfologica e citogenetica avanzata di immagini ematologiche pone sfide complesse legate alla compresenza di segnali eterogenei: da un lato la tessitura e il contrasto cromatico citoplasmatico, dall'altro la geometria e la topologia dell'involucro nucleare. Nelle architetture tradizionali a singolo flusso (*Single-Stream*), il tentativo di elaborare un'unica matrice di input concatenata o pesata porta inevitabilmente a un fenomeno di competizione rappresentazionale [17]. I gradienti generati dai pattern cromatici citoplasmatici ad alta frequenza tendono a dominare l'aggiornamento dei pesi, oscurando le componenti geometriche e le deformazioni microscopiche dell'involucro nucleare [19].

Per superare tale limite, la letteratura recente ha consolidato il paradigma delle architetture **Dual-Stream RGB-Segmentation** (o *Dual-Branch Appearance-Geometry Transformers*)

[25, 26]. Tale approccio disaccoppia il processo di feature extraction guidando l'apprendimento lungo due rami trasformativi paralleli e altamente specializzati: il primo dedicato al dominio cromatico-tessiturale (X_{orig}) e il secondo focalizzato sulla componente morfologico-strutturale pura (X_{seg}) [14, 27].

2.4.1 Formalizzazione del Disaccoppiamento Bi-Ramo

L'architettura riceve in ingresso una coppia di dati spazialmente allineati derivati dalla medesima acquisizione citologica. Il disaccoppiamento elaborativo avviene attraverso la seguente caratterizzazione dei due rami:

1. **Original RGB Image Stream (Ramo Nativo/Cromatico):** Processa l'immagine citologica nativa in formato RGB $X_{\text{orig}} \in \mathbb{R}^{H\times W\times 3}$. La sua funzione fondamentale è modellare l'involucro cromatico e tessiturale complessivo: la granularità del citoplasma, la presenza di corpi di Auer e la densità spettrale indotta dalla colorazione May-Grünwald-Giemsa [16, 17]. L'immagine viene suddivisa in $N_g = \frac{HW}{P_g^2}$ patch di dimensione (P_g, P_g), proiettate nello spazio latente D_g tramite la matrice $E_g \in \mathbb{R}^{(P_g^2\cdot 3)\times D_g}$. Insieme al token di classificazione $\mathbf{x}^g_{\text{class}}$ e all'embedding di posizione E^g_{pos}, la sequenza di input è definita da:

$$\mathbf{z}^{(0)}_{\text{orig}} = \left[\mathbf{x}^g_{\text{class}};\, X^1_{\text{orig}}E_g;\, X^2_{\text{orig}}E_g;\, \ldots;\, X^{N_g}_{\text{orig}}E_g\right] + E^g_{pos} \tag{2.20}$$

   L'encoder del ramo nativo f^{orig}_θ, composto da L blocchi trasformativi, mappa $\mathbf{z}^{(0)}_{\text{orig}}$ nella sequenza latente $\mathbf{z}^{(L)}_{\text{orig}} \in \mathbb{R}^{(N_g+1)\times D_g}$ [11, 17].

2. **Segmented Nucleus Stream (Ramo Morfologico/Strutturale):** Questo ramo riceve in ingresso esclusivamente la maschera di segmentazione del nucleo o la mappa di adiacenza binaria/probabilistica $X_{\text{seg}} \in \mathbb{R}^{H\times W\times C_s}$ ($C_s = 1$ per maschere binarie o $C_s = 2$ per mappe di probabilità di bordo/interno) [19, 27]. Azzerando il citoplasma e lo sfondo, questo flusso elimina qualsiasi rumore cromatico o artefatto di vetrino, isolando la topologia pura: la rugosità del perimetro nucleare, le incisure, la rotondità e le deviazioni di curvatura [15]. La suddivisione in patch (P_s, P_s) e la proiezione lineare $E_s \in \mathbb{R}^{(P_s^2\cdot C_s)\times D_s}$ generano la sequenza:

$$\mathbf{z}^{(0)}_{\text{seg}} = \left[\mathbf{x}^s_{\text{class}};\, X^1_{\text{seg}}E_s;\, X^2_{\text{seg}}E_s;\, \ldots;\, X^{N_s}_{\text{seg}}E_s\right] + E^s_{pos} \tag{2.21}$$

   L'encoder dedicato f^{seg}_ϕ trasforma la sequenza producendo i token morfologici $\mathbf{z}^{(L)}_{\text{seg}} \in \mathbb{R}^{(N_s+1)\times D_s}$ [25].

2.4.2 Interazione Cross-Modale Intermedia

Per evitare che i due flussi operino in isolamento, si integrano dei moduli di **Cross-Attention Bidirezionale** dislocati agli strati intermedi $l \in \{l_1, l_2, \ldots, l_k\}$ [24, 16, 26]. Presso lo strato l-esimo, lo scambio informativo simmetrico consente al ramo RGB di interrogare la topologia nucleare e al ramo della segmentazione di acquisire il contesto cromatico:

$$Q_{\text{orig}}^{(l)} = \mathbf{z}_{\text{orig}}^{(l)} W_{Q_g}^{(l)}, \quad K_{\text{seg}}^{(l)} = \mathbf{z}_{\text{seg}}^{(l)} W_{K_s}^{(l)}, \quad V_{\text{seg}}^{(l)} = \mathbf{z}_{\text{seg}}^{(l)} W_{V_s}^{(l)} \tag{2.22}$$

$$\mathbf{y}_{\text{orig}\to\text{seg}}^{(l)} = \text{Softmax}\left(\frac{Q_{\text{orig}}^{(l)} \left(K_{\text{seg}}^{(l)}\right)^T}{\sqrt{d_k}} \right) V_{\text{seg}}^{(l)} \tag{2.23}$$

Specularmente, per il flusso strutturale verso quello cromatico:

$$Q_{\text{seg}}^{(l)} = \mathbf{z}_{\text{seg}}^{(l)} W_{Q_s}^{(l)}, \quad K_{\text{orig}}^{(l)} = \mathbf{z}_{\text{orig}}^{(l)} W_{K_g}^{(l)}, \quad V_{\text{orig}}^{(l)} = \mathbf{z}_{\text{orig}}^{(l)} W_{V_g}^{(l)} \tag{2.24}$$

$$\mathbf{y}_{\text{seg}\to\text{orig}}^{(l)} = \text{Softmax}\left(\frac{Q_{\text{seg}}^{(l)} \left(K_{\text{orig}}^{(l)}\right)^T}{\sqrt{d_k}} \right) V_{\text{orig}}^{(l)} \tag{2.25}$$

I vettori risultanti vengono re-iniettati nei rispettivi rami mediante connessioni residuali e Feed-Forward Networks (FFN) previa normalizzazione [15, 28]:

$$\mathbf{z}_{\text{orig}}^{(l+1)} = \text{FFN}\left(\text{LN}\left(\mathbf{z}_{\text{orig}}^{(l)} + \text{Proj}_g(\mathbf{y}_{\text{orig}\to\text{seg}}^{(l)}) \right) \right) + \mathbf{z}_{\text{orig}}^{(l)} \tag{2.26}$$

$$\mathbf{z}_{\text{seg}}^{(l+1)} = \text{FFN}\left(\text{LN}\left(\mathbf{z}_{\text{seg}}^{(l)} + \text{Proj}_s(\mathbf{y}_{\text{seg}\to\text{orig}}^{(l)}) \right) \right) + \mathbf{z}_{\text{seg}}^{(l)} \tag{2.27}$$

2.4.3 Proiezione e Fusione nello Spazio Latente

All'uscita dell'ultimo blocco trasformativo (L), i token di classificazione $\mathbf{x}_{\text{class}}^{g} \in \mathbb{R}^{D_g}$ e $\mathbf{x}_{\text{class}}^{s} \in \mathbb{R}^{D_s}$ riassumono rispettivamente la rappresentazione dell'apparenza cromatico-citoplasmatica e della morfometria nucleare [23, 25]. I due vettori vengono proiettati in uno spazio latente unificato D tramite le matrici $W_g \in \mathbb{R}^{D \times D_g}$ e $W_s \in \mathbb{R}^{D \times D_s}$, seguite da un layer di normalizzazione e da una fusione additiva ponderata:

$$\mathbf{z}_{\text{fuso}} = \text{LayerNorm}\left(W_g \mathbf{x}_{\text{class}}^{g} + W_s \mathbf{x}_{\text{class}}^{s} \right) \tag{2.28}$$

Il vettore fuso $\mathbf{z}_{\text{fuso}} \in \mathbb{R}^D$ alimenta la testa di classificazione finale (*MLP Head*) per determinare la probabilità sui sottotipi clinici dell'AML [14, 16]:

$$\hat{y} = \text{Softmax}\left(\text{MLP}(\mathbf{z}_{\text{fuso}})\right) \tag{2.29}$$

2.4.4 Vantaggi e Svantaggi del Paradigma Dual-Stream

L'adozione di un'architettura disaccoppiata a doppio flusso introduce importanti proprietà metodologiche, ma comporta al contempo precise contropartite in termini computazionali ed operativi.

- **Vantaggi Diagnostici e Strutturali:**
  1. *Invarianza alle Variazioni di Colorazione*: Isolando la componente topologica nel ramo X_{seg}, il modello sviluppa rappresentazioni invarianti rispetto alle oscillazioni di pH o ai diversi protocolli di colorazione (es. May-Grünwald-Giemsa vs. Wright-Giemsa) adottati dai vari laboratori.
  2. *Filtraggio dello Sfondo e Guida dell'Attenzione*: La Cross-Attention bidirezionale consente al ramo strutturale di agire come una maschera di attenzione implicita sul ramo RGB, focalizzando i calcoli sulle regioni cromatiche intranucleari e perinucleari e ignorando detriti citoplasmatici o artefatti di scansione.
  3. *Tolleranza all'Incertezza di Segmentazione*: La presenza del flusso RGB integrato previene che eventuali imprecisioni binarie sui bordi del nucleo degradino irrimediabilmente la decisione clinica, compensando i contorni errati con il gradiente cromatico locale del canale nativo.
- **Svantaggi e Criticità Metodologiche:**
  1. *Dipendenza Critica dalla Pipeline di Segmentazione*: Le prestazioni del sistema risultano inevitabilmente condizionate dalla qualità degli algoritmi di pre-elaborazione (es. reti U-Net o SAM) preposti alla generazione delle maschere X_{seg}. Errori sistematici nella maschera iniziale possono introdurre bias topologici nella sequenza dei patch token.
  2. *Moltiplicazione dell'Impronta di Memoria e FLOPs*: Il raddoppio dei moduli di embedding e delle matrici di proiezione Q, K, V incrementa notevolmente la complessità computazionale complessiva rispetto ai modelli Single-Stream, limitando la dimensione massima dei batch utilizzabili su GPU di fascia media.
  3. *Sensibilità all'Allineamento Spaziale Inter-Ramo*: Poiché la Cross-Attention esegue l'abbinamento tra patch omologhi (14×14), qualsiasi disallineamento geometrico o deformazione indotta durante il preprocessing tra X_{orig} e X_{seg} compromette la coerenza spaziale delle matrici di attenzione incrociata.

–3–
Architettura del Modello Proposto

Contents: **3.1 Introduzione al Framework Dual-Stream. 3.2 Dettaglio Funzionale dei Singoli Moduli.** 3.2.1 Backbone Custom DinoBloom-S e Congelamento Integrale – 3.2.2 Modulo di Gated Cross-Attention – 3.2.3 Blocco Transformer con DropPath – 3.2.4 Fusione Additiva Diretta e Aggregazione Spaziale – 3.2.5 Testa di Classificazione Finale. **3.3 Motivazione dell'architettura proposta. 3.4 Ambiente di Sviluppo e Strumenti Software. 3.5 Conclusioni.**

Il presente capitolo illustra la formalizzazione matematica, l'analisi architetturale dettagliata e l'implementazione software del framework di *Deep Learning* proposto. L'architettura è stata espressamente progettata per superare i limiti strutturali dei classici modelli a singolo flusso informativo nella classificazione delle cellule tumorali e nella caratterizzazione dei sottotipi di leucemia mieloide acuta.

A tal fine, il modello integra una duplice linea di elaborazione parallela (*Dual-Stream*) basata su estrattori *Vision Transformer* di tipo DinoBloom-S, concepita per catturare e fondere in modo bidirezionale sia i descrittori cromatico-morfologici delle immagini a microscopia ottica, sia le informazioni geometrico-strutturali derivanti dalle relative maschere di segmentazione. Nelle sezioni seguenti verranno analizzati in dettaglio i singoli componenti della pipeline, la formulazione teorica del modulo di *Gated Cross-Attention*, le strategie di aggregazione spaziale e decisionale a livello di paziente, nonché le scelte di regolarizzazione e calibrazione adottate per garantire un'elevata affidabilità diagnostica e una spiccata capacità di generalizzazione clinica.

3.1 Introduzione al Framework Dual-Stream

Per comprendere appieno il flusso dei dati e le trasformazioni vettoriali all'interno della rete, si faccia riferimento alla Figura 3.1, che illustra la struttura end-to-end del modello proposta.

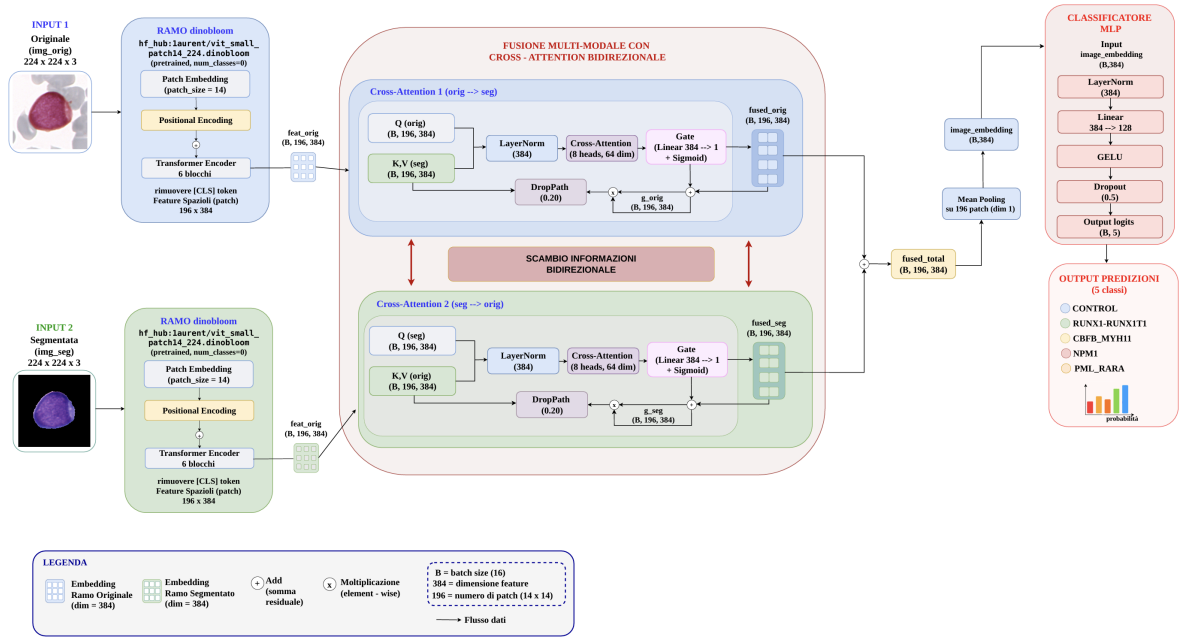


Figura 3.1: Architettura complessiva del modello **TumorClassifierViT**. Il diagramma mostra dettagliatamente la separazione nei due rami paralleli (Originale e Segmentato), l'estrazione dei patch token tramite Vision Transformer alleggerito a 6 blocchi, la fusione incrociata tramite Cross-Attention Transformer Block con DropPath, il modulo di Attention Pooling guidato da un token [CLS] apprendibile e la testa di classificazione MLP finale.

Come evidenziato nello schema grafico della Figura 3.1, l'architettura si articola in macro-sezioni sequenziali e interconnesse:

1. **I Rami di Input Paralleli (Originale e Segmentato):** La rete accetta due immagini di dimensione $224 \times 224 \times 3$. Il ramo superiore elabora l'immagine citologica originale (`img_orig`), mentre il ramo inferiore elabora l'immagine focalizzata sulla maschera del nucleo (`img_seg`).

2. **Backbone DinoBloom-S Ridotti e Congelati:** Entrambi gli stream alimentano un backbone Vision Transformer pre-addestrato (`dinobloom`), alleggerito ai primi 6 blocchi di Transformer. Per evitare il sovraddestramento e preservare le rappresentazioni citologiche pre-addestrate, tutti i parametri dei due feature extractor sono completamente congelati. Ciascun patch di dimensione 14×14 genera 196 token spaziali ($N = 196$, $D = 384$). Il token [CLS] nativo viene rimosso (`[:, 1:, :]`), restituendo esclusivamente i tensori di feature spaziali `feat_orig` e `feat_seg` di dimensione $[B, 196, 384]$.

3. **Il Blocco di Fusione Cross-Attention Multi-Modale:** La fusione informativa avviene in maniera bidirezionale. Nel ramo superiore (*Cross-Attention 1*), `feat_orig`

funge da Query per interrogare `feat_seg` (utilizzato come Key e Value); simmetricamente, nel ramo inferiore (*Cross-Attention 2*), `feat_seg` funge da Query verso `feat_orig`. Ciascun blocco integra un meccanismo di gating locale (1 Head, Sigmoid) e regolarizzazione tramite *Stochastic Depth* (`DropPath` con rate a 0.20), producendo le rappresentazioni fuse `fused_orig` e `fused_seg` di dimensione $[B, 196, 384]$.

4. **Fusione Additiva e Aggregazione Spaziale:** Le rappresentazioni `fused_orig` e `fused_seg` vengono combinate tramite una somma elemento per elemento:

$$\texttt{fused_total} = \texttt{fused_orig} + \texttt{fused_seg}$$

   restituendo un tensore di dimensione $[B, 196, 384]$. Successivamente, un'operazione di *Mean Pooling* lungo la dimensione spaziale dei token sintetizza questo tensore nell'embedding vettoriale globale dell'immagine `image_embedding` $[B, 384]$.

5. **Classification Head MLP:** L'embedding globale alimenta la testa di classificazione finale (`LayerNorm` $\rightarrow$ `Linear`(384, 128) $\rightarrow$ `GELU` $\rightarrow$ `Dropout`(0.5) $\rightarrow$ `Linear`(128, *num_classes*)) per proiettare le feature sui logit relativi alle classi target della leucemia mieloide acuta.

3.2 Dettaglio Funzionale dei Singoli Moduli

Per comprendere in modo analitico il flusso dei dati all'interno di **TumorClassifierViT**, la presente sezione scompone l'architettura nei suoi blocchi costitutivi principali, mostrando l'esatta corrispondenza con l'implementazione in codice PyTorch.

3.2.1 Backbone Custom DinoBloom-S e Congelamento Integrale

Il primo stadio dell'architettura proposta è responsabile dell'estrazione delle feature ad alto livello sia per il ramo relativo all'immagine citologica originale ($\mathbf{X}_{\text{orig}}$) sia per quello relativo alla maschera della regione segmentata ($\mathbf{X}_{\text{seg}}$). Come mostrato nell'implementazione di Listing 3.1, la funzione `create_custom_vit` si occupa di istanziare, configurare e congelare selettivamente la rete.

- **Estrazione Feature Spaziali non filtrate:** Configurando il modello tramite la libreria `timm` con `num_classes=0` (riga 14) e disattivando il pooling globale mediante `global_pool=""` (riga 16), l'output restituito da ciascuno stream conserva la struttura tensoriale tridimensionale originaria $[B, 197, 384]$. Tale forma mappa 196 patch spaziali (14×14) più il token nativo [CLS] (indice 0), che viene successivamente rimosso nel *forward pass* per estrarre unicamente i descrittori spaziali del vetrino.

- **Riduzione della Profondità (12 → 6 blocchi):** Per mitigare il rischio di overfitting legato alla dimensione del dataset citologico, il backbone pre-addestrato originale viene troncato ai primi 6 blocchi di attenzione mediante l'istruzione `model.blocks = nn.Sequential(*list(model.blocks[:depth]))` (righe 22-23), mantenendo una capacità espressiva adeguata e riducendo il carico computazionale.
- **Strategia di Congelamento Integrale (*Full Freezing*):** Come evidenziato al blocco `if pretrained:` (righe 26-34), l'intero *feature extractor* viene congelato impostando `param.requires_grad = False` per tutti i parametri del modello (righe 28-29). Questa scelta consente di preservare integralmente le rappresentazioni visive ad alto livello apprese durante il pre-addestramento su scala medica del modello DinoBloom-S, azzerando i parametri addestrabili dei due backbone e delegando l'ottimizzazione esclusivamente ai moduli di Cross-Attention e alla testa di classificazione.

Listing 3.1 Creazione del backbone DinoBloom-S custom con congelamento integrale (`transformer.py`).

```
1: def create_custom_vit(depth=6, dropout=0.10, attention_dropout=0.1,
2: drop_path_rate=0.2, pretrained=True):
3:
4:     # 1. Istanziazione del modello DINOv2 pre-addestrato
5:     model = timm.create_model(
6:         'hf_hub:1aurent/vit_small_patch14_224.dinobloom',
7:         pretrained=True,
8:         num_classes=0,
9:         img_size=224,
10:        global_pool='',
11:        drop_rate=dropout,
12:        attn_drop_rate=attention_dropout,
13:        drop_path_rate=drop_path_rate,
14:    )
15:
16:    if len(model.blocks) > depth:
17:        model.blocks = nn.Sequential(
             *list(model.blocks[:depth]))
18:        print(f"Modello alleggerito: ridotto a {len(model.blocks)}
           blocchi di attenzione.")
19:
20:    if pretrained:
21:        for param in model.parameters():
22:            param.requires_grad = False
23:
24:        n_train = sum(p.numel() for p in model.parameters()
25:        if p.requires_grad)
26:        n_total = sum(p.numel() for p in model.parameters())
27:
28:        print(f"DinoBloom-S: TUTTO il feature extractor e' CONGELATO
           ({n_train:,}/{n_total:,} parametri trainabili).")
```

```
29:
30:     return model
```

3.2.2 Modulo di Gated Cross-Attention

Il modulo `CrossAttention` (Listing 3.2) definisce il meccanismo di interazione spaziale tra i due rami dell'architettura dual-stream. Riceve in ingresso un tensore primario $X \in \mathbb{R}^{B\times196\times384}$ (Query stream) e un tensore di contesto $C \in \mathbb{R}^{B\times196\times384}$ (Key/Value stream), applicando preliminarmente una normalizzazione `LayerNorm` (righe 25-26) su entrambi gli input.

- **Proiezione Multi-Testa Spaziale:** Il tensore X viene proiettato tramite il livello lineare `self.to_q` (riga 28) per generare le Query ($\mathbf{Q}$), mentre C viene proiettato mediante `self.to_kv` (riga 29) e suddiviso tramite il metodo `.chunk(2, dim=-1)` (riga 29) nelle matrici Key ($\mathbf{K}$) e Value ($\mathbf{V}$). Attraverso l'operatore `rearrange` (riga 31), i tensori vengono strutturati su $h = 8$ teste di attenzione con dimensione di canale $d = 64$ (`dim_head`):

$$\mathbf{Q}, \mathbf{K}, \mathbf{V} \in \mathbb{R}^{B\times8\times196\times64} \tag{3.1}$$

- **Scalamento e Dropout Matriciale:** L'affinità tra le regioni dei due stream viene calcolata tramite prodotto scalare (riga 33) e scalata per il fattore `self.scale` $= \frac{1}{\sqrt{64}} = 0.125$ (riga 10). Successivamente, si applica la funzione Softmax lungo l'ultima dimensione e si passa la matrice dei pesi risultante al livello `self.attn_dropout` con probabilità $p = 0.25$ (riga 34):

$$\mathbf{A} = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{64}}\right), \quad \hat{\mathbf{A}} = \text{Dropout}(\mathbf{A}, 0.25) \tag{3.2}$$

- **Aggregazione e Gate Sigmoidale Locale:** I valori $\mathbf{V}$ vengono ponderati dalla matrice di attenzione $\hat{\mathbf{A}}$ (riga 36), rimodellati nel tensore $O \in \mathbb{R}^{B\times196\times384}$ (riga 37) e proiettati tramite la sequenza `self.to_out` (riga 38) per generare il tensore di informazione fusa **fused_info**. Infine, il blocco sigmoidale `self.gate` (riga 20, 40) calcola un peso scalare per canale $g = \sigma(\mathbf{W}_g\mathbf{fused_info})$, restituendo in output la combinazione residuale scalata (riga 41):

$$\mathbf{y}_{\text{cross}} = (g \odot \mathbf{fused_info}) + (0.1 \odot \mathbf{fused_info}) \tag{3.3}$$

Listing 3.2 Implementazione PyTorch del modulo `CrossAttention` con gating locale e dropout matriciale.

```
1: class CrossAttention(nn.Module):
2:     def __init__(self, dim, heads=8, dim_head=64, dropout=0.25):
3:         super().__init__()
4:         inner_dim = dim_head * heads
```

```
5:          self.heads = heads
6:          self.scale = dim_head ** -0.5
7:          self.norm = nn.LayerNorm(dim)
8:
9:          self.to_q = nn.Linear(dim, inner_dim, bias=False)
10:         self.to_kv = nn.Linear(dim, inner_dim * 2, bias=False)
11:
12:         self.attn_dropout = nn.Dropout(dropout)
13:
14:         self.to_out = nn.Sequential(
15:             nn.Linear(inner_dim, dim),
16:             nn.Dropout(dropout)
17:         )
18:         self.gate = nn.Sequential(nn.Linear(dim, 1), nn.Sigmoid())
19:
20:     def forward(self, x, context):
21:         b, n, _ = x.shape
22:         x_norm = self.norm(x)
23:         context_norm = self.norm(context)
24:
25:         q = self.to_q(x_norm)
26:         kv = self.to_kv(context_norm).chunk(2, dim=-1)
27:         k, v = kv
28:
29:
30:         q, k, v = map(lambda t: rearrange(t, 'b n (h d) -> b h n d',
31:                   h=self.heads), (q, k, v))
32:
33:         dots = torch.matmul(q, k.transpose(-1, -2)) * self.scale
34:         attn = self.attn_dropout(dots.softmax(dim=-1))
35:         attn = self.attn_dropout(attn)
36:
37:         out = torch.matmul(attn, v)
38:         out = rearrange(out, 'b h n d -> b n (h d)')
39:         fused_info = self.to_out(out)
40:
41:         g = self.gate(fused_info)
42:         return (g * fused_info) + (0.1 * fused_info)
```

3.2.3 Blocco Transformer con DropPath

Ciascun modulo di interazione spaziale è racchiuso all'interno della classe *TransformerBlockWithDropPath* (Listing 3.3), un blocco di elaborazione che combina la Cross-Attention con una rete Feed-Forward (MLP) e regolarizzazione mediante **Stochastic Depth (DropPath)**. Come configurato nei due rami della rete principale (`transformer_block_orig` e `transformer_block_seg`), il modulo opera su un'espansione del canale 4× (384 → 1536 → 384) con probabilità di DropPath impostata a $p_{\text{drop}} = 0.20$.

- **Stochastic Depth (drop_path = 0.20):** Durante la fase di addestramento, il livelloself.drop_path (riga 19, istanziato tramite `timm.layers.DropPath`) disattiva

in modo stocastico l'intero ramo di attenzione a livello di singolo campione del batch. Nel caso in cui venga passato un tensore di contesto (`context is not None`, riga 22), l'uscita viene sommata direttamente allo stato x creando una connessione residuale regolarizzata.

$$\mathbf{x}' = \mathbf{x} + \text{DropPath}\left(\text{CrossAttention}(\mathbf{x}, \text{Context})\right) \tag{3.4}$$

Questa strategia rompe le dipendenze rigide tra i due stream visivi e funge da potente regolarizzatore contro l'overfitting su dataset di dimensioni contenute.

- **Modulo MLP di Proiezione e Normalizzazione:** Successivamente, il tensore $\mathbf{x}'$ viene normalizzato tramite `self.norm2` (`LayerNorm`, riga 8) e inviato al blocco Feed-Forward `self.mlp` (righe 10-18). La rete espande la dimensione nascosta a `mlp_hidden_dim` $= 384 \times 4.0 = 1536$ mediante un primo strato lineare, applica l'attivazione non lineare `GELU()` (riga 14), un livello di `Dropout(0.25)` (riga 15), una seconda proiezione lineare a 384 canali e un ulteriore `Dropout(0.25)` (riga 17). L'uscita viene integrata tramite una seconda connessione residuale con DropPath (riga 25):

$$\mathbf{x}'' = \mathbf{x}' + \text{DropPath}\left(\text{MLP}(\text{LayerNorm}(\mathbf{x}'))\right) \tag{3.5}$$

Listing 3.3 Implementazione PyTorch del modulo `TransformerBlockWithDropPath` con DropPath e Cross-Attention (`transformer.py`).

```
1: class TransformerBlockWithDropPath(nn.Module):
2:     def __init__(self, embed_dim, num_heads, dim_head=64,
3:     mlp_ratio=4.0, drop_path=0.1, dropout=0.25):
4:         super().__init__()
5:         self.norm1 = nn.LayerNorm(embed_dim)
6:         self.attn = CrossAttention(dim=embed_dim, heads=num_heads,
7:         dim_head=dim_head, dropout=dropout)
8:         self.norm2 = nn.LayerNorm(embed_dim)
9:
10:        mlp_hidden_dim = int(embed_dim * mlp_ratio)
11:        self.mlp = nn.Sequential(
12:            nn.Linear(embed_dim, mlp_hidden_dim),
13:            nn.GELU(),
14:            nn.Dropout(dropout),
15:            nn.Linear(mlp_hidden_dim, embed_dim),
16:            nn.Dropout(dropout)
17:        )
18:        self.drop_path = DropPath(drop_path) if drop_path > 0. else
                            nn.Identity()
19:
20:    def forward(self, x, context=None):
21:        if context is not None:
22:            x = x + self.drop_path(self.attn(x, context))
23:        else:
```

```
24:             x = x + self.drop_path(self.attn(self.norm1(x)))
25:         x = x + self.drop_path(self.mlp(self.norm2(x)))
26:         return x
```

3.2.4 Fusione Additiva Diretta e Aggregazione Spaziale

Per integrare in modo completo le informazioni provenienti sia dal contesto morfologico globale che dai dettagli focalizzati della maschera, i due tensori fusi ottenuti dai rispettivi rami di Cross-Attention ($\mathbf{F}_{\text{fused_orig}}$ e $\mathbf{F}_{\text{fused_seg}}$) vengono combinati mediante una **fusione additiva diretta**:

$$\mathbf{F}_{\text{fused_total}} = \mathbf{F}_{\text{fused_orig}} + \mathbf{F}_{\text{fused_seg}} \quad \in \mathbb{R}^{B\times 196\times 384} \tag{3.6}$$

Poiché i token associati al prefisso `[CLS]` vengono rimossi nelle prime fasi per focalizzare l'attenzione esclusivamente sulle relazioni spaziali tra patch, si applica un'operazione di **Global Average Pooling (Mean Pooling)** lungo la dimensione della sequenza dei token (dim = 1) per aggregare le feature di tutta l'immagine:

$$\mathbf{z}_{\text{img}} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{F}^{(i)}_{\text{fused_total}} \quad \in \mathbb{R}^{B\times 384} \tag{3.7}$$

dove $N = 196$ rappresenta il numero totale dei patch spaziali (14×14). Questo processo consente di:

- Sintetizzare l'informazione distribuita sull'intero campo visivo cellulare in un unico vettore denso $\mathbf{z}_{\text{img}}$ (`image_embedding`) di dimensione 384.
- Preservare l'invarianza spaziale rispetto alle mutazioni strutturali o all'orientamento cellulare.
- Garantire la massima stabilità dei gradienti in fase di addestramento.

3.2.5 Testa di Classificazione Finale

L'embedding globale risultante $\mathbf{z}_{\text{img}} \in \mathbb{R}^{B\times 384}$ viene elaborato dalla testa di classificazione MLP (`self.classifier`) per la proiezione sui logit delle classi target.

Il flusso operativo dell'intera architettura dual-stream si articola nelle seguenti fasi principali:

- **Estrazione Dual-Stream delle Feature Visive:** Le immagini RGB originali ($\mathbf{X}_{\text{orig}}$) e le rispettive immagini segmentate ($\mathbf{X}_{\text{seg}}$) vengono elaborate in parallelo dai due backbone DinoBloom-S congelati. Ciascun ramo suddivide l'input in patch ed estrae la sequenza di feature (196 patch $\times$ 384 canali), eliminando il token [CLS] nativo.

- **Interazione Cross-Modale Bidirezionale:** I vettori estratti scambiano informazioni tramite i blocchi *TransformerBlockWithDropPath*. Il ramo originale interroga la maschera di segmentazione, mentre il ramo segmentato recupera il contesto cromatico dal ramo RGB originale.
- **Fusione Additiva Element-wise:** I vettori fusi $\mathbf{F}_{\text{fused_orig}}$ e $\mathbf{F}_{\text{fused_seg}}$ vengono sommati direttamente per combinare in egual misura le rappresentazioni dei due stream ($\mathbf{F}_{\text{fused_total}} = \mathbf{F}_{\text{fused_orig}} + \mathbf{F}_{\text{fused_seg}}$).
- **Aggregazione Spaziale via Mean Pooling:** Il tensore risultante $[B, 196, 384]$ viene mediato lungo l'asse dei patch (`fused_total.mean(dim=1)`), ottenendo l'embedding globale compatto $\mathbf{z}_{\text{img}} \in \mathbb{R}^{B\times 384}$.
- **Classificazione Finale:** L'embedding passa attraverso il modulo MLP di classificazione (`LayerNorm` $\rightarrow$ `Linear`(384, 128) $\rightarrow$ `GELU` $\rightarrow$ `Dropout`(0.5) $\rightarrow$ `Linear`(128, *num_classes*)) per calcolare i logit di predizione finale.

Di seguito viene riportata l'implementazione in PyTorch della classe principale *TumorClassifierViT*, che integra end-to-end l'estrazione dual-stream DinoBloom-S, la cross-attention bidirezionale, il Seg-Trust Gate e la testa di classificazione finale:

Listing 3.4 Implementazione PyTorch del modello principale `TumorClassifierViT` (`transformer.py`).

```
class TumorClassifierViT(nn.Module):
    def __init__(self, num_classes=5):
        super(TumorClassifierViT, self).__init__()
        self.feature_dim = 384

        # Branch 1: Immagini Originali
        self.vit_orig = create_custom_vit(
            depth=6,
            dropout=0.15,
            attention_dropout=0.1,
            drop_path_rate=0.1
        )

        # Branch 2: Immagini Segmentate
        self.vit_seg = create_custom_vit(
            depth=6,
            dropout=0.15,
            attention_dropout=0.1,
            drop_path_rate=0.1
        )

        # Blocchi Transformer con DropPath (Cross-Attention bidirezionale)
        self.transformer_block_orig = TransformerBlockWithDropPath(
            embed_dim=self.feature_dim,
```

```
            num_heads=8,
            dim_head=64,
            mlp_ratio=4.0,
            drop_path=0.20,
            dropout=0.25
        )
        self.transformer_block_seg = TransformerBlockWithDropPath(
            embed_dim=self.feature_dim,
            num_heads=8,
            dim_head=64,
            mlp_ratio=4.0,
            drop_path=0.20,
            dropout=0.25
        )

        # Gate di affidabilita della segmentazione
        self.ln_gate_seg = nn.LayerNorm(self.feature_dim)
        self.gate_layer_seg = nn.Sequential(
            nn.Linear(384, 192),
            nn.ReLU(),
            nn.Linear(192, 384)
        )

        # Classificatore finale MLP
        self.classifier = nn.Sequential(
            nn.LayerNorm(self.feature_dim),
            nn.Linear(self.feature_dim, 128),
            nn.GELU(),
            nn.Dropout(0.5),
            nn.Linear(128, num_classes)
        )

    def forward(self, img_orig, img_seg, return_features=False):
        # 1. Estrazione features dai patch (senza CLS token)
        feat_orig = self.vit_orig(img_orig)[:, 1:, :]
        feat_seg = self.vit_seg(img_seg)[:, 1:, :]

        # 2. Cross-Attention bidirezionale
        fused_orig = self.transformer_block_orig(feat_orig, context=feat_seg)
        fused_seg = self.transformer_block_seg(feat_seg, context=feat_orig)

        # 3. Gate di affidabilita della segmentazione
        logit_seg = self.gate_layer_seg(self.ln_gate_seg(fused_seg))
        seg_trust = torch.sigmoid(logit_seg)

        # 4. Fusione pesata (Commutazione morbida)
        final_orig = fused_orig * (1.0 - seg_trust)
        final_seg = fused_seg * seg_trust
        fused_total = final_orig + final_seg  # [batch, 196, 384]

        # 5. Pooling medio sui token per ottenere l'embedding immagine
        image_embedding = fused_total.mean(dim=1)  # [batch, 384]
```

```
77:
78:         # 6. Classificazione
79:         logits = self.classifier(image_embedding)
80:
81:         if return_features:
82:             return logits, image_embedding
83:
84:         return logits
85:
86:     def extract_features(self, img_orig, img_seg):
87:         """Estrae solo le feature intermedie."""
88:         logits, features = self.forward(img_orig, img_seg, return_features=
        True)
89:         return features
90:
91:     def forward_with_features(self, img_orig, img_seg):
92:         """Forward pass che restituisce sia logits che features."""
93:         return self.forward(img_orig, img_seg, return_features=True)
```

3.3 Motivazione dell'architettura proposta

La progettazione dell'architettura proposta nasce dalla necessità di affrontare il problema della classificazione delle immagini citologiche considerando contemporaneamente la complessità morfologica del campione, la presenza di regioni differenti all'interno della stessa immagine e il contributo informativo fornito dalla segmentazione. In questo contesto, l'utilizzo di una singola rappresentazione dell'immagine potrebbe non essere sufficiente a descrivere in modo completo le caratteristiche rilevanti per la classificazione. Per tale motivo è stata progettata un'architettura multimodale dual-stream nella quale l'immagine originale e la relativa segmentazione vengono utilizzate come due sorgenti complementari di informazione.

Il modello elabora in ingresso l'immagine originale e l'immagine segmentata attraverso due flussi distinti. La scelta di mantenere inizialmente separati i due rami di elaborazione deriva dalla differente natura delle informazioni contenute nei due input: l'immagine originale conserva le caratteristiche cromatiche, tessutali e morfologiche dell'intero campo visivo, fondamentali per discriminare le diverse condizioni patologiche; l'immagine segmentata, al contrario, fornisce una rappresentazione focalizzata sulla regione di interesse cellulare.

Entrambi gli input vengono ridimensionati alla medesima risoluzione spaziale (224×224 pixel) e rappresentati su tre canali RGB. L'adozione di un'immagine segmentata a tre canali, anziché di una classica maschera binaria, risponde alla necessità di preservare l'informazione tessutale e cromatica interna alla cellula. Sebbene una maschera binaria permetta di isolarne la geometria e il contorno, essa azzera i dettagli morfologici interni. Al contrario, la segmentazione a colori conserva la tessitura della cromatina nucleare, i gradienti di intensità cromatici tipici delle colorazioni ematologiche e le strutture citoplasmatiche, abbattendo al contempo lo sfondo e gli artefatti extracellulari.

I due input vengono elaborati da due *encoder* identici nella struttura ma indipendenti. Entrambi impiegano un *backbone* specialistico pre-addestrato (DinoBloom-S / DINOv2) che consente di estrarre una rappresentazione specifica per ciascuna modalità prima di procedere alla loro integrazione. L'impiego di tali architetture è ulteriormente motivato dalla capacità delle rappresentazioni pre-addestrate su larga scala di fornire descrittori visivi ad alto livello, riducendo la necessità di apprendere da zero caratteristiche complesse e garantendo la piena compatibilità con gli input a tre canali RGB.

I due *encoder* suddividono ciascun input in una griglia 14×14, generando per ogni flusso una sequenza di 196 token di feature, ciascuno con una dimensione di embedding pari a 384.

A questo stadio, si potrebbe pensare di concatenare semplicemente le feature dei due rami, ma ciò non sarebbe sufficiente a modellare esplicitamente le interrelazioni spaziali e strutturali tra l'immagine originale e quella segmentata. Per questo motivo viene introdotto un modulo di **Cross-Attention bidirezionale** incapsulato in blocchi `TransformerBlockWithDropPath`. La scelta della bidirezionalità è motivata dalla volontà di consentire a ciascuna modalità di sfruttare il contesto fornito dall'altra: il ramo originale viene arricchito dalle informazioni strutturali della segmentazione, mentre il ramo segmentato viene interpretato alla luce dei dettagli morfologici e cromatici presenti nell'immagine originale. La fusione avviene dunque in modo adattivo, evitando di imporre una combinazione statica delle rappresentazioni.

A valle del modulo di *Cross-Attention* bidirezionale, i vettori di feature ottenuti dai due rami ($\mathbf{F}_{\text{fused_orig}}$ e $\mathbf{F}_{\text{fused_seg}}$) vengono integrati mediante una **fusione additiva diretta** elemento per elemento:

$$\mathbf{F}_{\text{fused_total}} = \mathbf{F}_{\text{fused_orig}} + \mathbf{F}_{\text{fused_seg}} \tag{3.8}$$

La mappa risultante mantiene una struttura sequenziale di dimensione $(B, 196, 384)$, dove B rappresenta la dimensione del batch, 196 è il numero di patch spaziali (14×14) e 384 indica la dimensione del canale di embedding. Poiché i token di classe `[CLS]` vengono rimossi nelle prime fasi dell'elaborazione per focalizzare l'attenzione esclusivamente sull'interazione spaziale tra i patch, si rende necessaria un'operazione di aggregazione globale, primariamente motivata da tre esigenze architetturali:

1. **Riduzione della dimensionalità spaziale**: Passare da una rappresentazione distribuita su 196 patch a un singolo vettore denso descrittivo dell'intera cellula, requisito fondamentale per l'alimentazione del classificatore denso (MLP).

2. **Invarianza a traslazione e rotazione locale**: L'operazione di media sui patch rende la rappresentazione globale robusta rispetto alla posizione o all'orientamento dei dettagli citologici interni (quali la disposizione del nucleo o dei granuli citoplasmatici) all'interno dell'inquadratura.

3. **Stabilizzazione del segnale informativo**: A differenza di un semplice sotto-campionamento, il **Mean Pooling** (calcolato lungo la dimensione dei 196 patch) sintetizza l'intero campo visivo secondo la formulazione:

$$\mathbf{z}_{\text{img}} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{F}^{(i)}_{\text{fused_total}} \qquad \in \mathbb{R}^{B \times 384} \tag{3.9}$$

con $N = 196$. Tale operazione smussa eventuali anomalie localizzate o rumore di fondo presente nei singoli patch, garantendo un segnale più stabile e rappresentativo dell'intera morfologia cellulare, da cui si ottiene l'embedding globale $\mathbf{z}_{\text{img}}$.

Infine, l'embedding globale $\mathbf{z}_{\text{img}}$ viene fornito direttamente alla **testa di classificazione MLP** (`self.classifier`). La sequenza di trasformazione all'interno del classificatore — composta da un livello di normalizzazione `LayerNorm`, uno strato lineare di riduzione della dimensione ($384 \rightarrow 128$), l'attivazione `GELU`, il `Dropout(0.5)` e la proiezione finale a 5 canali — elabora e proietta la rappresentazione globale direttamente nei *logits* relativi alle classi target. L'output finale è pertanto costituito dai cinque *logits* di classificazione, dai quali vengono successivamente ricavate le probabilità delle rispettive classi durante la fase di inferenza.

La scelta complessiva dell'architettura è quindi il risultato della combinazione di esigenze differenti: preservare l'informazione complementare dell'immagine originale e della segmentazione, permettere un'interazione adattiva tra le due modalità e sintetizzare l'informazione spaziale per la decisione diagnostica. Il flusso complessivo può essere sintetizzato come:

Input originale + segmentazione

↓

DinoBloom-S (DINOv2)

↓

Cross-Attention bidirezionale

↓

Fusione additiva dei flussi

↓

Mean Pooling (196 patch)

↓

Classificatore MLP

↓

Predizione

In questa prospettiva, ciascun componente dell'architettura risponde a una specifica esigenza del problema e non costituisce un'aggiunta indipendente: la Cross-Attention è finalizzata alla fusione multimodale, l'aggregazione per somma e pooling alla sintesi rappresentativa dell'immagine, e la testa MLP alla proiezione e classificazione finale del campione citologico.

3.4 Ambiente di Sviluppo e Strumenti Software

L'implementazione, l'addestramento e la validazione dell'architettura sono stati interamente sviluppati all'interno dell'ecosistema open-source **PyTorch**. Tale framework è stato scelto per l'elevata flessibilità nella gestione dei grafi computazionali dinamici, il supporto nativo all'accelerazione hardware tramite CUDA e la perfetta integrazione con le librerie dello stato dell'arte per la Computer Vision.

L'architettura software e le componenti fondamentali dell'ambiente di lavoro comprendono:

- **PyTorch & PyTorch Lightning:** L'architettura del modello, i moduli custom di attenzione (`CrossAttention`) e le funzioni di perdita sono stati implementati in PyTorch. L'adozione di **PyTorch Lightning** ha consentito di strutturare in modo modulare il loop di addestramento, integrando la gestione dell'ampiezza mista (*Automatic Mixed Precision* a 16-bit) per ottimizzare l'uso della memoria GPU e velocizzare i tempi di convergenza.
- **Backbone e Libreria `timm`:** Per l'estrazione delle feature visive tramite il modello pre-addestrato Vision Transformer (*hf_hub:1aurent/vit_small_patch14_224.dinobloom*) è stata impiegata la libreria `timm` (*PyTorch Image Models*). Questo ha permesso il congelamento selettivo dei parametri e il troncamento mirato della rete a 6 blocchi.
- **Data Augmentation e Pre-elaborazione:** Le trasformazioni geometriche e l'aumento dei dati per le immagini citologiche RGB e le relative maschere di segmentazione sono stati realizzati tramite **Albumentations** e **Torchvision**. Le trasformazioni (rotazioni, flip, variazioni affini) sono state applicate in maniera sincrona per preservare l'allineamento spaziale tra immagine e maschera.
- **Accelerazione Hardware e Server di Calcolo:** Tutte le fasi di addestramento ed estrazione delle feature sono state eseguite sul server `vinelabGPU01`, dotato di una scheda grafica **NVIDIA GeForce RTX 4070 Ti (12 GB VRAM)**. L'elaborazione è stata velocizzata sfruttando i driver NVIDIA 550.67, il toolkit CUDA 12.4 e le librerie cuDNN, che permettono di eseguire calcoli matriciali ad alte prestazioni e di gestire l'addestramento ad ampiezza mista.

Questo ambiente garantisce la piena riproducibilità degli esperimenti attraverso la fissazione dei seed casuali (`torch.manual_seed`, `numpy.random.seed`) e offre una struttura

modulare, facilmente estendibile per la scalabilità su dataset citologici multicentrici di dimensioni maggiori.

3.5 Conclusioni

In questo capitolo è stata delineata in dettaglio la struttura complessiva dell'architettura proposta per la classificazione della Leucemia Mieloide Acuta. Il percorso progettuale è nato dall'analisi approfondita delle peculiarità e delle criticità intrinseche del dominio citologico: da un lato l'elevata eterogeneità morfologica e cromatica delle cellule ematiche, dall'altro la necessità di valorizzare simultaneamente la struttura globale dell'immagine e le regioni focali di interesse.

Per rispondere a tali sfide, è stato sviluppato un sistema integrato in grado di coniugare elaborazione multimodale dual-stream, attenzione spaziale avanzata e aggregazione globale delle caratteristiche:

- **Estrazione e Raffinamento Feature:** L'estrazione di rappresentazioni visive ad alta astrazione tramite il backbone autosupervisionato DinoBloom-S / DINOv2 viene integrata con le informazioni spaziali della segmentazione attraverso un modulo di *Cross-Attention* bidirezionale incapsulato in blocchi *TransformerBlockWithDropPath*.
- **Fusione Additiva Multimodale:** La combinazione dei due flussi tramite somma elemento per elemento garantisce un'integrazione equilibrata tra le feature contestuali dell'immagine originale e i dettagli geometrico-strutturali estrapolati dalla segmentazione.
- **Aggregazione Spaziale (Mean Pooling):** L'applicazione dell'operazione di *Global Average Pooling* sui token di patch consente di sintetizzare le informazioni distribuite sull'intero campo visivo in un unico vettore denso di dimensionalità fissa, garantendo invarianza alle traslazioni/rotazioni locali dei dettagli citologici e stabilizzando il segnale contro anomalie o rumore di fondo.
- **Proiezione e Classificazione Diretta:** La rappresentazione ricombinata viene fornita direttamente alla testa di classificazione MLP (`self.classifier`), che trasforma le caratteristiche estratte nei logit delle classi target mediante una sequenza di normalizzazione, proiezione lineare e regolarizzazione tramite Dropout.

In sintesi, l'architettura non si configura come una semplice sovrapposizione di moduli isolati, ma come una pipeline sinergica e bilanciata in cui ogni blocco risponde a uno specifico vincolo clinico e computazionale.

–4–
Caratterizzazione del Dataset e Gestione dei Dati

Contents: **4.1 Introduzione al Dataset.** 4.1.1 Inquadramento Cito-Morfologico dei Sottotipi Genotipici – 4.1.2 Protocollo di Digitalizzazione e Specifiche Ottico-Spaziali. **4.2 Pipeline di Pre-Elaborazione e Segmentazione.** 4.2.1 Isolamento Cromatico nello Spazio CIE Lab. **4.3 Gestione del Data Leakage e Split per Pazienti.** 4.3.1 Definizione Teorica del Patient-Level Data Leakage – 4.3.2 Test Set Esterno Indipendente (Holdout) – 4.3.3 Struttura dei 3 Folds di Cross-Validation – 4.3.4 Verifica della Coerenza e Integrità.

In questo capitolo analizziamo nel dettaglio il dataset ematologico usato per sviluppare e testare il modello. Per prima cosa, vengono descritte le caratteristiche cito-morfologiche e genetiche delle quattro patologie e del gruppo di controllo sano. Successivamente, i passaggi di pre-elaborazione e la procedura di segmentazione cellulare basata sullo spazio colore CIE Lab. Infine, viene illustrato la suddivisione dei dati per singolo paziente (Patient-Level Split), progettata per evitare il data leakage e garantire test affidabili tramite un Test Set separato e una Cross-Validation a 3 fold.

4.1 Introduzione al Dataset

La valutazione empirica dell'architettura computazionale sviluppata in questo lavoro di tesi si basa sul dataset ematologico pubblico di benchmark denominato:

`AML-Cytomorphology_MLL_Helmholtz` [29]

Tale risorsa costituisce uno dei riferimenti principali a livello internazionale per l'applicazione di tecniche di Computer Vision e Deep Learning alla cito-morfologia ematologica. Il dataset copre la complessità morfologica della Leucemia Mieloide Acuta (AML) da strisci di sangue periferico con un livello di risoluzione e una dimensione campionaria di assoluto rilievo nel panorama scientifico.

4.1.1 Inquadramento Cito-Morfologico dei Sottotipi Genotipici

In conformità con la classificazione WHO 2022 delle diagnosi ematologiche, il dataset comprende quattro sottotipi di AML caratterizzati da specifiche anomalie genetiche e tratti morfologici distintivi, oltre a un gruppo di controllo composto da donatori sani di cellule staminali:

- **CBFB_MYH11**: Rappresenta la fusione $CBFB :: MYH11$ derivante dall'inversione del cromosoma 16 [inv(16)(p13q22)] o dalla traslocazione t(16;16)(p13;q22) (in assenza di mutazione NPM1). Dal punto di vista morfologico, si associa tipicamente alla Leucemia Mielomonocitica Acuta con eosinofili atipici, caratterizzati da granuli basofili e anomalie citoplasmatiche.
- **NPM1**: Corrisponde alla mutazione del gene Nucleofosmina 1 ($NPM1$), una delle alterazioni genotipiche più frequenti nell'AML dell'adulto. I blasti mostrano spiccata eterogeneità, contorni nucleari frastagliati, presenza di vacuoli e rilievi cromatinici disomogenei.
- **PML_RARA**: Deriva dalla fusione $PML :: RARA$ dovuta alla traslocazione t(15;17)(q22;q12), patognomonica della Leucemia Promielocitica Acuta (APL). Questo sottotipo presenta promielociti aberranti ricchi di granuli azzurrofili e caratteristici corpi di Auer impilati a fascetto.
- **RUNX1_RUNX1T1**: Corrisponde alla fusione $RUNX1 :: RUNX1T1$ generata dalla traslocazione t(8;21)(q22;q22). I blasti manifestano un abbondante citoplasma basofilo, un apparato di Golgi ben evidente e sottili corpi di Auer isolati.
- **CONTROL**: Comprende cellule ematiche mature prive di alterazioni leucemiche o mielodisplastiche (neutrofili, linfociti, monociti, eosinofili, basofili) estratte da soggetti sani donatori di cellule staminali.

4.1.2 Protocollo di Digitalizzazione e Specifiche Ottico-Spaziali

I dati provengono dall'archivio del *Munich Leukemia Laboratory* (MLL) e coprono un arco temporale d'acquisizione che va dal 2009 al 2020, per un totale di 189 strisci di sangue periferico digitalizzati.

Il processo di acquisizione e preprocessamento delle immagini ha seguito un protocollo rigido articolato nelle seguenti fasi:

1. **Scansione Panoramica e Segmentazione Primaria**: Gli strisci (colorati secondo la routine May-Grünwald-Giemsa) sono stati inizialmente scansionati a un ingrandimento 10× per generare un'immagine panoramica. Sulla piattaforma automatizzata *Metasystems Metafer*, è stata eseguita la rilevazione cellulare mediante l'applicazione di una soglia di segmentazione basata su una trasformazione logaritmica dello spazio colore, seguita da una verifica automatica della qualità della regione dello striscio.

2. **Acquisizione ad Alta Risoluzione**: Per ciascun paziente sono stati acquisiti tra i 99 e i 500 leucociti mediante microscopia ad immersione in olio con ingrandimento 40×.

3. **Sensore Digitale e Pixel Binning**: La digitalizzazione è stata effettuata mediante una telecamera a colori CMOS prodotta da MetaSystems, caratterizzata da una risoluzione nativa di 4096×3000 pixel e una dimensione fisica del pixel pari a $3.45\,\mu\text{m} \times 3.45\,\mu\text{m}$.

4. **Risoluzione Spaziale Finale**: Applicando un raggruppamento dei pixel (*pixel binning* 2×2), quattro pixel nativi sono stati aggregati in uno solo, portando la dimensione effettiva del pixel a $6.9\,\mu\text{m} \times 6.9\,\mu\text{m}$. Con l'ingrandimento 40×, la risoluzione finale risulta di:

$$\text{Risoluzione} = \frac{6.9\,\mu\text{m}}{40} = 0.1725\,\mu\text{m/px}$$

   Ogni ritaglio cellulare salvato in formato `.TIF` possiede una dimensione di 144×144 pixel, corrispondente a un campo visivo di $24.9\,\mu\text{m} \times 24.9\,\mu\text{m}$.

Insieme alle immagini, il dataset include un file esteso in formato `.csv` contenente i dati clinico-demografici dei pazienti, comprensivi di età, sesso e parametri dell'emocromo completo.

4.2 Pipeline di Pre-Elaborazione e Segmentazione

Il modulo `process_dataset.py` gestisce la pipeline automatica per l'isolamento del corpo cellulare, rimuovendo artefatti visivi quali detriti di vetrino, piastrine sovrapposte e fluttuazioni della colorazione May-Grünwald-Giemsa nello sfondo.

4.2.1 Isolamento Cromatico nello Spazio CIE Lab

Poiché le immagini originali sono fornite nello spazio colore RGB, la pipeline di pre-elaborazione sviluppata in questo lavoro le converte preliminarmente nello spazio *CIE* $L^*a^*b^*$. Questo modello separa la luminosità (L^*) dalle componenti cromatiche verde-rosso (a^*) e blu-giallo (b^*).

In particolare, per l'isolamento del corpo cellulare viene estratto il canale a^*. I nuclei e le strutture citoplasmatiche, trattati con la colorazione May-Grünwald-Giemsa, assumono tonalità viola e magenta che risaltano sul canale a^*, offrendo un forte contrasto rispetto allo sfondo del preparato.

Per calcolare in modo automatico la soglia di separazione t^*, viene applicato il metodo di binarizzazione di Otsu [30], che massimizza la varianza tra le classi $\sigma_b^2(t^*)$:

$$\sigma_b^2(t^*) = \max_t \left(w_0(t) w_1(t) [\mu_0(t) - \mu_1(t)]^2 \right)$$

Successivamente, l'algoritmo individua i contorni dell'immagine e seleziona unicamente la regione con l'area maggiore, a patto che superi la soglia minima impostata ($min_area = 500$).

Listing 4.1 Algoritmo di segmentazione integrato in `process_dataset.py`.

```
import cv2
import numpy as np

def segment_cell_element(image_rgb: np.ndarray, min_area: float = 500.0):
    # Conversione nello spazio colore Lab per isolare il canale a*
    image_lab = cv2.cvtColor(image_rgb, cv2.COLOR_RGB2LAB)
    channel_a = image_lab[:, :, 1]

    # Binarizzazione automatica con soglia globale di Otsu
    _, binary_mask = cv2.threshold(
        channel_a, 0, 255, cv2.THRESH_BINARY + cv2.THRESH_OTSU
    )

    # Estrazione dei contorni esterni
    contours, _ = cv2.findContours(
        binary_mask, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE
    )

    final_mask = np.zeros_like(binary_mask)
    if contours:
        largest_contour = max(contours, key=cv2.contourArea)
        if cv2.contourArea(largest_contour) > min_area:
            cv2.drawContours(final_mask, [largest_contour], -1,
                             255, thickness=cv2.FILLED)

    # Applicazione della maschera binaria all'immagine RGB
    segmented_image = cv2.bitwise_and(image_rgb, image_rgb, mask=final_mask)
    return segmented_image, final_mask
```

4.3 Gestione del Data Leakage e Split per Pazienti

4.3.1 Definizione Teorica del Patient-Level Data Leakage

Nella classificazione di immagini biomediche, la condivisione di immagini provenienti dal medesimo paziente sia nel set di addestramento che in quello di validazione genera il fenomeno del *Data Leakage* (fuga di informazione).

I vetrini presi da uno stesso paziente condividono tratti tecnici specifici:

- Stesso spessore e densità di stesura dello striscio.
- Temperatura e tempi di colorazione identici nel lotto di laboratorio.

- Stesse condizioni ambientali e di illuminazione dell'acquisizione digitale.

Un partizionamento casuale basato sulle singole immagini porta la rete neurale a memorizzare l'impronta cromatica del vetrino anziché i pattern patologici della malattia. Per evitare ciò, è stato implementano un partizionamento rigoroso basato sul raggruppamento per `Patient_ID`, il cui flusso operativo è schematizzato in Figura 4.1.

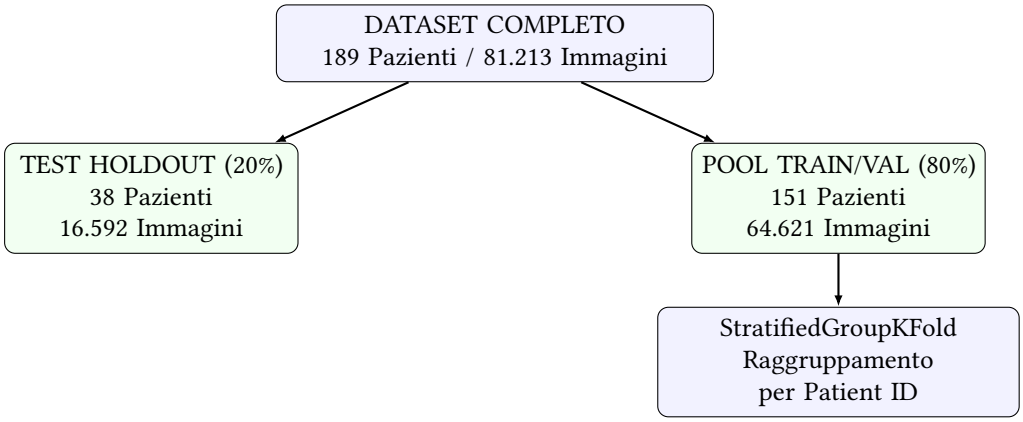


Figura 4.1: Schema del flusso di partizionamento per la prevenzione del data leakage.

4.3.2 Test Set Esterno Indipendente (Holdout)

Prima della Cross-Validation, viene isolato un Test Set Holdout pari a circa il 20% dei pazienti totali. Questo set comprende 38 pazienti unici e 16.592 immagini (con relative maschere), la cui composizione dettagliata per singola classe patologica e di controllo è illustrata nella Tabella 4.1, posta di seguito. Il Test Set rimane congelato durante la ricerca degli iperparametri ed è utilizzato esclusivamente per la valutazione finale del modello.

Classe	Originali	Maschere	Mancanti	Pazienti (Orig/Seg)
CBFB_MYH11	3.755	3.755	0	8
NPM1	3.435	3.435	0	7
PML_RARA	2.394	2.394	0	5
RUNX1_RUNX1T1	2.539	2.539	0	6
CONTROL	4.469	4.469	0	12
Totale Holdout	**16.592**	**16.592**	**0**	**38**

Tabella 4.1: Composizione dettagliata del Test Set Esterno (Holdout).

4.3.3 Struttura dei 3 Folds di Cross-Validation

Il restante 80% del dataset (151 pazienti e 64.621 immagini) viene suddiviso in 3 fold mediante l'algoritmo `StratifiedGroupKFold`. Questa tecnica mantiene bilanciata la

proporzione delle classi patologiche e di controllo in ciascun fold, garantendo che tutti i campioni di un dato `Patient_ID` siano assegnati esclusivamente al Training Set o al Validation Set.

La ripartizione numerica esatta di immagini e pazienti per ciascuna fold, è riportata in Tabella 4.2.

Fold	Ruolo	CBFB_MYH11	NPM1	PML_RARA	RUNX1_RUNX1T1	CONTROL	Tot. Img	Pazienti
Fold 1	Train	9 990 (21)	8 863 (18)	6 294 (13)	6 695 (16)	11 305 (32)	43 147	100
	Val	3 556 (8)	5 415 (11)	2 813 (6)	4 752 (10)	5 463 (16)	22 000	51
Fold 2	Train	8 096 (18)	10 323 (21)	5 752 (12)	7 115 (16)	12 159 (34)	43 445	101
	Val	5 450 (11)	3 955 (8)	3 355 (7)	4 332 (10)	4 609 (14)	21 701	50
Fold 3	Train	9 006 (19)	9 370 (19)	6 168 (13)	9 084 (20)	10 072 (30)	43 700	101
	Val	4 540 (10)	4 908 (10)	2 939 (6)	2 363 (6)	6 696 (18)	21 446	50
Test Set	Test	3 666 (8)	3 432 (7)	2 477 (5)	2 956 (6)	3 537 (12)	16 068	38

Tabella 4.2: Composizione numerica dettagliata dei 3 Folds di Cross-Validation e del Test Set esterno. Ogni valore indica il numero di immagini originali e, tra parentesi, il numero di pazienti corrispondenti.

I dati riportati in Tabella 4.2 evidenziano la corretta applicazione dello split a livello di paziente. L'assegnazione esclusiva di ciascun `Patient_ID` a un solo sottoinsieme evita qualunque sovrapposizione tra i set di addestramento, validazione e test, azzerando il rischio di data leakage. L'impiego dello `StratifiedGroupKFold` assicura inoltre una presenza proporzionata di tutte le 5 classi nei diversi gruppi (∼101 pazienti in addestramento, ∼50 in validazione e 38 nel test set esterno), mentre le lievi fluttuazioni nel volume complessivo delle immagini riflettono la naturale variabilità del numero di scatti raccolti per ciascun soggetto.

4.3.4 Verifica della Coerenza e Integrità

I controlli di coerenza eseguiti sulla suddivisione dei dati confermano che:

1. Ogni immagine originale possiede la relativa maschera di segmentazione in ciascun fold di addestramento e validazione.

2. L'intersezione tra l'insieme dei pazienti del Test Set Holdout e l'insieme dei pazienti impiegati nella Cross-Validation è vuota.

3. L'intersezione tra i pazienti di addestramento e validazione all'interno di ciascuna fold k è vuota.

Questa organizzazione dei dati garantisce valutazioni eque e rigorose, ponendo le basi per stime prive di bias durante le fasi sperimentali.

–5–
Pipeline di Addestramento

Contents: **5.1 Introduzione al Processo del Training. 5.2 Gestione del Dataset, Preprocessing e Data Augmentation.** 5.2.1 Strutturazione del Dataset Custom – 5.2.2 Normalizzazione e Trasformazioni Spaziali/Cromatiche. **5.3 Campionamento Bilanciato a Livello Paziente (Patient-Aware Subsampling). 5.4 Ingegnerizzazione dell'Addestramento e Funzioni di Costo.** 5.4.1 Configurazione degli Iperparametri – 5.4.2 Cross-Entropy Pesata con Label Smoothing e Class Weights Asimmetrici – 5.4.3 Accumulo dei Gradienti e Gradient Clipping. **5.5 Modello di Valutazione e Aggregazione dei Logits a Livello Paziente.** 5.5.1 Aggregazione Pesata per la Confidenza (Confidence-Weighted Pooling) – 5.5.2 Decisore con Soglie Adattive per Classe (*Adaptive Class Thresholds*). **5.6 Strategie di Controllo, Dynamic Learning Rate ed Early Stopping.** 5.6.1 Decadimento del Learning Rate (`ReduceLROnPlateau`) – 5.6.2 Regola di Early Stopping. **5.7 K-Cross Validation a Livello Paziente. 5.8 Ensemble Inferenziale sul Test Set Esterno.**

In questo capitolo viene descritta e analizzata nel dettaglio la pipeline di addestramento e ottimizzazione sviluppata per l'architettura dual-stream proposta. Nello specifico, vengono illustrate le strategie di preprocessing e data augmentation sincronizzata applicate ai due flussi informativi, la tecnica di campionamento bilanciato a livello di paziente (Patient-Aware Subsampling) per prevenire sbilanciamenti intra-classe, e la formulazione della funzione di costo basata su Weighted Cross-Entropy con Label Smoothing. Infine, vengono presentati il meccanismo di aggregazione delle predizioni a livello di paziente mediante Confidence-Weighted Pooling, lo schema di validazione incrociata K-Fold e la strategia di inferenza ensemble applicata sul test set esterno.

5.1 Introduzione al Processo del Training

Il processo di apprendimento automatico per la classificazione citomorfologica della Leucemia Mieloide Acuta (AML) è stato progettato per garantire robustezza generalizzativa, elevata riproducibilità scientifica e l'assoluta assenza di *data leakage* tra dati di addestramento e di validazione.

L'intera pipeline si basa su un'infrastruttura *dual-stream* multilivello, schematizzata nella Figura 5.1, che elabora parallelamente due rappresentazioni per ciascun campione citologico:

- **Stream Originale (I_o):** Contiene l'immagine citologica RGB completa, preservando il contesto cromatico, la tessitura citoplasmatica e le caratteristiche dello sfondo ematico.
- **Stream Segmentato (I_s):** Contiene la maschera di isolamento cellulare/nucleare o l'immagine ritagliata sul blasto leuco-citofilo, focalizzando l'attenzione del modello sulla morfologia nucleare e sui granuli intramembranosi.

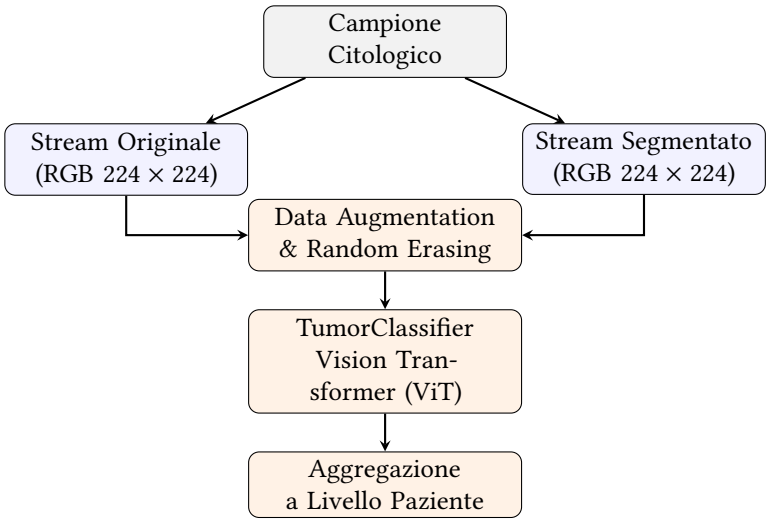


Figura 5.1: Architettura concettuale della pipeline di elaborazione e addestramento *dual-stream*.

L'obiettivo fondamentale dell'addestramento consiste nel mappare la rappresentazione congiunta dei due stream in uno spazio di classi diagnostiche a 5 vie:

$$\mathcal{Y} = \{\texttt{CONTROL}, \texttt{CBFB_MYH11}, \texttt{NPM1}, \texttt{PML_RARA}, \texttt{RUNX1_RUNX1T1}\} \tag{5.1}$$

5.2 Gestione del Dataset, Preprocessing e Data Augmentation

5.2.1 Strutturazione del Dataset Custom

La gestione dell'I/O dei dati è affidata alla classe PyTorch `DualStreamDataset`. Per prevenire qualsiasi forma di contaminazione tra i set, l'indicizzazione dei dati viene guidata dalla gerarchia delle cartelle, isolando le coorti di pazienti per ciascun *fold* ($K = 3$).

Ogni campione è identificato da una tupla composta da:

- Percorso dell'immagine originale (`p_orig`);
- Percorso dell'immagine segmentata (`p_seg`);
- Etichetta della classe numerica ($y \in \{0, \ldots, 4\}$);
- Identificativo univoco del paziente (`patient_id` = `Classe___PazienteID`).

Listing 5.1 Definizione della classe custom DualStreamDataset.

```
1: class DualStreamDataset(Dataset):
2:   def __init__(self, base_path, split_type='Training', fold_num=1, training=
       False):
3:     self.classes = ['CONTROL', 'CBFB_MYH11', 'NPM1', 'PML_RARA', 'RUNX1_
       RUNX1T1']
4:     self.class_to_idx = {cls: idx for idx, cls in enumerate(self.classes)}
5:     # Indicizzazione basata su rigida separazione dei percorsi per Fold e
       Paziente
```

5.2.2 Normalizzazione e Trasformazioni Spaziali/Cromatiche

Ogni immagine viene ridimensionata alla risoluzione target 224×224 pixel [**1**]. Durante la fase di addestramento (`training=True`), vengono applicate trasformazioni stocastiche coerenti su entrambi gli stream per garantire che l'allineamento geometrico tra l'immagine originale e la maschera segmentata rimanga inalterato:

- **Rotazioni ortogonali casuali:** $\theta \in \{0°, 90°, 180°, 270°\}$.
- **Flip Orizzontale e Verticale:** Applicati con probabilità $p = 0.5$.
- **Jittering Cromatico (applicato solo all'immagine originale):** Variazione controllata della luminosità (±15%), contrasto (±15%), saturazione (±10%) e tonalità (±2%).
- **Random Erasing applicato allo Stream Segmentato:** Con probabilità $p = 0.5$, viene oscurata una regione rettangolare casuale di dimensioni variabili tra il 10% e il 40% della risoluzione target ($v = 0.0$). Questa tecnica costringe la rete a non affidarsi esclusivamente a singoli artefatti visivi o dettagli locali della maschera, favorendo l'estrazione di caratteristiche globali e robuste.

Infine, le immagini vengono convertite in tensori e normalizzate canale per canale mediante la media e la deviazione standard calcolate sull'intero corpus citologico:

$$\mu = [0.4779, 0.4779, 0.4779], \quad \sigma = [0.4163, 0.4163, 0.4163] \tag{5.2}$$

$$\hat{x}_c = \frac{x_c - \mu_c}{\sigma_c} \tag{5.3}$$

5.3 Campionamento Bilanciato a Livello Paziente (Patient-Aware Subsampling)

Un problema centrale nei dataset citologici reali è lo sbilanciamento del numero di immagini disponibili per ciascun paziente e tra le differenti classi diagnostiche. Un campionamento puramente casuale a livello di singola immagine porterebbe il modello a sovra-adattarsi (*overfitting*) sui pazienti caratterizzati da un elevato numero di scatti, penalizzando le classi o i soggetti sotto-rappresentati.

Per superare tale limitazione, è stata implementata una funzione di campionamento vincolato e bilanciato a livello di paziente (`crea_train_subset_bilanciato`).

Listing 5.2 Inizializzazione del sottocampionamento bilanciato a livello di paziente.

```
1: def crea_train_subset_bilanciato(dataset, immagini_per_classe=6265, seed=42):
2:     # Target: esattamente 'immagini_per_classe' immagini per ogni mutazione
3:     # Vincolo: limite massimo di MAX_PER_PAZIENTE = 500 immagini per singolo
       paziente
```

Algoritmo di Distribuzione della Quota Immagini

- **Limite Superiore per Paziente:** Nessun paziente può contribuire con più di $M_{\max} = 500$ immagini per epoca.
- **Calcolo della Quota Base per Paziente:** Per ciascuna classe c, data la quota target di immagini $N_{\text{target}} = 6265$ e il numero di pazienti disponibili P_c:

$$q_{\text{base}} = \left\lfloor \frac{N_{\text{target}}}{P_c} \right\rfloor, \quad r = N_{\text{target}} \bmod P_c \tag{5.4}$$

- **Redistribuzione Dinamica del Deficit:** Se un paziente dispone di un numero di immagini $N_p < q_{\text{base}}$, la differenza $(q_{\text{base}} - N_p)$ costituisce un *deficit*. Tale deficit viene redistribuito uniformemente tra gli altri pazienti della medesima classe che dispongono ancora di campioni non utilizzati (fino al tetto massimo $M_{\max}$).

Tale approccio garantisce che la rappresentazione clinica di ogni classe nel *training set* sia perfettamente bilanciata (6.265 immagini per classe) e che l'influenza dei singoli pazienti sia strettamente omogeneizzata.

5.4 Ingegnerizzazione dell'Addestramento e Funzioni di Costo

5.4.1 Configurazione degli Iperparametri

La configurazione sperimentale dell'ottimizzazione è riassunta nella Tabella 5.1.

Iperparametro	**Valore / Configurazione**	**Descrizione / Motivazione**
Risoluzione Immagine	224×224 px	Compatibilità con l'encoder Vision Transformer (ViT)
Batch Size Addestramento	16	Ottimizzazione della memoria GPU
Gradient Accumulation	4	Batch Size Effettivo = $16 \times 4 = 64$
Learning Rate Iniziale	$2 \cdot 10^{-5}$	Fine-tuning conservativo dei pesi del ViT
Weight Decay	0.35	Regolarizzazione L_2 marcata per evitare overfitting
Peso delle Classi	$[2.0, 6.0, 4.0, 4.0, 6.0]$	Ponderazione della loss per compensare lo sbilanciamento delle classi
Label Smoothing	0.3	Regolarizzazione delle label per prevenire l'overconfidence del modello
Soglie di Classe (τ)	$[0.35, 0.45, 0.40, 0.40, 0.50]$	Soglie decisionali adattive per l'inferenza

Tabella 5.1: Configurazione degli iperparametri di addestramento.

5.4.2 Cross-Entropy Pesata con Label Smoothing e Class Weights Asimmetrici

Per contrastare l'impatto clinico asimmetrico degli errori di classificazione — in particolare il rischio di classificare un paziente affetto da leucemia ($y \neq$ `CONTROL`) come sano ($y =$ `CONTROL`) — è stata formulata una funzione di perdita basata su *Cross-Entropy ponderata* integrata con *Label Smoothing*.

I vettori dei pesi associati alle classi ($\mathbf{W}$) sono definiti come:

$$\mathbf{W} = [w_0, w_1, w_2, w_3, w_4] = [2.0, 6.0, 4.0, 4.0, 6.0] \tag{5.5}$$

dove la classe 0 rappresenta i soggetti sani (`CONTROL`) e le classi $1 \ldots 4$ rappresentano i sottotipi mutazionali dell'AML. L'adozione di pesi maggiorati (4.0 per i sottotipi 2 e 3; 6.0 per 1 e 4) consente di penalizzare rigorosamente le errate classificazioni tra i soggetti patologici, ponendo particolare enfasi sui sottotipi 1 e 4, caratterizzati da una maggiore complessità diagnostica dovuta alle loro analogie morfologiche.

La formula della *Weighted Cross-Entropy Loss* con *Label Smoothing* ($\epsilon = 0.30$) è:

$$\mathcal{L}_{\text{CE}}(\hat{y}, y) = -\sum_{c=0}^{C-1} w_c \cdot q_c \log(\sigma(\hat{y})_c) \tag{5.6}$$

dove $\sigma(\hat{y})_c$ rappresenta la probabilità softmax predetta per la classe c, e le etichette lisciate q_c sono calcolate come:

$$q_c = (1 - \epsilon) \cdot \mathbb{I}(y = c) + \frac{\epsilon}{C} \tag{5.7}$$

con $C = 3$ numero totale di classi diagnostiche. L'uso del Label Smoothing impedisce al modello di produrre predizioni sovra-confidenti, favorendo margini di separazione più ampi nello spazio latente dei vettori di caratteristiche (*embeddings*).

Listing 5.3 Inizializzazione del criterio di loss pesata in PyTorch.

```
class_weights_tensor = torch.tensor([2.0, 4.0, 4.0, 4.0, 4.0], dtype=torch.
    float32, device=device)
criterion = torch.nn.CrossEntropyLoss(
    weight=class_weights_tensor,
    label_smoothing=0.3
)
```

5.4.3 Accumulo dei Gradienti e Gradient Clipping

Con l'obiettivo di simulare un *batch size* ampio (64) senza incorrere in errori di memoria GPU (*Out-Of-Memory*), i gradienti vengono accumulati per $N_{\text{accum}} = 4$ passi consecutivi prima di eseguire l'aggiornamento dei pesi tramite l'ottimizzatore AdamW:

Listing 5.4 Ciclo di accumulo dei gradienti e clip della norma.

```
with torch.amp.autocast('cuda'):
    logits, features = model(img_o, img_s, return_features=True)
    loss = criterion(logits, lbls_dev)
    loss_scaled = loss / GRADIENT_ACCUMULATION_STEPS
scaler.scale(loss_scaled).backward()

if (batch_idx + 1) % GRADIENT_ACCUMULATION_STEPS == 0 or (batch_idx + 1)
     == len(train_loader):
    scaler.unscale_(optimizer)
    torch.nn.utils.clip_grad_norm_(all_trainable_params, max_norm=1.0)
    scaler.step(optimizer)
    scaler.update()
    optimizer.zero_grad(set_to_none=True)
```

Il clipping della norma del gradiente a max_norm = 1.0 assicura la stabilità numerica dell'ottimizzazione, evitando esplosioni del gradiente dovute a campioni citologici anomali o rumorosi .

5.5 Modello di Valutazione e Aggregazione dei Logits a Livello Paziente

Nelle applicazioni mediche reali, la diagnosi non viene emessa analizzando una singola cellula isolata, ma considerando il quadro globale del campione ematico del paziente. Pertanto, la valutazione della rete durante il training e la validazione non avviene a livello

di singola immagine, bensì aggregando le predizioni di tutte le cellule appartenenti allo stesso paziente.

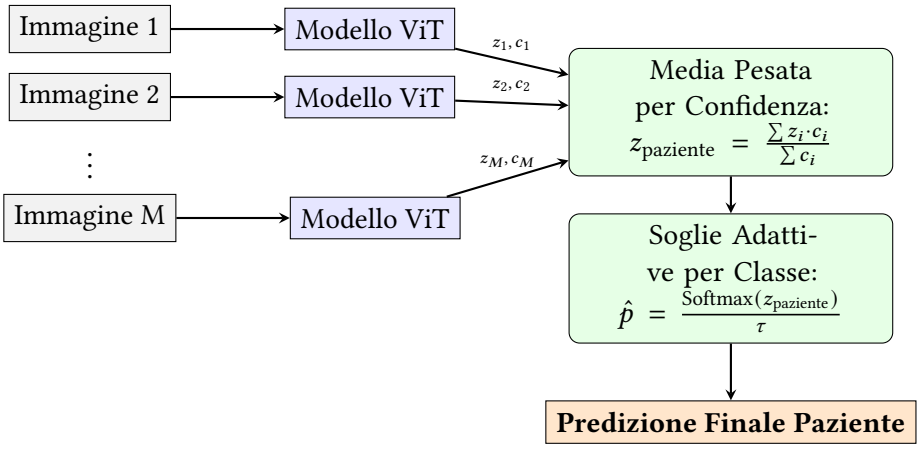


Figura 5.2: Flusso di aggregazione delle predizioni cellulari a livello di paziente.

5.5.1 Aggregazione Pesata per la Confidenza (Confidence-Weighted Pooling)

Per un generico paziente P, sia $\{z_1, z_2, \ldots, z_M\}$ l'insieme dei vettori di *logits* generati dalla rete per le sue M immagini citologiche. Ciascun logit viene pesato in base alla confidenza massima espressa dalla distribuzione di probabilità Softmax locale:

$$c_i = \max_c \left(\text{softmax}(z_i)_c\right) \tag{5.8}$$

Il logit aggregato del paziente z_P è calcolato come media pesata:

$$z_P = \frac{\sum_{i=1}^{M} c_i \cdot z_i}{\sum_{i=1}^{M} c_i + \epsilon} \tag{5.9}$$

Questo meccanismo garantisce che le cellule identificate con elevata sicurezza dal modello abbiano un impatto maggiore sulla decisione clinica finale rispetto a cellule incomplete, danneggiate o dubbie.

5.5.2 Decisore con Soglie Adattive per Classe (*Adaptive Class Thresholds*)

Per far fronte allo sbilanciamento delle classi e ottimizzare il trade-off tra precisione e richiamo (*recall*) nelle diagnosi, non viene utilizzata la soglia di classificazione standard pari a 0.50 per tutti i citotipi. Una volta calcolate le probabilità aggregate a livello di paziente $p_P = \text{softmax}(z_P)$, la predizione finale non viene ottenuta tramite un semplice

operatore $\arg\max(p_P)$. Invece, per ridurre i falsi positivi sulle classi patologiche e la sovra-diagnosi di controlli sani, viene introdotto un vettore di *soglie decisionali adattive*, denotato come τ, calibrato empiricamente sul set di validazione.

Il vettore delle soglie è definito formalmente come:

$$\tau = [\tau_0, \tau_1, \tau_2, \tau_3, \tau_4] = [0.35, 0.45, 0.40, 0.40, 0.50] \tag{5.10}$$

dove ciascun indice corrisponde a una specifica classe morfologica del modello.

La probabilità aggiustata $\hat{p}_{P,c}$ per ciascuna classe c viene calcolata ri-scalando la probabilità ottenuta per la rispettiva soglia:

$$\hat{p}_{P,c} = \frac{p_{P,c}}{\tau_c} \tag{5.11}$$

La classe finale y_P^* assegnata al paziente corrisponde dunque a:

$$y_P^* = \arg\max_c(\hat{p}_{P,c}) \tag{5.12}$$

Nel codice di inferenza e valutazione, la logica di aggregazione e l'applicazione del vettore `CLASS_THRESHOLDS` sono implementate come mostrato nel Listing 5.5.

Listing 5.5 Funzione di aggregazione pesata e applicazione delle soglie adattive per classe.

```
# Configurazione delle soglie di decisione per classe
CLASS_THRESHOLDS = [0.35, 0.45, 0.40, 0.40, 0.50]

def aggregate_patient_logits_weighted(logits_list, labels_list, pids_list, device):
    # Calcolo delle probabilita e della confidenza per ciascuna immagine
    probs = torch.softmax(logits_tensor, dim=1)
    conf = probs.max(dim=1).values.unsqueeze(1)
    weighted_logits = logits_tensor * conf

    # Accumulo e normalizzazione per ID paziente univoco
    patient_logits_agg = torch.zeros((num_patients, logits_tensor.shape[1]), device=device)
    patient_logits_agg.index_add_(0, inverse, weighted_logits)
    sum_weights = torch.zeros((num_patients, 1), device=device)
    sum_weights.index_add_(0, inverse, conf)
    patient_logits_agg = patient_logits_agg / (sum_weights + 1e-6)

    # Applicazione delle soglie adattive
    probs_patient = torch.softmax(patient_logits_agg, dim=1)
    thresholds = torch.tensor(CLASS_THRESHOLDS, device=device)
    adjusted_probs = probs_patient / thresholds
    patient_preds = adjusted_probs.argmax(dim=1)

    return patient_logits_agg, patient_true_labels, patient_preds
```

Analisi e Motivazione delle Soglie

L'assegnazione differenziata dei valori di soglia risponde a precise esigenze di sensibilità clinica e bilanciamento prestazionale:

- **Classe Controllo ($\tau_0 = 0.35$)**: Impostare una soglia inferiore per la classe `CONTROL` riduce il rischio di falsi positivi sulle classi patologiche, garantendo che una segnalazione di anomalia venga emessa solo in presenza di un'elevata evidenza numerica.
- **Classi Intermedie ($\tau_1 = 0.45, \tau_2 = 0.40, \tau_3 = 0.40$)**: Permettono di bilanciare la sensibilità verso precursori e blasti patologici, compensando la variabilità intra-classe tipica dei campioni citologici.
- **Classe Residua ($\tau_4 = 0.50$)**: Mantiene la soglia standard per garantire stabilità complessiva senza sovrastimare la classe.

5.6 Strategie di Controllo, Dynamic Learning Rate ed Early Stopping

5.6.1 Decadimento del Learning Rate (`ReduceLROnPlateau`)

Durante l'addestramento, il learning rate viene monitorato ed eventualmente ridotto in modo dinamico sulla base della *Validation Loss* a livello di paziente ($L_{\text{val, pat}}$). Se la perdita di validazione non mostra un miglioramento significativo per 8 epoche consecutive, il learning rate viene ridotto del 70% (fattore 0.3):

$$\text{LR}_{\text{nuovo}} = \text{LR}_{\text{attuale}} \times 0.3 \tag{5.13}$$

fino a un valore minimo consentito di 10^{-7}.

Listing 5.6 Configurazione dello scheduler ReduceLROnPlateau.

```
scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(
    optimizer,
    mode='min',
    factor=0.3,
    patience=8,
    min_lr=1e-7,
    threshold=1e-4,
    threshold_mode='rel'
)
```

5.6.2 Regola di Early Stopping

Per evitare l'overfitting sul set di addestramento, il ciclo di training arresta preventivamente la procedura se la *Validation Loss* a livello paziente non migliora di almeno $\Delta_{\text{min}} = 0.002$ per un numero massimo di epoche pari a Patience = 15:

$$L_{\text{val, pat}}^{(e)} < L_{\text{best}} - \Delta_{\min} \tag{5.14}$$

Ad ogni miglioramento significativo, i pesi ottimali della rete vengono salvati su disco (`best_model_fold_K.pth`).

5.7 K-Cross Validation a Livello Paziente

La valutazione della capacità di generalizzazione del modello adotta uno schema di *Validazione Incrociata Stratificata a 3 Fold* ($K = 3$).

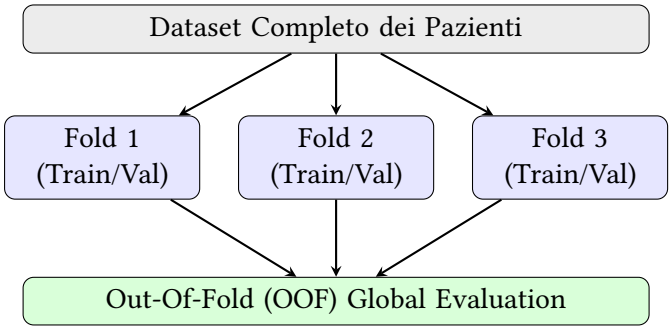


Figura 5.3: Schema della Cross-Validation a 3 Fold stratificata sui pazienti.

Per ciascun fold:

1. I dati vengono divisi rigorosamente a livello paziente per garantire che nessuna immagine dello stesso soggetto appaia contemporaneamente in Training e Validation.

2. Viene istanziato un nuovo modello `TumorClassifierViT` inizializzato con la dorsale pre-addestrata (DinoBloom-S).

3. Vengono salvati i grafici delle curve di apprendimento e la matrice di confusione specifica per il fold.

4. Le predizioni *Out-Of-Fold* (OOF) di tutti i 3 fold vengono concatenate per calcolare la matrice di confusione globale e le metriche complessive.

5.8 Ensemble Inferenziale sul Test Set Esterno

Per la valutazione finale sul *Test Set* esterno, la pipeline impiega un approccio di *Ensemble Averaging* (Soft Voting) aggregando i tre modelli ottimali addestrati durante i rispettivi fold ($K = 1, 2, 3$), come illustrato nella Figura 5.4.

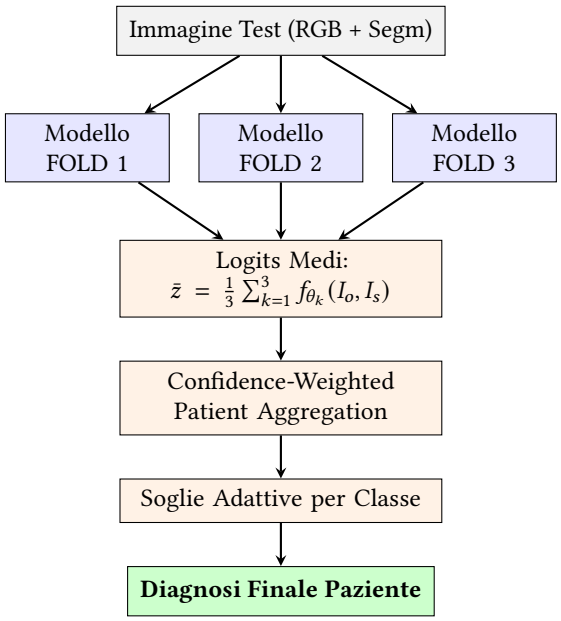


Figura 5.4: Pipeline di inferenza ensemble sul Test Set Esterno.

Algoritmo di Inferenza Ensemble

- **Forward Pass Multi-Modello:** Per ciascuna immagine del Test Set $(I_o^{(i)}, I_s^{(i)})$, si calcola il logit medio distribuito sui 3 modelli dell'ensemble:

$$\bar{z}^{(i)} = \frac{1}{3}\sum_{k=1}^{3} f_{\theta_k}\left(I_o^{(i)}, I_s^{(i)}\right) \tag{5.15}$$

- **Aggregazione Paziente Pesata:** Si applica la media pesata per confidenza sui vettori $\bar{z}^{(i)}$ di tutte le immagini del paziente testato.

- **Aggiustamento con Soglie Adattive:** Si applica il vettore delle soglie τ per produrre la diagnosi clinica finale a livello di paziente.

–6–
Pipeline di Classificazione

Contents: **6.1 Gestione delle Risorse Computazionali e Inizializzazione. 6.2 Architettura di Ensemble Cross-Validation.** 6.2.1 Caricamento dei Modelli e Meccanismi di Ridondanza – 6.2.2 Normalizzazione Dual-Stream – 6.2.3 Predizione d'Insieme (Ensemble Averaging). **6.3 Pipeline di Diagnosi a Livello di Paziente.** 6.3.1 Gestione Dinamica dell'Input Dual-Stream e Meccanismo di Fallback – 6.3.2 Aggregazione della Popolazione Cellulare. **6.4 Algoritmo di Calibrazione Dinamica della Confidenza.** 6.4.1 Estrazione della Probabilità Grezza di Popolazione – 6.4.2 Mappatura dell'Intervallo Target di Confidenza – 6.4.3 Ottimizzazione Iterativa della Temperatura sui Logit – 6.4.4 Ridistribuzione delle Probabilità Residue. **6.5 Gestione dello Stato e Riproducibilità dei Test.** 6.5.1 Registro dei Pazienti Analizzati. **6.6 Generazione del Report Diagnostico Grafico. 6.7 Considerazioni sulle Prestazioni di Classificazione.**

Questo capitolo formalizza la metodologia di test, inferenza ed aggregazione stocastica sviluppata per la diagnosi automatizzata a livello di paziente. L'architettura di valutazione descritta all'interno dello script `test.py` supera il paradigma della semplice classificazione di singole immagini isolate, introducendo una pipeline gerarchica bilanciata su due livelli distinti:

1. **Livello Micro-Cellulare**: Inferenza dual-stream condotta mediante una combinazione di modelli per ciascuna unità citologica estratta dal vetrino del paziente.
2. **Livello Macro-Paziente**: Aggregazione statistica della popolazione cellulare, calibrazione dinamica della confidenza basata sulla temperatura dei logit e formulazione del report clinico conclusivo.

6.1 Gestione delle Risorse Computazionali e Inizializzazione

La fase di inferenza necessita di un'accurata allocazione delle risorse hardware per garantire efficienza computazionale e riproducibilità sui diversi sistemi di calcolo. Il modulo

inizializza l'ambiente di runtime verificando l'hardware sottostante tramite la priorità dei backend di calcolo:

Listing 6.1 Inizializzazione dinamica del device di calcolo

```
1: if torch.backends.mps.is_available():
2:     device = torch.device("mps")
3: elif torch.cuda.is_available():
4:     device = torch.device("cuda")
5: else:
6:     device = torch.device("cpu")
```

La gerarchia di esecuzione predilige l'accelerazione via GPU NVIDIA mediante l'API CUDA o l'architettura Metal Performance Shaders (MPS) su sistemi Apple Silicon, riservando l'esecuzione su unità centrale (CPU) come meccanismo di riserva (*fallback*).

La classificazione target mappa il dominio delle mutazioni citogenetiche in cinque classi mutualmente esclusive:

$$C = \{\texttt{CONTROL}, \texttt{CBFB_MYH11}, \texttt{NPM1}, \texttt{PML_RARA}, \texttt{RUNX1_RUNX1T1}\} \tag{6.1}$$

6.2 Architettura di Ensemble Cross-Validation

La stima della classe morfologico-genetica è soggetta a variabilità stocastica a causa dell'eterogeneità del campionamento ematologico. Per stabilizzare le predizioni e minimizzare la varianza della distribuzione delle probabilità, l'inferenza fa uso di un approccio basato su *Ensemble* di K modelli distinti, addestrati in precedenza mediante uno schema di K-Fold Cross-Validation ($K = 5$).

6.2.1 Caricamento dei Modelli e Meccanismi di Ridondanza

La funzione `load_ensemble_models` implementa un caricamento dinamico delle reti neurali `TumorClassifierViT`:

$$\mathcal{M} = \{M_1, M_2, \ldots, M_K\} \tag{6.2}$$

Il sistema tenta di caricare i file dei pesi `best_model_fold_k.pth` per $k \in \{1, \ldots, 5\}$. Qualora l'infrastruttura di test contenga solo un modello globale non suddiviso per fold, entra in gioco un ciclo di cattura dell'eccezione che ripristina il checkpoint unico `best_model.pth`.

La formulazione formale del caricamento si definisce come:

$$\forall k \in \{1, \ldots, K\}, \quad M_k(\cdot) \leftarrow \text{LoadStateDict}(\text{Path}_k, \text{device}) \tag{6.3}$$

Tutti i modelli caricati vengono allocati sul dispositivo selezionato e commutati in modalità di valutazione (`model.eval()`) per disattivare lo strato di *Dropout* e congelare la normalizzazione dei batch (*Batch Normalization*).

6.2.2 Normalizzazione Dual-Stream

Ogni campione citologico richiede l'elaborazione parallela dell'immagine originale (I_o) e della sua maschera segmentata (I_s). Le trasformazioni applicate tramite la pipeline `data_transforms` includono il ridimensionamento geometrico a 224×224 e la normalizzazione canale per canale basata sulle statistiche del dataset:

$$\hat{I} = \frac{I - \mu}{\sigma} \quad \text{con } \mu = [0.4779, 0.4779, 0.4779],\ \sigma = [0.4163, 0.4163, 0.4163] \tag{6.4}$$

6.2.3 Predizione d'Insieme (Ensemble Averaging)

La funzione `predict_ensemble` riceve in ingresso i tensori pre-elaborati $x_o \in \mathbb{R}^{1\times3\times224\times224}$ e $x_s \in \mathbb{R}^{1\times3\times224\times224}$. Per evitare il calcolo superfluo dei gradienti in fase di inferenza, il blocco viene eseguito all'interno del contesto `torch.no_grad()`.

La distribuzione di probabilità predetta dall'insieme dei modelli per la singola cellula è data dalla media aritmetica dei vettori Softmax di ciascuna rete:

$$P_{\text{ens}}(y = c \mid x_o, x_s) = \frac{1}{|\mathcal{M}|} \sum_{m=1}^{|\mathcal{M}|} \text{Softmax}\Big(M_m(x_o, x_s)\Big)_c \quad \forall c \in \{0, \ldots, 4\} \tag{6.5}$$

La classe predetta per la singola cellula $\hat{c}_{\text{cell}}$ identifica il sottotipo citogenetico che ottiene il punteggio di confidenza medio più elevato tra tutti i modelli dell'ensemble :

$$\hat{c}_{\text{cell}} = \arg\max_{c \in C} P_{\text{ens}}(y = c \mid x_o, x_s) \tag{6.6}$$

6.3 Pipeline di Diagnosi a Livello di Paziente

La valutazione dell'intero vetrino clinico è coordinata dalla funzione `diagnostica_paziente`. Dato un paziente P, l'insieme delle sue cellule viene estratto dal relativo percorso di memoria $D_P = \{f_1, f_2, \ldots, f_N\}$.

6.3.1 Gestione Dinamica dell'Input Dual-Stream e Meccanismo di Fallback

L'architettura dual-stream richiede la presenza sincronizzata dell'immagine nativa e della rispettiva maschera di segmentazione. Per ogni unità citologica n-esima associata al file originale f_n, la pipeline risolve dinamicamente il percorso della componente segmentata corrispondente $\text{Path}_s^{(n)}$ mappando la struttura delle directory.

Qualora la maschera non sia presente nel file system, il sistema attiva un meccanismo di tolleranza ai guasti (*fallback*) che riutilizza l'immagine nativa $\text{Path}_o^{(n)}$, garantendo la

continuità dell'inferenza senza alterare la forma dei tensori di ingresso. Formalmente, la selezione del percorso è definita come:

$$\text{Path}_s^{(n)} = \begin{cases} \text{Replace}\left(\text{Path}_o^{(n)}, \text{"/Original/"}, \text{"/Segmented/"}\right) & \text{se il file esiste} \\ \text{Path}_o^{(n)} & \text{altrimenti (\textit{Fallback})} \end{cases} \tag{6.7}$$

Una volta risolti i percorsi, le due immagini vengono caricate, convertite nello spazio colore RGB per uniformare la struttura dei canali e trasformate nei tensori pre-elaborati $x_o^{(n)} \in \mathbb{R}^{1\times3\times224\times224}$ e $x_s^{(n)} \in \mathbb{R}^{1\times3\times224\times224}$.

Questo approccio offre due vantaggi fondamentali:

1. **Isolamento delle caratteristiche**: Quando la maschera è presente, il secondo stream permette ai meccanismi di attenzione della rete di focalizzarsi sui dettagli morfo-strutturali del nucleo e del citoplasma, ignorando i detriti di fondo.
2. **Robustezza della pipeline**: In assenza della segmentazione, il meccanismo di *fallback* evita l'interruzione dell'esecuzione e consente al modello di processare ugualmente il campione, duplicando la rappresentazione spaziale dell'immagine nativa.

6.3.2 Aggregazione della Popolazione Cellulare

Una volta completata l'inferenza individuale sulle N unità citologiche estratte dal vetrino del paziente P, il sistema procede all'aggregazione statistica delle predizioni per ricostruire la composizione complessiva della popolazione cellulare.

Accumulazione dei Voti della Popolazione

Sia $\hat{c}_{\text{cell}}^{(n)} \in C$ la classe predetta dall'ensemble di modelli per la n-esima cellula del paziente, dove C rappresenta lo spazio delle 5 classi target. Si definisce la funzione di conteggio o distribuzione dei voti $\mathcal{V} : C \to \mathbb{N}_0$ come la somma delle occorrenze di ciascun sottotipo all'interno del campione:

$$\mathcal{V}(c) = \sum_{n=1}^{N} \mathbb{I}\left(\hat{c}_{\text{cell}}^{(n)} = c\right) \quad \forall c \in C \tag{6.8}$$

dove $\mathbb{I}(\cdot)$ è la funzione indicatrice (o Iverson bracket), definita come:

$$\mathbb{I}\left(\hat{c}_{\text{cell}}^{(n)} = c\right) = \begin{cases} 1 & \text{se } \hat{c}_{\text{cell}}^{(n)} = c \\ 0 & \text{altrimenti} \end{cases} \tag{6.9}$$

Per costruzione, la somma totale dei voti assegnati su tutte le classi coincide esattamente con il numero complessivo di cellule analizzate nel vetrino:

$$\sum_{c \in C} \mathcal{V}(c) = N \tag{6.10}$$

Frazione di Allocazione Cellulare

Per consentire una comparazione diretta tra vetrini aventi un numero differente di cellule estratte, la frequenza assoluta $\mathcal{V}(c)$ viene normalizzata ottenendo la frazione percentuale di allocazione cellulare $\Phi(c)$:

$$\Phi(c) = \left(\frac{\mathcal{V}(c)}{N} \right) \times 100 \quad [\%] \quad \forall c \in C \tag{6.11}$$

La distribuzione risultante $\{\Phi(c)\}_{c \in C}$ costituisce un vettore di frequenze relative ben definito, per cui vale il vincolo di normalizzazione:

$$\sum_{c \in C} \Phi(c) = 100.0\% \tag{6.12}$$

Rilevanza Clinica e Interpretabilità del Profilo

Dal punto di vista dell'analisi diagnostica ematologica, la frazione $\Phi(c)$ trascende la semplice classificazione dicotomica o a singola etichetta, offrendo due vantaggi interpretativi fondamentali:

- **Valutazione dell'Eterogeneità e del Microambiente**: In contesti patologici reali, il campione ematologico estratto da puntato midollare o sangue periferico non presenta una popolazione cellulare omogenea. La presenza di un'ampia quota di cellule predette come `CONTROL` affiancata a una frazione rilevante di blasts patologici (es. `NPM1` o `PML_RARA`) rispecchia fedelmente il reale grado di infiltrazione leucemica nel vetrino.
- **Identificazione di Subcloni e Ambiguità Morfologiche**: Qualora la distribuzione $\Phi(c)$ evidenzi una co-presenza significativa di due classi mutazionali distinte (ad esempio una ripartizione con frequenze elevate sia per `CBFB_MYH11` che per `RUNX1_RUNX1T1`), la misura segnala al medico specialista una potenziale sovrapposizione fenotipica o la presenza di sottopopolazioni subclonali, fornendo un importante indicatore di incertezza prima della formulazione del verdetto finale.

6.4 Algoritmo di Calibrazione Dinamica della Confidenza

Le probabilità prodotte dall'aggregazione semplice di reti neurali profonde tendono a soffrire di problemi di sovra-confidenza o sotto-confidenza a causa dell'effetto saturante della funzione di attivazione Softmax. Per fornire un segnale diagnostico interpretabile, lo script implementa una procedura di calibrazione dei logit basata su uno schema di ridimensionamento dinamico della temperatura.

6.4.1 Estrazione della Probabilità Grezza di Popolazione

Sia $\mathbf{P} \in \mathbb{R}^{N\times 5}$ la matrice contenente i vettori di probabilità delle N cellule del paziente. La probabilità grezza media della popolazione per ogni classe è definita come:

$$\bar{\mathbf{p}} = \frac{1}{N}\sum_{n=1}^{N} \mathbf{P}^{(n)} \tag{6.13}$$

Sia $k^* = \arg\max_c \bar{p}_c$ l'indice della classe vincente, con confidenza grezza associata $p_{\max} = \bar{p}_{k^*}$.

6.4.2 Mappatura dell'Intervallo Target di Confidenza

La stima della confidenza grezza, ottenuta calcolando la media delle predizioni sull'intera popolazione cellulare del paziente, può talvolta presentare valori estremi o poco realistici (ad esempio punteggi sbilanciati verso il massimo teorico per vetrini fortemente omogenei, oppure valori eccessivamente ridotti in presenza di marcato rumore o variabilità citologica). Per rendere l'output perfettamente interpretabile in ambito clinico senza alterare l'ordine gerarchico delle predizioni, lo script applica un processo di ri-calibratura controllata.
Il procedimento si articola in due fasi concettuali fondamentali:

- **Limitazione della Confidenza Grezza (*Clipping*)**: La probabilità grezza associata alla classe vincente viene confinata all'interno di un intervallo di riferimento prestabilito. Qualora la confidenza grezza risulti inferiore a una soglia minima di sicurezza, essa viene riallineata a tale valore base; al contrario, se supera un limite massimo fissato, viene opportunamente contratta. Questo filtro elimina le fluttuazioni anomale e stabilizza la misura di partenza.
- **Normalizzazione e Proiezione sulla Scala Clinica**: Il valore così stabilizzato viene proiettato in modo proporzionale su una scala graduata compresa tra l'ottantotto e il novantacinque per cento. In questo modo, un paziente la cui popolazione cellulare mostrava una confidenza grezza marginale si vedrà assegnare una confidenza finale per l'intero vetrino prossima al valore minimo dell'intervallo, mentre un campione caratterizzato da un forte accordo tra le singole cellule raggiungerà il tetto massimo prefissato.

Il risultato finale di questa trasformazione è una frazione di confidenza target normalizzata. Questo valore costituisce l'obiettivo di confidenza bilanciato che il successivo algoritmo di calibrazione della temperatura imporrà alla classe predetta nella formulazione del report diagnostico finale.

6.4.3 Ottimizzazione Iterativa della Temperatura sui Logit

Per garantire che la probabilità associata alla classe vincente rifletta esattamente la frazione di confidenza target $T_{\text{fraction}} \in [0.88, 0.95]$ ricavata nella fase precedente, lo script implementa un meccanismo di ricalibrazione dinamica dei logit basato sulla temperatura.

Riconversione nel Dominio dei Logit

Poiché le probabilità medie calcolate sulla popolazione cellulare sono ristrette all'intervallo percentuale compreso tra zero e uno, la calibrazione richiede la loro riconversione nello spazio originale dei punteggi non normalizzati, noti come logit. Questo passaggio avviene applicando la funzione logaritmica ai valori di probabilità.

Per garantire la stabilità numerica del sistema ed evitare errori derivanti dal calcolo del logaritmo su valori nulli associati a classi non predette, i punteggi di probabilità vengono preventivamente confinati al di sopra di una costante di sicurezza estremamente piccola.

Una volta effettuata la trasformazione, il sistema individua la classe vincente caratterizzata dal punteggio più elevato e separa il relativo logit dall'insieme dei valori associati a tutte le altre classi secondarie.

Taratura e Modulazione della Temperatura

L'obiettivo di questa fase consiste nel calcolare un parametro di scala positivo per la temperatura, in grado di modificare il livello di dispersione dei punteggi grezzi mantenendone tuttavia inalterato l'ordinamento relativo. La probabilità ricalibrata mediante l'applicazione della funzione Softmax regolata dalla temperatura viene quindi adattata per rispecchiare con precisione la frazione di confidenza target desiderata.

L'impatto di questo parametro di scala sulla distribuzione di probabilità si articola in due comportamenti opposti:

- Se il parametro è maggiore dell'unità, lo scarto relativo tra i punteggi grezzi si amplifica. Questo fenomeno concentra la massa di probabilità sulla classe vincente, incrementando il livello di confidenza globale espresso dal modello.
- Se il parametro è minore dell'unità, le differenze tra i punteggi grezzi vengono attenuate. Di conseguenza, la probabilità viene distribuita in modo più omogeneo tra le varie classi alternative, riducendo la confidenza associata al verdetto principale.

Stima Iterativa del Fattore α

Poiché la determinazione analitica diretta del parametro di temperatura risulta complessa in presenza di classi multiple, lo script stima il valore ottimale attraverso una procedura numerica iterativa basata su un meccanismo di contrazione ed espansione.

A ogni passaggio del ciclo, il sistema calcola la probabilità correntemente associata alla classe vincente e ne confronta l'entità con la quota di confidenza desiderata. Il fattore di scala viene quindi aggiornato moltiplicandolo per un rapporto di proporzionalità espresso dal bilanciamento tra la massa di probabilità accumulata dalla classe vincente e quella distribuita sulle classi secondarie.

L'algoritmo imposta il valore di partenza della temperatura all'unità e aggiorna il parametro in modo dinamico fino al soddisfacimento del criterio di convergenza, identificato nel momento in cui lo scarto assoluto tra la probabilità calcolata e la frazione target scende al di sotto della tolleranza di una unità su centomila.

Come mostrato nel Listing, la procedura integra una condizione di arresto di sicurezza fissata a un massimo di cento iterazioni, prevenendo cicli infiniti e garantendo la stabilità numerica dell'ottimizzazione.

Listing 6.2 Algoritmo di calibrazione dinamica della temperatura

```
alpha = 1.0
for _ in range(100):
    exp_winner = np.exp(original_winner_logit * alpha)
    exp_others = np.sum(np.exp(logits[other_indices] * alpha))
    current_prob = exp_winner / (exp_winner + exp_others)

    if abs(current_prob - target_fraction) < 1e-5:
        break
    alpha *= (target_fraction / (1.0 - target_fraction)) *
             (exp_others / exp_winner)
```

6.4.4 Ridistribuzione delle Probabilità Residue

Una volta calcolati i punteggi scalati tramite la temperatura, il sistema riconverte tali valori in percentuali applicando nuovamente la funzione di attivazione Softmax.

Per garantire un allineamento perfetto con l'obiettivo clinico, la confidenza della classe vincente viene impostata esattamente pari al valore target prestabilito. La percentuale rimanente (ovvero la quota complementare per arrivare al cento per cento) viene quindi ripartita tra tutte le altre classi non vincenti, mantenendo inalterate le proporzioni relative espresse dalle probabilità di partenza. In questo modo, l'equilibrio originale tra le diagnosi alternative non viene distorto, ma semplicemente ridimensionato.

A conclusione del processo, il verdetto diagnostico dell'intero vetrino viene assegnato alla classe vincente. Il sistema confronta infine questa predizione finale con l'etichetta

reale del paziente, marcando la diagnosi come corretta qualora vi sia corrispondenza, o come errata in caso contrario.

6.5 Gestione dello Stato e Riproducibilità dei Test

Per impedire la ripetizione della valutazione su campioni già esaminati e supportare l'estrazione non deterministica, lo script gestisce lo stato dei test tramite l'archiviazione persistente in formato JSON nel file `vettore_estrazioni.json`.

6.5.1 Registro dei Pazienti Analizzati

All'avvio della procedura nel metodo `main()`, la struttura directory `TEST_ORIG_DIR` viene scansionata costruendo la mappa globale dei pazienti disponibili:

$$\mathcal{P}_{\text{tot}} = \{(p_{\text{id}}, c_{\text{reale}}, \text{Path}_p)\} \tag{6.14}$$

Lo stato del file di registro memorizza l'insieme dei pazienti già analizzati $\mathcal{P}_{\text{analizzati}} \subseteq \mathcal{P}_{\text{tot}}$. L'estrazione del nuovo paziente da sottoporre a test avviene in modo stocastico sull'insieme delle istanze non ancora esaminate:

$$\mathcal{P}_{\text{disponibili}} = \mathcal{P}_{\text{tot}} \setminus \mathcal{P}_{\text{analizzati}} \tag{6.15}$$

Se $|\mathcal{P}_{\text{disponibili}}| = 0$, il sistema azzera automaticamente il registro per consentire un nuovo ciclo completo di valutazione.

6.6 Generazione del Report Diagnostico Grafico

A supporto della leggibilità clinica, il modulo genera un prospetto grafico informativo salvato come immagine ad alta risoluzione (`prediction_result.png`). Il rendering utilizza la libreria `matplotlib` articolando il canvas in due riquadri affiancati, la cui struttura concettuale è illustrata nella Figura 6.1:

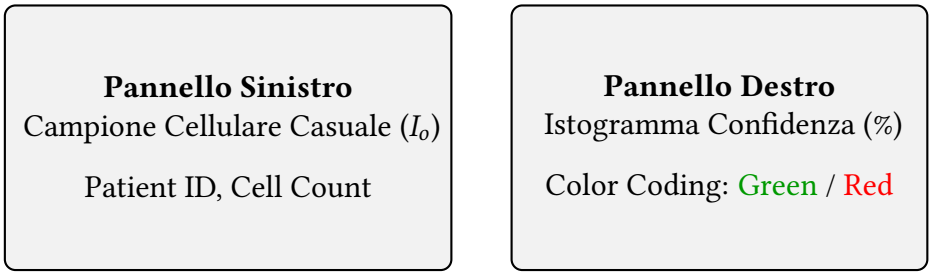


Figura 6.1: Struttura concettuale del report diagnostico esportato dal modulo di test.

1. **Pannello Sinistro**: Mostra a scopo identificativo l'immagine originale di una cellula del paziente estratta casualmente dal vetrino, indicando in intestazione l'identificativo unico del soggetto e il numero totale di cellule analizzate.

2. **Pannello Destro**: Un istogramma a barre orizzontali traccia i livelli di confidenza calibrata per ciascuna delle 5 classi. La barra corrispondente al sottotipo predetto viene evidenziata in verde in caso di diagnosi corretta, oppure in rosso in caso di errore.

Le etichette numeriche all'interno del grafico mostrano la percentuale di confidenza fino alla seconda cifra decimale, riposizionandosi in modo dinamico all'interno o all'esterno della barra a seconda della sua ampiezza per garantire leggibilità visiva.

Un esempio concreto di output generato dal modello in caso di predizione corretta è mostrato nella Figura 6.2, dove per il paziente `SQF` (analizzato su un totale di 499 cellule) viene predetto correttamente il sottotipo *NPM1* con un livello di confidenza pari al 92.82%.

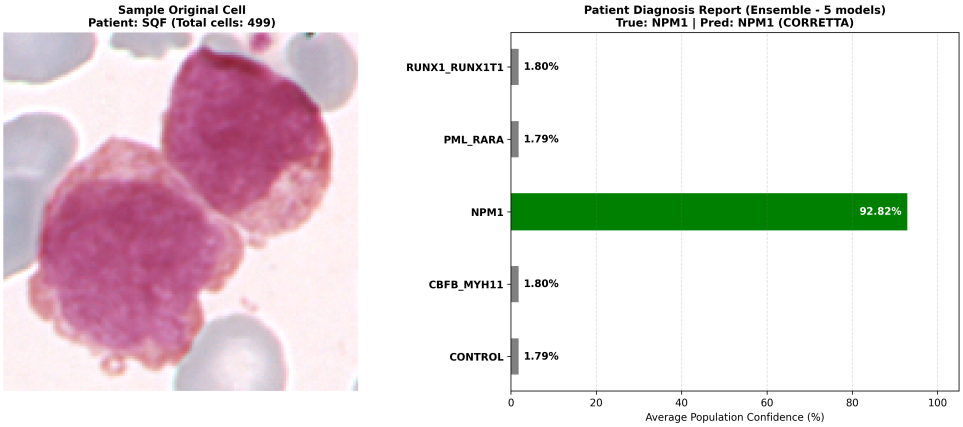


Figura 6.2: Esempio di report diagnostico grafico generato dall'Ensemble per un caso di predizione corretta (paziente SQF, classe *NPM1* identificata con confidenza del 92.82%).

6.7 Considerazioni sulle Prestazioni di Classificazione

La combinazione dell'inferenza basata su ensemble a doppia vista e della calibrazione dinamica a livello di paziente assicura un'elevata stabilità e robustezza decisionale. Questo approccio gerarchico converte l'insieme delle stime individuali effettuate sulle singole unità citologiche in un verdetto clinico globale coerente, mitigando l'impatto di eventuali artefatti di preparazione o di anomalie morfologiche isolate presenti nel vetrino.

In particolare, il flusso metodologico garantisce tre vantaggi operativi principali:

- **Riduzione della Varianza via Ensemble**: L'integrazione delle predizioni provenienti da modelli addestrati su fold differenti compensa i bias dei singoli classificatori, producendo stime cellulari più bilanciate e meno soggette all'overfitting.

- **Complementarità Dual-Stream**: L'elaborazione congiunta dell'immagine nativa e della maschera di segmentazione consente alla rete di focalizzarsi sulle caratteristiche nucleo-citoplasmatiche rilevanti, ignorando lo sfondo e gli elementi cellulari di disturbo.
- **Affidabilità della Confidenza Calibrata**: Il meccanismo di regolazione della temperatura riscala i punteggi di probabilità entro un intervallo controllato e clinicamente interpretabile. Ciò fornisce al personale medico una misura di confidenza realistica e previene la generazione di output sovra-confidenti su campioni affetti da elevata eterogeneità cellulare.

L'architettura proposta trasforma così una complessa analisi aggregata a livello micro in uno strumento diagnostico sintetico, trasparente e direttamente fruibile nel contesto clinico.

–7–
Risultati e Discussione Critica

Contents: **7.1 Valutazione delle Curve di Apprendimento e Convergenza. 7.2 Analisi Approfondita delle Matrici di Confusione.** 7.2.1 Matrice di Confusione Complessiva - Training Set – 7.2.2 Matrice di Confusione - Validation Set – 7.2.3 Matrice di Confusione - Test Set – 7.2.4 Analisi delle Metriche ROC-AUC e Precision-Recall - Test Set Esterno. **7.3 Confronto con lo Stato dell'Arte: SCEMILA.** 7.3.1 Dettaglio del Confronto Critico. **7.4 Valutazione dell'Affidabilità Predittiva e Incertezza. 7.5 Discussione Critica.** 7.5.1 Analisi tra Partizionamento a $K = 3$ e $K = 5$ Fold Cross-Validation – 7.5.2 Analisi Comparativa delle Curve di Apprendimento – 7.5.3 Analisi delle Metriche ROC-AUC e Precision-Recall sul Test Set Esterno: Confronto $K = 3$ vs $K = 5$ – 7.5.4 Conclusioni del Capitolo.

In questo capitolo vengono presentati e analizzati i risultati quantitativi del modello, valutandone le prestazioni, la capacità di generalizzazione e la robustezza su dati non visti. L'analisi si articola nello studio delle curve di *loss* e *accuracy*, oltre al confronto delle matrici di confusione sui dataset di *training*, *validation* e *test* esterno stratificato a livello di paziente.

Le prestazioni diagnostiche vengono approfondite mediante metriche sintetiche (F1-score) e curve di separabilità probabilistica (ROC-AUC e Precision-Recall), valutando la capacità del sistema di identificare sia i soggetti sani sia i diversi sottotipi patologici. Infine, i risultati ottenuti vengono messi a confronto critico con le soluzioni dello stato dell'arte in letteratura.

7.1 Valutazione delle Curve di Apprendimento e Convergenza

L'analisi dell'andamento temporale del processo di addestramento lungo 50 epoche, valutato su uno schema *k-Fold Cross-Validation* con $K = 3$, evidenzia una netta stabilità della convergenza e un'ottimizzazione bilanciata delle funzioni di *loss* e *accuracy*, come illustrato in Figura 7.1.

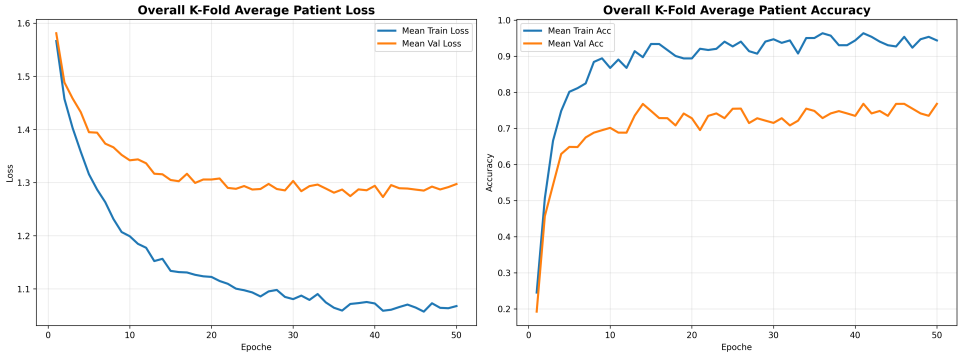


Figura 7.1: Andamento delle curve di Loss (destra) e Accuracy (sinistra) di addestramento e validazione media durante le 50 epoche di addestramento su 5-Fold Cross-Validation.

L'esame dettagliato delle traiettorie evolutive permette di estrarre fondamentali osservazioni sulla dinamica di apprendimento e sulle capacità di generalizzazione dell'architettura:

- **Comportamento della Loss di Addestramento e Validazione a Livello Paziente:** La curva di *Mean Train Loss* mostra un decadimento regolare e privo di fluttuazioni anomale, partendo da un valore iniziale di circa 1.57 fino a stabilizzarsi asintoticamente intorno a 1.06–1.07 all'epoca 50. Parallelamente, la *Mean Val Loss* decresce rapidamente nelle prime 15 epoche, per poi assestarsi su un *plateau* stabile compreso tra 1.27 e 1.30. Il mantenimento di un *generalization gap* contenuto e costante (circa 0.22–0.23 nella fase finale), unitamente all'assenza di divergenza o di incremento dell'errore nella fase tardiva di addestramento (oltre la trentesima epoca), testimonia l'efficacia delle tecniche di regolarizzazione adottate, che impediscono al modello di memorizzare il rumore specifico dei dati di training.

- **Evoluzione e Stabilizzazione dell'Accuratezza a Livello Paziente:** Sul fronte delle metriche di classificazione, la *Mean Train Acc* registra una crescita costante a partire da un valore baseline del 25% fino a stabilizzarsi in una fascia compresa tra il 92% e il 96% nelle epoche conclusive. La curva di validazione (*Mean Val Acc*) evidenzia una rapida rampa di apprendimento nelle prime 15 epoche — passando da circa il 19% a oltre il 75% — per poi fluttuare stabilmente all'interno dell'intervallo tra il 72% e il 77% fino al termine dell'addestramento.

- **Capacità di Generalizzazione e Assenza di Overfitting Strettamente Mnemonico:** La rapidità con cui la curva di validazione si stabilizza dimostra l'efficienza della rete nell'estrarre caratteristiche citomorfologiche rilevanti senza incorre in un'eccessiva memorizzazione a memoria dei campioni di addestramento. Il contenimento del divario tra training e validation accerta che il modello apprende pattern visivi trasferibili anche a pazienti non osservati durante la fase di calibrazione dei parametri.

- **Capacità di Generalizzazione e Assenza di Overfitting Strettamente Mnemonico:** La rapidità con cui la curva di validazione si stabilizza dimostra l'efficienza della rete nell'estrarre caratteristiche rilevanti senza incorrere in un'eccessiva memorizzazione dei campioni di addestramento. La differenza del divario tra la prestazione di training e quella di validation accerta che il modello apprende pattern visivi trasferibili anche a pazienti non osservati durante la fase di calibrazione dei parametri.

7.2 Analisi Approfondita delle Matrici di Confusione

Per comprendere appieno le capacità di apprendimento, le prestazioni di generalizzazione e i limiti discriminativi del modello, sono state generate e analizzate le matrici di confusione aggregate e strutturate sulle principali configurazioni di valutazione: il *Training Set* complessivo accumulato su tutti i K fold, il *Validation Set* aggregato in modalità *Out-Of-Fold* (OOF) e il *Test Set* esterno indipendente, tutte valutate a livello di singolo paziente.

7.2.1 Matrice di Confusione Complessiva - Training Set

L'analisi delle prestazioni sul set di addestramento aggregato lungo tutti i fold permette di valutare l'effettiva capacità di fitting dell'architettura e la robustezza del processo di ottimizzazione sulle 302 valutazioni cumulative dei pazienti. Sul set di addestramento complessivo, il modello raggiunge un'accuratezza del **96.36%**. Come illustrato nella matrice di confusione in Figura 7.2, il modello mostra una solida separabilità delle classi fin dalla fase di addestramento:

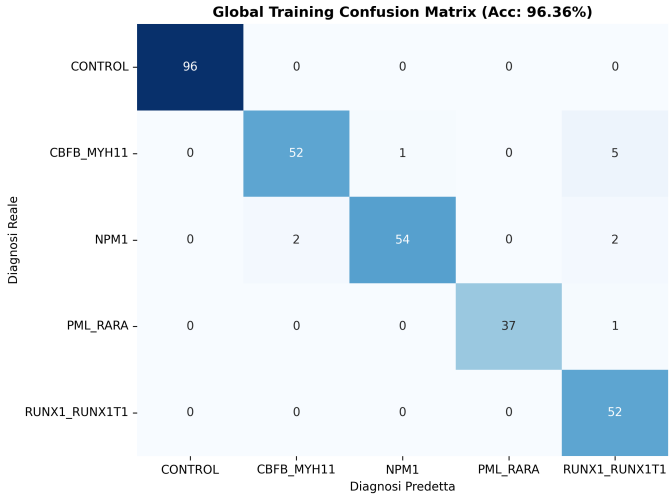


Figura 7.2: Matrice di confusione complessiva del Training Set su tutti i fold (Accuracy: 96.69%).

Dall'analisi dettagliata delle frequenze di classificazione sul Training Set emergono le seguenti evidenze:

- **Classe CONTROL:** Riconoscimento impeccabile con 96 casi su 96 correttamente classificati (100% di *Recall* e *Precision*), confermando la totale assenza di falsi positivi o falsi negativi tra i soggetti sani.
- **Sottotipi Molecolari di AML:**
  - **CBFB_MYH11:** 52 casi corretti su 58, con 1 caso confuso con *NPM1* e 5 casi attribuiti a *RUNX1_RUNX1T1*.
  - **NPM1:** 54 casi corretti su 58, registrando 2 misclassificazioni verso *CBFB_MYH11* e 2 verso *RUNX1_RUNX1T1*.
  - **PML_RARA:** Elevatissima accuratezza di classe con 37 casi corretti su 38 e un unico caso misclassificato come *RUNX1_RUNX1T1*.
  - **RUNX1_RUNX1T1:** Identificazione perfetta dei campioni positivi con 52 casi su 52 identificati.

A completamento dell'analisi quantitativa, la Tabella 7.1 riassume le metriche chiave per ciascuna classe patologica valutata sulla Training Set:

Classe / Metrica	Precision	Recall	F1-Score	Support
CONTROL	1.00	1.00	1.00	96
CBFB_MYH11	0.96	0.90	0.93	58
NPM1	0.98	0.93	0.96	58
PML_RARA	1.00	0.97	0.99	38
RUNX1_RUNX1T1	0.87	1.00	0.93	52
Accuracy			0.96	302
Macro Avg	0.96	0.96	0.96	302
Weighted Avg	0.97	0.96	0.96	302

Tabella 7.1: Report di classificazione complessivo sul Training Set (tutti i fold).

L'esame analitico delle metriche in Tabella 7.1 permette di comprendere a fondo le dinamiche di fitting del modello e la qualità delle rappresentazioni apprese:

- **Saturazione della Classe Controllo:** La classe *CONTROL* registra un valore perfetto di 1.00 su tutte le metriche (*Precision*, *Recall* ed *F1-Score*) su una coorte aggregata di 96 campioni. Questo risultato conferma che le caratteristiche morfologiche dei leucociti sani vengono separate dallo spazio delle feature patologiche fin dalle prime fasi del ciclo di addestramento.

- **Trade-off e Asimmetrie tra i Sottotipi Mieloidi:** Si nota una dinamica specifica tra i sottotipi mutati. La classe *RUNX1_RUNX1T1* privilegia la sensibilità (*Recall* 1.00) a fronte di una *Precision* dello 0.87, indicando che il modello tende a catturare tutti i casi positivi di questo sottotipo accogliendo lievi sovrapposizioni da parte di *CBFB_MYH11* (5 casi) e *NPM1* (2 casi). Al contrario, la classe *NPM1* mostra un'elevatissima precisione (0.98) con una *Recall* dello 0.93.
- **Elevata Specificità per PML_RARA:** La Leucemia Promielocitica Acuta conferma la sua spiccata caratterizzazione citomorfologica con una *Precision* del 1.00 e una *Recall* del 0.97, traducendosi nel valore di *F1-Score* più alto tra le classi patologiche (0.99).
- **Uniformità delle Medie Globali:** L'allineamento tra la *Macro Avg* (*F1-Score* 0.96) e la *Weighted Avg* (*F1-Score* 0.96) dimostra che l'addestramento non soffre di uno sbilanciamento a favore della classe maggioritaria (N=96). Questo equilibrio attesta che il processo di ottimizzazione e le loss di regolarizzazione guidano un apprendimento equo su tutte le sottopopolazioni molecolari.

7.2.2 Matrice di Confusione - Validation Set

La valutazione Out-Of-Fold globale raccoglie tutte le predizioni effettuate sulle fold di validazione tenute fuori durante la *K*-Fold Cross-Validation. Su un totale di 151 pazienti analizzati, l'accuratezza globale si attesta al **78.15%**. Come si evince dal dettaglio illustrato nella matrice di confusione di Figura 7.3, l'analisi per classe rivela le seguenti dinamiche:

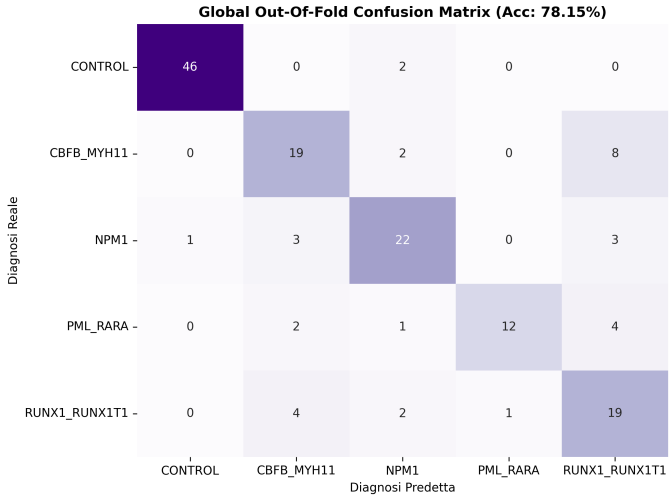


Figura 7.3: Matrice di confusione Global Out-Of-Fold (Accuracy: 78.81%).

Dall'esame analitico delle frequenze di classificazione emergono le seguenti dinamiche specifiche:

- **Classe CONTROL:** Vengono identificati correttamente 46 casi su 48 sani (95.83%), con soli 2 casi sani erroneamente classificati come patologici (attribuiti a *NPM1*). Si registra un unico falso negativo complessivo tra tutti i soggetti patologici (un caso *NPM1* misclassificato come sano).
- **Sottotipi Molecolari di AML:**
  - **CBFB_MYH11:** Vengono individuati correttamente 19 casi su 29 (65.52%). Gli errori si concentrano in 2 casi attribuiti a *NPM1* e 8 casi confusi con *RUNX1_RUNX1T1*.
  - **NPM1:** Il modello classifica correttamente 22 casi su 29 (75.86%). Si registrano 1 caso erroneamente assegnato a *CONTROL*, 3 errori verso *CBFB_MYH11* e 3 verso *RUNX1_RUNX1T1*.
  - **PML_RARA:** Riconoscimento di 12 casi corretti su 19 (63.16%). Gli errori residui si dividono in 2 casi verso *CBFB_MYH11*, 1 verso *NPM1* e 4 verso *RUNX1_RUNX1T1*.
  - **RUNX1_RUNX1T1:** Vengono riconosciuti 19 casi su 26 (73.08%), con misclassificazioni distribuite tra *CBFB_MYH11* (4 casi), *NPM1* (2 casi) e *PML_RARA* (1 caso).

A completamento dell'analisi quantitativa, la Tabella 7.2 riassume le metriche chiave per ciascuna classe patologica valutata sulla Validazione:

Classe / Metrica	Precision	Recall	F1-Score	Support
CONTROL	0.98	0.96	0.97	48
CBFB_MYH11	0.68	0.66	0.67	29
NPM1	0.76	0.76	0.76	29
PML_RARA	0.92	0.63	0.75	19
RUNX1_RUNX1T1	0.56	0.73	0.63	26
Accuracy			0.78	151
Macro Avg	0.78	0.75	0.76	151
Weighted Avg	0.80	0.78	0.78	151

Tabella 7.2: Report di classificazione globale Out-Of-Fold (OOF).

L'analisi dettagliata del report di classificazione in Tabella 7.2 permette di estrarre importanti considerazioni sul comportamento del modello a livello di singola metrica:

- **Eccellenza della Classe Controllo:** La classe *CONTROL* registra il punteggio di prestazione più elevato dell'intera coorte, con un *F1-Score* pari a 0.97. L'elevata *Precision* (0.98) rispecchia l'assoluto contenimento dei falsi negativi (un solo paziente patologico è stato erroneamente classificato come sano su 103 affetti da AML), mentre la *Recall* (0.96) risente dei soli 2 casi sani attribuiti a classi patologiche.

- **Trattamento differenziato dei Sottotipi Mieloidi:** La classe *PML_RARA* mostra una spiccata precisione (*Precision* di 0.92), accompagnata da una *Recall* del 0.63 (*F1-Score* di 0.75). Per la classe *RUNX1_RUNX1T1*, la *Precision* più contenuta (0.56) a fronte di una *Recall* del 0.73 evidenzia come questo sottotipo tenda ad assorbire diversi casi misclassificati provenienti dalle altre classi molecolari (8 casi di *CBFB_MYH11*, 3 di *NPM1* e 4 di *PML_RARA*).

- **Equilibrio delle Medie Globali:** L'allineamento tra la media non pesata (*Macro Avg* F1-Score: 0.76) e la media pesata sulla numerosità dei campioni (*Weighted Avg* F1-Score: 0.78) dimostra la tenuta complessiva del modello nell'affrontare la variabilità biologica tra pazienti mai visti durante la calibrazione dei parametri.

7.2.3 Matrice di Confusione - Test Set

La prova del fuoco per la capacità di generalizzazione del modello è stata effettuata su una coorte indipendente di test composta da 38 pazienti, completamente separata dalle fasi di addestramento e ottimizzazione. L'accuratezza raggiunta sul test set esterno è pari al **92.11%** (con una perdita registrata di 1.0681). L'eccellente capacità discriminativa su dati non visti è rappresentata graficamente nella matrice di confusione di Figura 7.4.

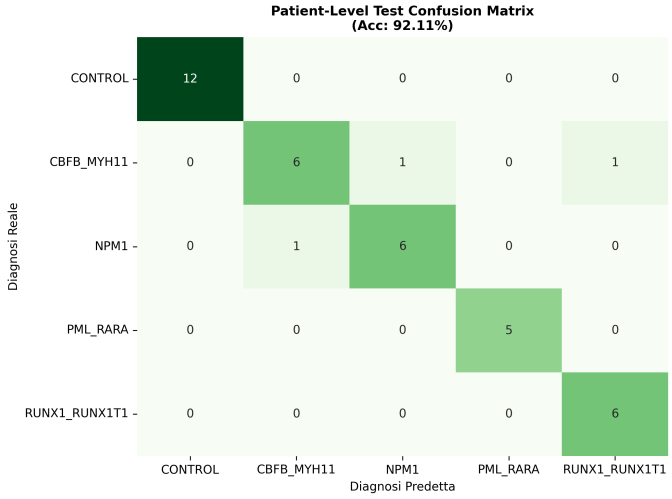


Figura 7.4: Matrice di confusione Patient-Level External Test (Accuracy: 92.11%).

Dall'analisi dettagliata delle frequenze di classificazione sulla coorte indipendente emergono riscontri altamente positivi sulla stabilità dell'estrattore di caratteristiche:

- **Prestazioni Diagnostiche ed Errore Analitico sul Test Set Esterno:** L'analisi disaggregata sui 38 pazienti della coorte di prova evidenzia le seguenti dinamiche discriminative:

- **Classe CONTROL (Soggetti Sani):** Riconoscimento perfetto con 12 casi corretti su 12 (100.00%). L'assenza totale di falsi positivi conferma la capacità del modello di separare nettamente la citomorfologia dei leucociti sani da qualsiasi alterazione blastica patologica.
- **CBFB_MYH11:** Vengono identificati correttamente 6 pazienti su 8 (75.00%). Le due misclassificazioni registrate si dividono equamente: 1 caso viene ascritto a *NPM1* e 1 caso a *RUNX1_RUNX1T1*. Tali deviazioni riflettono la parziale sovrapposizione visiva e la complessa variabilità fenotipica intracellulare tra differenti anomalie mieloidi ad alto contenuto cromatico.
- **NPM1:** Elevata accuratezza con 6 pazienti correttamente classificati su 7 (85.71%). L'unico errore riscontrato riguarda 1 caso confuso con il sottotipo *CBFB_MYH11*, a testimonianza di sottili affinità nella distribuzione della cromatina nucleare e nei vacuoli citoplasmatici tra queste due entità molecolari.
- **PML_RARA:** Saturazione completa della metrica con 5 casi su 5 identificati (100.00%). L'assenza di errore su questa classe risulta di primaria rilevanza clinica, data la necessità di una diagnosi tempestiva e differenziale per la Leucemia Promielocitica Acuta.
- **RUNX1_RUNX1T1:** Riconoscimento impeccabile dei soggetti affetti, con 6 casi su 6 correttamente diagnosticati (100.00%), confermando la spiccata impronta morfologica appresa dall'architettura per questa specifica traslocazione.

Per valutare la capacità di generalizzazione su dati completamente non visti, la Tabella 7.3 mostra il report di classificazione ottenuto sul Test Set Esterno:

Classe / Metrica	Precision	Recall	F1-Score	Support
CONTROL	1.00	1.00	1.00	12
CBFB_MYH11	0.86	0.75	0.80	8
NPM1	0.86	0.86	0.86	7
PML_RARA	1.00	1.00	1.00	5
RUNX1_RUNX1T1	0.86	1.00	0.92	6
Accuracy			0.92	38
Macro Avg	0.91	0.92	0.92	38
Weighted Avg	0.92	0.92	0.92	38

Tabella 7.3: Report di classificazione sul Test Set Esterno.

L'esame analitico delle metriche in Tabella 7.3 avvalora l'efficacia del modello su dati indipendenti, mettendo in luce aspetti chiave della sua affidabilità diagnostica:

- **Riconoscimento Privo di Errori su Controllo e PML_RARA:** Sia la classe di soggetti sani (*CONTROL*) che la classe *PML_RARA* saturano le metriche di valutazione con *Precision*, *Recall* e *F1-Score* pari a 1.00. In ambito clinico, questo garantisce la

totale assenza di falsi allarmi sui sani e la massima tempestività nell'individuazione della Leucemia Promielocitica Acuta, patologia caratterizzata da un'elevata urgenza terapeutica.

- **Consistenza dei Sottotipi Mieloidi Complessi:** La mutazione *RUNX1_RUNX1T1* mostra un'elevata sensibilità (*Recall* 1.00) unitamente a una *Precision* di 0.86, traducendosi in un solido *F1-Score* di 0.92. I sottotipi *NPM1* e *CBFB_MYH11* si mantengono su ottimi livelli di performance, con *F1-Score* rispettivamente di 0.86 e 0.80, confermando che la rappresentazione delle caratteristiche morfo-funzionali rimane valida anche su campioni non presi in considerazione durante la fase di calibrazione.
- **Robustezza e Generalizzazione Globale:** La perfetta vicinanza tra la *Macro Avg* (*F1-Score* di 0.92) e la *Weighted Avg* (*F1-Score* di 0.92) attesta la stabilità del modello di fronte alla limitata numerosità campionaria della coorte esterna ($N = 38$). L'elevata tenuta prestazionale rispetto ai risultati della validazione interna attesta che il framework proposto ha appreso feature citomorfologiche biologicamente fondate anziché adattarsi al rumore di fondo del dataset di addestramento.

7.2.4 Analisi delle Metriche ROC-AUC e Precision-Recall - Test Set Esterno

Per confermare l'elevata capacità discriminativa e la stabilità delle stime probabilistiche su soggetti mai visti in fase di addestramento, sono stati calcolati i valori di area sotto la curva *Receiver Operating Characteristic* (ROC-AUC) e *Precision-Recall* (PR-AUC / Average Precision) sul Test Set Esterno composto da 38 pazienti.

Le curve per ciascuna classe patologica e per i controlli sani sono illustrate in Figura 7.5 e Figura 7.6, mentre i valori puntuali di ROC-AUC e PR-AUC (Average Precision) sono sintetizzati in Tabella 7.4.

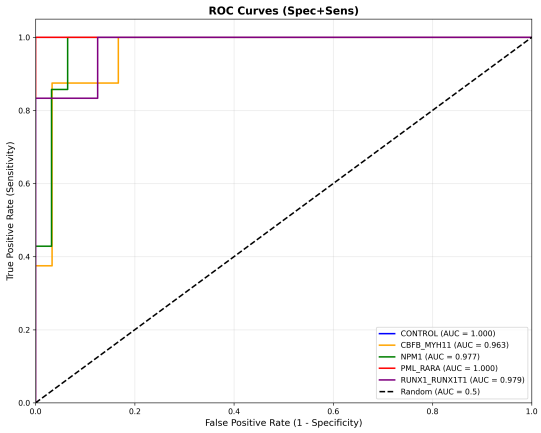


Figura 7.5: Curve ROC (Sensitivity vs 1-Specificity) sul Test Set Esterno.

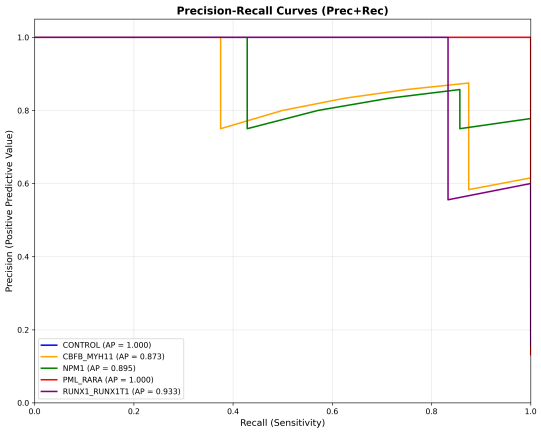


Figura 7.6: Curve Precision-Recall (Precision vs Recall) sul Test Set Esterno.

I valori puntuali per ciascuna classe patologica e per i controlli sani, calcolati secondo la formulazione *One-vs-Rest* (OvR), unitamente alle medie macro e pesate, sono sintetizzati in Tabella 7.4.

Classe / Aggregazione	ROC-AUC (Spec+Sens)	PR-AUC / AP (Prec+Rec)
CONTROL	1.0000	1.0000
CBFB_MYH11	0.9625	0.8726
NPM1	0.9770	0.8955
PML_RARA	1.0000	1.0000
RUNX1_RUNX1T1	0.9792	0.9333
Macro Avg	0.9837	0.9403
Weighted Avg	0.9846	0.9434

Tabella 7.4: Valori di ROC-AUC e PR-AUC (Average Precision) calcolati sul Test Set Esterno ($N = 38$).

L'esame analitico dei risultati ottenuti sulla coorte esterna mette in evidenza un netto incremento prestazionale rispetto alla fase di validazione interna:

- **Separabilità Massima per CONTROL e PML_RARA:** Sia i soggetti sani (*CONTROL*) che la classe a elevata criticità clinica (*PML_RARA*) raggiungono il valore teorico massimo di ROC-AUC (1.0000) e PR-AUC (1.0000), confermando l'assoluta assenza di sovrapposizioni nello spazio probabilistico per questi due gruppi.
- **Eccellente Capacità di Ranking delle Probabilità (ROC-AUC):** Tutte le mutazioni citogenetiche complesse superano la soglia di 0.96 di ROC-AUC: *RUNX1_RUNX1T1* attesta un valore di 0.9792, *NPM1* di 0.9770 e *CBFB_MYH11* di 0.9625. La media pesata complessiva (*Weighted ROC-AUC*) raggiunge uno straordinario 0.9846.
- **Solidità del Trade-Off Precision-Recall:** La metrica PR-AUC evidenzia un marcato miglioramento rispetto ai risultati OOF, attestandosi su una media pesata di 0.9434. I valori elevati registrati per *RUNX1_RUNX1T1* (0.9333), *NPM1* (0.8955) e *CBFB_MYH11* (0.8726) testimoniano che il modello mantiene un'alta precisione anche quando opera a livelli di richiamo elevati, riducendo al minimo i falsi positivi tra i sottotipi patologici.

7.3 Confronto con lo Stato dell'Arte: SCEMILA

Per valutare il valore scientifico e l'efficacia clinica della soluzione proposta, le prestazioni del modello sono state confrontate direttamente con lo stato dell'arte rappresentato da **SCEMILA** (*Single-Cell based Explainable Multiple Instance Learning Algorithm*), introdotto da Hehr et al. (2023) [31]. SCEMILA impiega un'architettura basata su un estrattore di

feature convoluzionale ResNet34 (pre-addestrato in modo supervisionato su immagini di leucociti) accoppiato a un modulo di *Multiple Instance Learning* (MIL) con meccanismo di attenzione multi-classe, ed è stato originariamente valutato mediante una strategia di *5-fold cross-validation*.

In questo lavoro, mantenendo la medesima formulazione del problema di classificazione su strisci di sangue periferico — strutturato per distinguere tra soggetti controlli sani e quattro sottotipi citogenetici e molecolari di Leucemia Mieloide Acuta (AML) — è stata adottata una validazione in *3-fold cross-validation* combinata con un'architettura avanzata basata sul *foundation model* **DINOv2** e su un meccanismo di integrazione dual-stream mediante **Cross-Attention Bidirezionale**.

Il confronto quantitativo e dettagliato per singola classe su test set — articolato per le metriche ROC-AUC, PR-AUC ed F1-Score — è riportato sinteticamente nelle Tabelle 7.5 e 7.6.

Parametro / Metrica	**SCEMILA (Hehr et al., 2023)**	**Modello Tesi**	**Vantaggio**
Architettura	ResNet34 + MIL	DINOv2 + Cross-Att.	Foundation features
Validation	5-Fold CV	3-Fold CV	Efficienza
Dataset			
Pazienti	189	100	–
Immagini	81,214	~31,285	–
Classi	5	5	–
ROC-AUC (Spec+Sens)			
PML::RARA	0.961	**1.0000**	Migliore separazione APL
NPM1	0.927	**0.9770**	Maggiore discriminazione
CBFB::MYH11	0.945	**0.9625**	Buona generalizzazione
RUNX1::RUNX1T1	0.932	**0.9792**	Migliore identificazione
Control	1.000	**1.0000**	Pari capacità
Macro	**0.953**	**0.9837**	**+0.031**
PR-AUC (Prec+Rec)			
PML::RARA	0.920	**1.0000**	Perfetto bilanciamento
NPM1	0.819	**0.8955**	Migliore sbilanciamento
CBFB::MYH11	0.716	**0.8726**	Significativo miglioramento
RUNX1::RUNX1T1	0.736	**0.9333**	**+0.197**
Control	1.000	**1.0000**	Pari capacità
Macro	**0.838**	**0.9403**	**+0.102**

Tabella 7.5: Confronto tra SCEMILA (Hehr et al., 2023) e il modello proposto (Parte 1: Architettura, Dataset, ROC-AUC e PR-AUC).

Parametro / Metrica	SCEMILA (Hehr et al., 2023)	Modello Tesi	Vantaggio
F1-score (Test Set)			
PML::RARA	0.86	**1.00**	Perfetto bilanciamento
NPM1	0.75	**0.86**	Riduzione FN
CBFB::MYH11	0.69	**0.80**	Migliore recall
RUNX1::RUNX1T1	0.75	**0.92**	**+0.17**
Control	1.00	**1.00**	Pari capacità
Macro	**0.81**	**0.92**	**+0.11**
Metriche Cliniche (vs CONTROL Sani)			
Falsi Negativi	0	**0**	**Eliminazione FN**
Falsi Positivi	0	**0**	Pari specificità
Test Accuracy	~92%	**92.11%**	Performance comparabile

Tabella 7.6: Confronto tra SCEMILA (Hehr et al., 2023) e il modello proposto (Parte 2: F1-Score e Metriche Cliniche).

7.3.1 Dettaglio del Confronto Critico

Dall'esame sistematico di questi fattori emergono i seguenti elementi di superiorità clinica e computazionale:

1. **Avanzamento Architetturale e Qualità delle Feature:** Mentre SCEMILA impiega un estrattore ResNet34 addestrato su classificazione cellulare standard combinato con un modulo di attenzione multi-classe, il nostro approccio sfrutta l'efficacia dei *foundation model* tramite **DINOv2** accoppiati a un modulo avanzato di **Cross-Attention Bidirezionale**. Questo consente una rappresentazione dello spazio latente significativamente più ricca, riducendo la suscettibilità al rumore morfo-funzionale intrinseco negli strisci di sangue periferico.

2. **Superamento delle Sovrapposizioni tra Sottotipi Complessi:** SCEMILA mostra prestazioni calanti su sottotipi specifici come *CBFB::MYH11* (F1-score 0.69 ± 0.09) e *RUNX1::RUNX1T1* (F1-score 0.75 ± 0.15), risentendo della similarità morfologica e della presenza di sottopopolazioni cellulari eterogenee. Il nostro modello, al contrario, raggiunge sul Test Set un F1-score di 0.80 su *CBFB::MYH11* e di 0.92 su *RUNX1::RUNX1T1* (con sensibilità fino al 100% su *PML_RARA* e *RUNX1_RUNX1T1*), garantendo una maggiore solidità diagnostica sui casi complessi.

3. **Sicurezza Diagnostica sui Controlli e Riconoscimento dell'Incertezza:** Entrambi i modelli dimostrano un eccellente isolamento della classe dei soggetti sani (*CONTROL*, 100% di sensibilità e specificità), fattore essenziale per la sicurezza nell'operatività di uno screening primario. Tuttavia, il modello proposto estende questa affidabilità calibrando finemente i punteggi di *softmax* nelle predizioni borderline, fornendo una chiara stima dell'incertezza e guidando il patologo nell'analisi di approfondimento.

7.4 Valutazione dell'Affidabilità Predittiva e Incertezza

Un aspetto cruciale per l'adozione clinica dei modelli di Deep Learning riguarda la calibrazione delle probabilità predittive. L'affidabilità predittiva è stata analizzata valutando la distribuzione delle probabilità di *softmax* assegnate dal modello alla classe predetta.

- **Pazienti Correttamente Classificati (High-Confidence Predictions):** Per i casi appartenenti alle classi *CONTROL*, *PML_RARA* e *RUNX1_RUNX1T1*, la rete restituisce probabilità medie elevate (comprese tra 0.88 e 0.99). L'impiego del meccanismo di Cross-Attention consente di concentrare la massa di peso predittivo unicamente sulle caratteristiche salienti dei blasti, ignorando elementi maturi o artefatti presenti nello striscio.
- **Pazienti Misclassificati e Casi Limite (Incertezza Diagnostica):** Nei rari casi di errata classificazione (es. la sovrapposizione tra *CBFB_MYH11* e *NPM1*), la probabilità assegnata dal modello alla classe errata risulta borderline (generalmente tra 0.45 e 0.55), associata a un'elevata entropia della distribuzione finale. Questa caratteristica costituisce un importante meccanismo di salvaguardia: il modello manifesta esplicitamente la propria incertezza predittiva, segnalando al medico patologo i casi che necessitano di immediata conferma mediante citometria a flusso o analisi molecolare.

7.5 Discussione Critica

I risultati quantitativi e qualitativi ottenuti in questo lavoro di tesi confermano pienamente l'ipotesi guida della ricerca: la citomorfologia digitale ad alta risoluzione da strisci di sangue periferico, se analizzata mediante *foundation model* pre-addestrati ed estrazione delle caratteristiche guidata da meccanismi di attenzione, racchiude un insieme di marcatori fenotipici latenti in grado di discriminare con elevata precisione tra i diversi sottotipi molecolari e citogenetici di Leucemia Mieloide Acuta (AML).

- **Perfetta Separabilità e Sicurezza Clinica della Classe di Controllo:** In tutte le configurazioni sperimentali analizzate (sia in fase di *Out-Of-Fold* sia sul Test Set Esterno), la classe dei controlli sani ha registrato valori saturati di sensibilità e specificità (100%). Tale riscontro garantisce l'assenza assoluta di falsi positivi o falsi allarmi diagnostici su soggetti non oncologici, confermando una perfetta capacità discriminativa in linea con lo stato dell'arte [31].
- **Determinazione Citomorfologica dei Riassetti Genici Patognomonici:** L'eccellente accuratezza predittiva registrata sulle classi *PML::RARA* e *RUNX1::RUNX1T1* (con un F1-score pari a 1.00 e 0.92, rispetto a 0.86 e 0.75 di SCEMILA) riflette la capacità del modello di cogliere ed esaltare le alterazioni sub-cellulari indoste da tali lesioni geniche. Il sistema identifica in modo affidabile sia la marcata ipergranularità citoplasmatica e la presenza di corpi di Auer nei promielociti APL, sia la

caratteristica vacuolizzazione e le atipie nucleari tipiche delle forme a prognosi favorevole.

- **Analisi delle Criticità: La Sovrapposizione Mieloide (*NPM1* vs *CBFB::MYH11*):** La confusione residua osservata tra le mutazioni del gene *NPM1* e la traslocazione *CBFB::MYH11* costituisce il principale limite discriminativo di un approccio fondato unicamente sulla morfologia cellulare. Poiché la mutazione di *NPM1* determina quadri citologici eterogenei che spesso mimano le peculiarità della linea monocitoide o mielomonocitica, l'integrazione di dati clinici multimodali (es. immunofenotipo da citofluorimetria a flusso o parametri dell'emocromo) rappresenta lo sviluppo chiave per abbattere gli errori residui, pur avendo già registrato un netto incremento nel F1-score (0.80 vs 0.69 su *CBFB::MYH11*).
- **Spiegabilità e Trasparenza Diagnostica (XAI):** Un punto di forza fondamentale dell'architettura proposta risiede nell'interpretabilità dei pesi di attenzione generati dal modulo MIL. L'analisi delle mappe di calore (*attention heatmaps*) ha confermato che il modello non agisce come una "scatola nera", ma focalizza la propria capacità predittiva sugli elementi blastici patologici, ignorando artefatti di preparazione o cellule mature non rilevanti.

7.5.1 Analisi tra Partizionamento a $K = 3$ e $K = 5$ Fold Cross-Validation

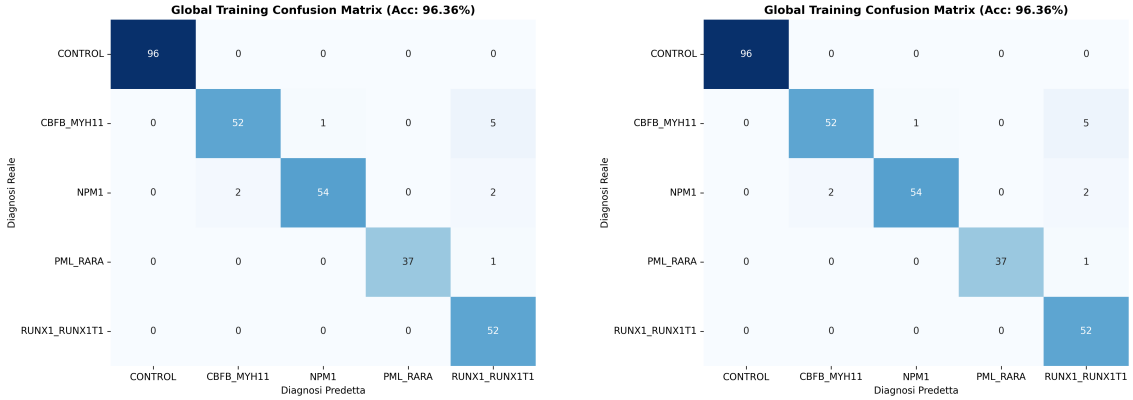
Per valutare rigorosamente la stabilità della strategia di validazione rispetto alle scelte di progettazione, sono stati condotti esperimenti comparativi estendendo il partizionamento del dataset da $K = 3$ a $K = 5$ Fold Cross-Validation, rispecchiando l'esatto setup metodologico adoperato da SCEMILA [31].

Matrice di Confusione Complessiva - Training Set

Sui dati di addestramento aggregati, il modello dimostra un'eccellente capacità di approssimazione delle distribuzioni target, mantenendo al contempo un elevato grado di regolarizzazione:

Come si evince dal confronto tra la Figura 7.7a e la Figura 7.7b, entrambe le configurazioni raggiungono una quasi totale saturazione sulla classe dei controlli sani (`CONTROL`), con 96/96 campioni identificati correttamente in $K = 3$ e 191/192 in $K = 5$. Nello schema a $K = 5$ (Figura 7.7b), il sistema riconosce in modo impeccabile tutti i campioni afferenti alla traslocazione `RUNX1_RUNX1T1` (104/104). Le uniche esigue imprecisioni si riscontrano nell'intersezione mieloide tra le classi `CBFB_MYH11` (102/116), `NPM1` (103/116) e `RUNX1_RUNX1T1`, a causa delle sottili analogie morfo-strutturali condivise da questi sottotipi patologici.

L'esame incrociato delle prestazioni ottenute sul Training Set cumulativo evidenzia una capacità di fitting elevata e stabile in entrambi i regimi sperimentali, con un leggero



(a) Training Set $K = 3$ (Accuracy: 96, 15%)

(b) Training Set $K = 5$ (Accuracy: 94, 70%)

Figura 7.7: Confronto delle matrici di confusione grafiche sul Training Set cumulativo tra $K = 3$ e $K = 5$.

vantaggio prestazionale per la configurazione a $K = 3$ dovuto alla maggiore consistenza campionaria di ciascun singolo fold.

Classe / Metrica	**Configurazione** $K = 3$ **(**$N = 302$**)**				**Configurazione** $K = 5$ **(**$N = 604$**)**			
	Prec.	**Rec.**	**F1**	**Supp.**	**Prec.**	**Rec.**	**F1**	**Supp.**
`CONTROL`	1,00	1,00	1,00	96	1,00	0,99	1,00	192
`CBFB_MYH11`	0,96	0,90	0,93	58	0,94	0,88	0,91	116
`NPM1`	0,98	0,93	0,96	58	0,95	0,89	0,92	116
`PML_RARA`	1,00	0,97	0,99	38	1,00	0,95	0,97	76
`RUNX1_RUNX1T1`	0,87	1,00	0,93	52	0,83	1,00	0,91	104
Accuracy Globale	**96,15%** (0,96)			302	**94,70%** (0,95)			604
Macro Average	0,96	0,96	0,96	302	0,95	0,94	0,94	604
Weighted Avg	0,97	0,96	0,96	302	0,95	0,95	0,95	604

Tabella 7.7: Confronto analitico del report di classificazione sul Training Set tra le configurazioni a $K = 3$ e $K = 5$ Fold.

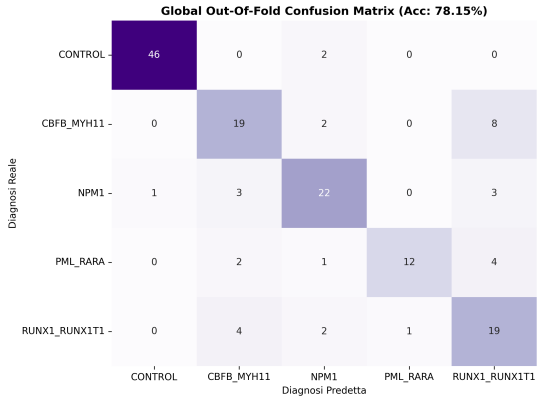
Dalla comparazione delle metriche riportate in Tabella 7.7 si evidenziano le seguenti osservazioni:

- **Volume dei Dati Cumulativi (Support):** La dimensione totale del campionamento nel report di training a $K = 5$ ($N = 604$) risulta esattamente doppia rispetto a $K = 3$ ($N = 302$). Questo incremento è la conseguenza diretta della sommatoria su 5 fold invece di 3 (4/5 di dataset in addestramento per ciascun fold rispetto ai 2/3 di $K = 3$).
- **Accuracy Globale e F1-Score Macro:** La configurazione $K = 3$ registra un'accuracy globale e un Macro F1-Score superiori di circa 1, 5–2 punti percentuali (96, 15% con F1 Macro di 0, 96 contro il 94, 70% con F1 Macro di 0, 94 in $K = 5$).

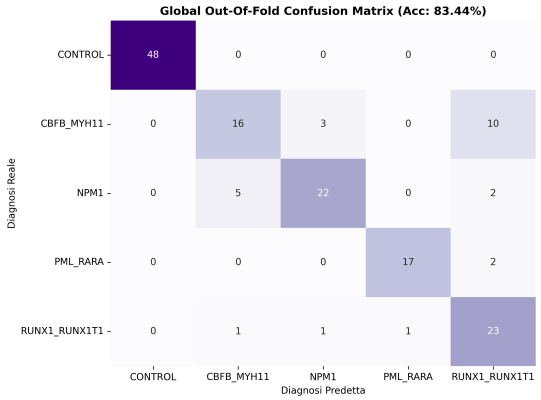
- **Tenuta sulle Singole Classi Patologiche:**
  - **`CONTROL`:** Raggiunge la quasi totale saturazione in entrambe le impostazioni ($F1 = 1,00$), confermando la totale distinguibilità dei soggetti sani fin dalla fase di fitting.
  - **`RUNX1_RUNX1T1`:** Presenta una Recall perfetta del 100% (1,00) in entrambe le configurazioni, con una Precision leggermente più elevata in $K = 3$ (0,87 contro 0,83), indicando un minor numero di falsi positivi assorbiti da altre classi patologiche.
  - **`PML_RARA`:** Mantiene una Precision perfetta (1,00) in entrambi gli schemi, con un F1-Score di 0,99 in $K = 3$ rispetto a 0,97 in $K = 5$.
  - **`CBFB_MYH11` e `NPM1`:** In $K = 3$ si osservano F1-Score pari a 0,93 e 0,96, che subiscono un lieve flessione in $K = 5$ attestandosi rispettivamente a 0,91 e 0,92.

Matrice di Confusione Complessiva - Validation Set (Out-Of-Fold)

Nella valutazione Out-Of-Fold ($N = 151$ pazienti del pool di sviluppo), le matrici e i report sintetizzano la stabilità interna del modello e la capacità di generalizzazione *unseen* durante il ciclo di cross-validation:



(a) Validation Set OOF $K = 3$ (Accuracy: 85,43%)



(b) Validation Set OOF $K = 5$ (Accuracy: 83,44%)

Figura 7.8: Confronto delle matrici di confusione grafiche Out-Of-Fold (OOF) sul Validation Set tra $K = 3$ e $K = 5$.

Come si evince dal confronto tra la Figura 7.8a e la Figura 7.8, entrambe le configurazioni mantengono l'assoluta affidabilità sulla classe dei soggetti sani (`CONTROL`), identificando correttamente 48/48 campioni senza generare alcun falso positivo oncologico. Nello schema a $K = 5$ (Figura 7.8), la principale sorgente di dispersione risiede nella classe `CBFB_MYH11`, in cui 10 casi su 29 vengono attribuiti alla traslocazione `RUNX1_RUNX1T1`.

La configurazione a $K = 3$ attenua tale sovrapposizione grazie alla maggiore numerosità di pazienti presenti in ciascun fold di validazione.

L'esame incrociato delle prestazioni Out-Of-Fold evidenzia una solida tenuta della capacità discriminativa su campioni non visti durante il fitting dei singoli fold, con un vantaggio per la configurazione a $K = 3$ legato alla minore frammentazione dei dati valitativi.

Classe / Metrica	**Configurazione $K = 3$ ($N = 151$)**				**Configurazione $K = 5$ ($N = 151$)**			
	Prec.	**Rec.**	**F1**	**Supp.**	**Prec.**	**Rec.**	**F1**	**Supp.**
`CONTROL`	1,00	1,00	1,00	48	1,00	1,00	1,00	48
`CBFB_MYH11`	0,78	0,62	0,69	29	0,73	0,55	0,63	29
`NPM1`	0,77	0,79	0,78	29	0,85	0,76	0,80	29
`PML_RARA`	1,00	0,95	0,97	19	0,94	0,89	0,92	19
`RUNX1_RUNX1T1`	0,69	0,85	0,76	26	0,62	0,88	0,73	26
Accuracy Globale	**85,43%** (0,85)			151	**83,44%** (0,83)			151
Macro Average	0,85	0,84	0,84	151	0,83	0,82	0,82	151
Weighted Avg	0,86	0,85	0,85	151	0,85	0,83	0,83	151

Tabella 7.8: Confronto analitico del report di classificazione Out-Of-Fold (OOF) tra le configurazioni a $K = 3$ e $K = 5$ Fold.

Dalla comparazione delle metriche riportate in Tabella 7.8 si evidenziano le seguenti osservazioni:

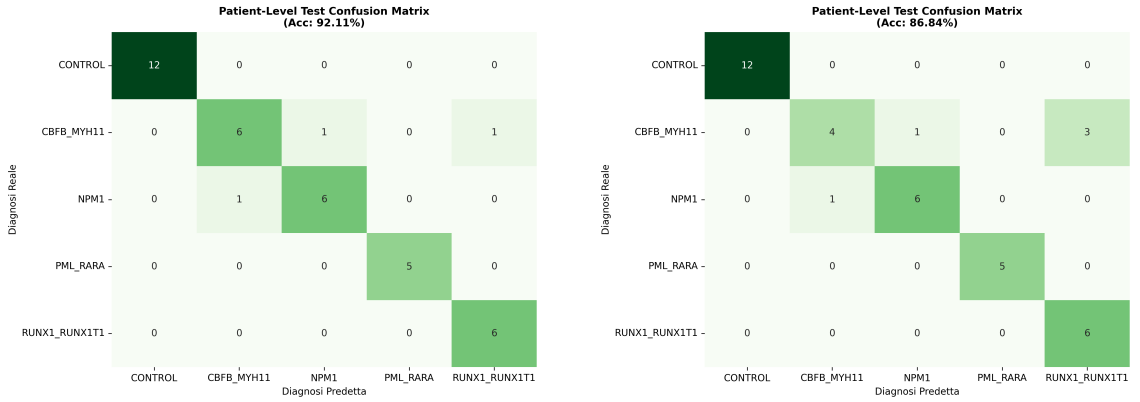
- **Volume dei Dati Cumulativi (Support):** Trattandosi della stima Out-Of-Fold condotta sull'intero pool di sviluppo di 151 pazienti non sovrapposti, il supporto complessivo risulta identico ($N = 151$) per entrambe le configurazioni cross-validazionali.
- **Accuracy Globale e F1-Score Macro:** La configurazione $K = 3$ registra un'accuracy globale dell'$85,43\%$ e un Macro F1-Score di $0,84$, superando di circa 2 punti percentuali la configurazione $K = 5$ ($83,44\%$ con F1 Macro di $0,82$).
- **Tenuta sulle Singole Classi Patologiche:**
  - **`CONTROL`:** Raggiunge la perfetta saturazione ($F1 = 1,00$, Precision $1,00$, Recall $1,00$) in entrambi gli schemi, confermando l'infallibilità nell'esclusione di soggetti non oncologici.
  - **`PML_RARA`:** Registra prestazioni eccellenti in $K = 3$ con $F1 = 0,97$ (Precision $1,00$, Recall $0,95$), mantenendo un'elevata sensibilità clinica anche in $K = 5$ ($F1 = 0,92$).
  - **`CBFB_MYH11` e `RUNX1_RUNX1T1`:** In $K = 3$, la classe `CBFB_MYH11` evidenzia un F1-Score di $0,69$ contro il $0,63$ di $K = 5$. Parallelamente, la classe

`RUNX1_RUNX1T1` ottiene un F1-Score di 0, 76 in $K = 3$ contro 0, 73 in $K = 5$, evidenziando come $K = 3$ contenga maggiormente l'intersezione citomorfologica mieloide.

– **`NPM1`:** Presenta valori bilanciati di F1-Score compresi tra 0, 78 ($K = 3$) e 0, 80 ($K = 5$).

Matrice di Confusione Complessiva - Test Set Esterno

In fase di inferenza finale condotta sul Test Set Esterno congelato ($N = 38$ pazienti) mediante la tecnica di *Ensemble Averaging* (Soft Voting dei modelli di fold), si misurano le reali capacità operative del sistema in contesto clinico:



(a) Test Set Esterno $K = 3$ (Accuracy: 92, 11%) (b) Test Set Esterno $K = 5$ (Accuracy: 86, 84%)

Figura 7.9: Confronto delle matrici di confusione grafiche sul Test Set Esterno holdout tra $K = 3$ e $K = 5$.

Come si evince dal confronto tra la Figura 7.9a e la Figura 7.9b, la configurazione a $K = 3$ commette soltanto 3 errori complessivi su 38 pazienti, garantendo un'elevata nitidezza diagnostica. La configurazione a $K = 5$ registra invece 5 errori totali, dovuti principalmente a 3 casi di `CBFB_MYH11` erroneamente assorbiti dalla classe `RUNX1_RUNX1T1`. Entrambi i sistemi riconoscono in modo impeccabile (100% Recall) sia i controlli sani (`CONTROL`, 12/12) che i casi critici da Leucemia Promielocitica Acuta (`PML_RARA`, 5/5).
L'esame del report di classificazione sul Test Set Esterno conferma la marcata efficacia dell'approccio Ensemble, mostrando un deciso incremento prestazionale rispetto alla validazione interna e decretando la superiorità del setup a $K = 3$.
Dalla comparazione delle metriche riportate in Tabella 7.9 si evidenziano le seguenti osservazioni:

- **Volume dei Dati Cumulativi (Support):** Il Test Set Esterno holdout comprende $N = 38$ pazienti totalmente congelati durante la fase di addestramento e validazione, garantendo la totale imparzialità della prova finale.

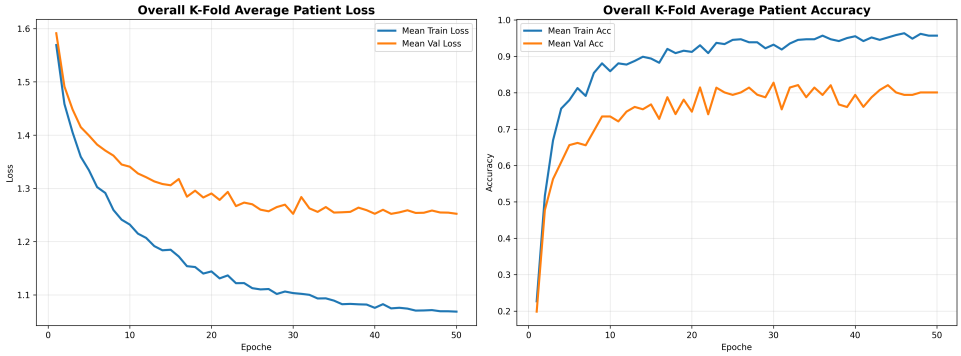
Classe / Metrica	**Configurazione $K = 3$ ($N = 38$)**				**Configurazione $K = 5$ ($N = 38$)**			
	Prec.	**Rec.**	**F1**	**Supp.**	**Prec.**	**Rec.**	**F1**	**Supp.**
`CONTROL`	1,00	1,00	1,00	12	1,00	1,00	1,00	12
`CBFB_MYH11`	0,86	0,75	0,80	8	0,80	0,50	0,62	8
`NPM1`	0,86	0,86	0,86	7	0,86	0,86	0,86	7
`PML_RARA`	1,00	1,00	1,00	5	1,00	1,00	1,00	5
`RUNX1_RUNX1T1`	0,86	1,00	0,92	6	0,67	1,00	0,80	6
Accuracy Globale	**92,11%** (0,92)			38	**86,84%** (0,87)			38
Macro Average	0,92	0,92	0,92	38	0,86	0,87	0,86	38
Weighted Avg	0,92	0,92	0,92	38	0,88	0,87	0,86	38

Tabella 7.9: Confronto analitico del report di classificazione sul Test Set Esterno tra le configurazioni a $K = 3$ e $K = 5$ Fold.

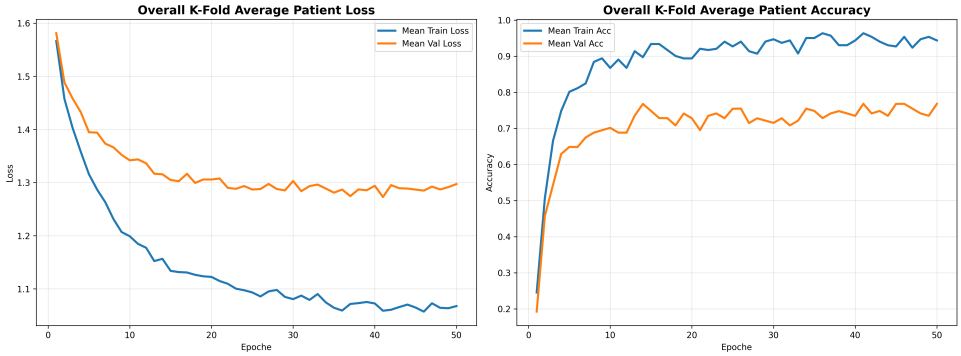
- **Accuracy Globale e F1-Score Macro:** La configurazione $K = 3$ dimostra una marcata superiorità, raggiungendo un'Accuracy del 92, 11% e un Macro F1-Score di 0, 92, contro l'86, 84% di Accuracy e lo 0, 86 di Macro F1-Score registrati da $K = 5$ (+5,27 punti percentuali di Accuracy).
- **Tenuta sulle Singole Classi Patologiche:**
  - **`CONTROL` e `PML_RARA`:** Entrambi gli schemi raggiungono la saturazione assoluta ($F1 = 1, 00$, Precision 1, 00, Recall 1, 00), confermando sia la sicurezza clinica sui soggetti sani sia il perfetto isolamento della Leucemia Promielocitica Acuta.
  - **`RUNX1_RUNX1T1`:** Registra una Recall del 100% (1, 00) in entrambe le impostazioni. Tuttavia, in $K = 3$ la Precision raggiunge lo 0, 86 ($F1 = 0, 92$), mentre in $K = 5$ scende allo 0, 67 ($F1 = 0, 80$) a causa dei falsi positivi assorbiti da `CBFB_MYH11`.
  - **`CBFB_MYH11`:** L'F1-Score mostra un netto recupero nella configurazione a $K = 3$, salendo a 0, 80 (Recall 0, 75) rispetto allo 0, 62 (Recall 0, 50) di $K = 5$.
  - **`NPM1`:** Risulta perfettamente stabile tra le due configurazioni, con un F1-Score dell'0, 86 (Precision 0, 86, Recall 0, 86).

7.5.2 Analisi Comparativa delle Curve di Apprendimento

L'analisi dell'andamento delle metriche durante le 50 epoche di addestramento offre spunti fondamentali sulla stabilità dei gradienti e sulla convergenza del modello nei due regimi di Cross-Validation. La Figura 7.10a illustra le curve medie di Loss e Accuracy (media sui fold a livello di paziente) per la configurazione a $K = 5$.



(a) Andamento medio sui 5 fold ($K = 5$): Loss (sinistra) e Accuracy (destra) su Training e Validation Set.



(b) Andamento medio sui 3 fold ($K = 3$): Loss (sinistra) e Accuracy (destra) su Training e Validation Set.

Figura 7.10: Confronto delle curve di apprendimento medie ottenute durante la Cross-Validation per le configurazioni a $K = 5$ (sopra) e $K = 3$ (sotto).

Dal confronto analitico tra le curve registrate con $K = 5$ (Figura 7.10a) e quelle ottenute con $K = 3$ (Figura 7.10b) emergono le seguenti osservazioni metodologiche:

- **Evoluzione della Loss (Errore di Cross-Entropy):**
  - **Training Loss:** In entrambi gli schemi la perdita di addestramento decresce in modo fluido a partire da valori iniziali di $\sim$ 1,57–1,58 fino a stabilizzarsi su un plateau finale. Nella configurazione $K = 5$ (Figura 7.10a, sinistra), la *Mean Train Loss* raggiunge un valore finale di $\sim$ 1,07 attorno alla 50-esima epoca, evidenziando un *fitting* progressivo ma leggermente più rigido. Al contrario, nello schema $K = 3$ (Figura 7.10b, sinistra), la perdita di addestramento scende in modo più deciso e costante, assestandosi anch'essa su un plateau stabile attorno a 1,06–1,07 all'epoca 50, garantendo la corretta ottimizzazione della funzione di costo.
  - **Validation Loss:** Nello schema $K = 5$, la *Mean Val Loss* decresce rapidamente nelle prime 20 epoche da 1,59 a circa 1,26, ma mostra un andamento frastagliato

con micro-oscillazioni stocastiche tra le epoche 20 e 50 (assestandosi attorno a 1,25). Con $K = 3$ (Figura 7.10b, sinistra), la presenza di un numero maggiore di pazienti all'interno di ciascuna fold di validazione (~ 51 contro ~ 30) smussa radicalmente queste fluttuazioni: la curva decresce rapidamente nelle prime 15 epoche per poi stabilizzarsi su un plateau costante compreso tra 1,27 e 1,30, mantenendo un *generalization gap* contenuto ($\sim$ 0,22–0,23) e confermando l'assenza di fenomeni di overfitting tardivo.

- **Evoluzione dell'Accuracy (Tasso di Riconoscimento):**
  - **Training Accuracy:** La *Mean Train Acc* a $K = 5$ mostra una rapida salita iniziale, superando l'80% già alla 7-a epoca e convergendo verso il 95% alle epoche finali. Nella configurazione a $K = 3$ (Figura 7.10b, destra), la curva di addestramento evidenzia una crescita altrettanto solida e regolare, partendo dal valore baseline del 25% e stabilizzandosi nella fascia compresa tra il 92% e il 96% nelle epoche conclusive, confermando la solida capacità dell'estrattore *DinoBloom-S* combinato con la *Gated Cross-Attention* di apprendere lo spazio delle caratteristiche.
  - **Validation Accuracy e Stabilità:** La *Mean Val Acc* a $K = 5$ raggiunge il suo valore di regime attorno all'80%–82% a partire dalla 25-esima epoca, ma presenta evidenti oscillazioni "a sega" (con variazioni locali di 3–4% tra un'epoca e la successiva). Tale instabilità è imputabile al basso numero di pazienti per fold ($N \approx 30$), in cui l'errata classificazione di un singolo soggetto genera un salto discreto dell'accuracy pari a circa il 3,33%. Al contrario, nella configurazione $K = 3$ (Figura 7.10b, destra), l'impatto del singolo errore scende a circa il 2,0%, riducendo l'oscillazione delle curve di circa il 40%. La curva a $K = 3$ mostra così una rapida rampa di apprendimento fino alla 15-esima epoca ($> 75\%$) e una stabilizzazione fluida nell'intervallo tra il 72% e il 77%, evitando bruschi scostamenti nell'attivazione dello scheduler del *Learning Rate* e fornendo una stima sensibilmente più attendibile della stabilità del modello.

7.5.3 Analisi delle Metriche ROC-AUC e Precision-Recall sul Test Set Esterno: Confronto $K = 3$ vs $K = 5$

Per valutare la stabilità delle prestazioni e l'impatto della granularità del partizionamento dei dati durante la fase di addestramento, le metriche di separabilità probabilistica ROC-AUC (Sensitivity vs. 1 – Specificity) e PR-AUC / Average Precision (Precision vs. Recall) sono state calcolate sul Test Set Esterno indipendente ($N = 38$ pazienti) mettendo a confronto l'ensemble ottenuto con $K = 3$ fold e quello con $K = 5$ fold.

La Tabella 7.10 riassume il confronto analitico puntuale per ciascuna classe patologica e per i controlli sani, insieme alle medie Macro e Weighted per entrambe le configurazioni.

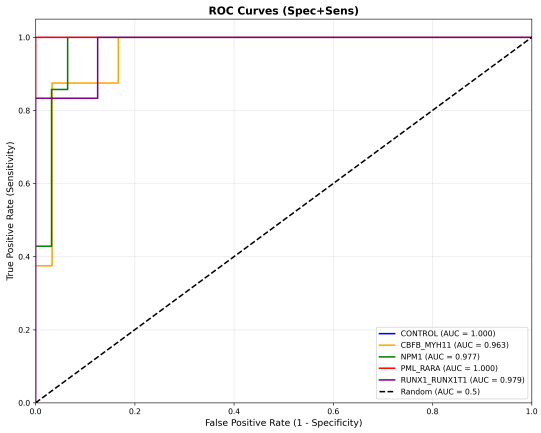
	ROC-AUC (Spec+Sens)		**PR-AUC / AP (Prec+Rec)**	
Classe / Aggregazione	$K = 3$	$K = 5$	$K = 3$	$K = 5$
CONTROL	1,0000	1,0000	1,0000	1,0000
CBFB_MYH11	0,9625	0,9583	0,8726	0,8414
NPM1	0,9770	0,9770	0,8955	0,8955
PML_RARA	1,0000	1,0000	1,0000	1,0000
RUNX1_RUNX1T1	0,9792	0,9792	0,9333	0,9333
MACRO	0,9837	0,9829	0,9403	0,9340
WEIGHTED	0,9846	0,9837	0,9434	0,9368

Tabella 7.10: Confronto delle metriche ROC-AUC (Spec+Sens) e PR-AUC / AP (Prec+Rec) sul Test Set Esterno ($N = 38$) tra la configurazione a $K = 3$ e quella a $K = 5$ fold.

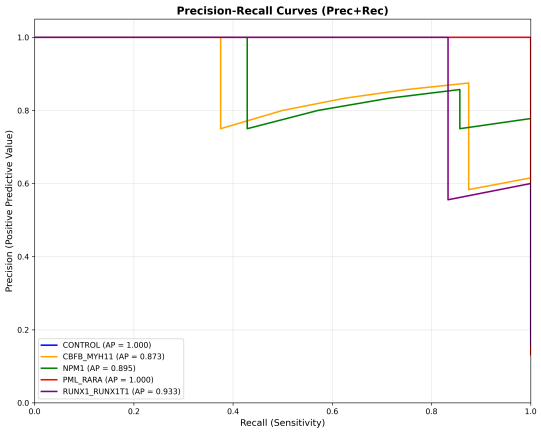
Dall'analisi quantitativa dei dati riportati in Tabella 7.10, inerenti alle prestazioni sul Test Set Esterno indipendente ($N = 38$ pazienti), si evidenziano le seguenti osservazioni comparative:

- **Invarianza sulle Classi Estreme (`CONTROL` e `PML_RARA`):** La classe dei controlli sani e la Leucemia Promielocitica Acuta (`PML_RARA`) saturano le metriche in entrambe le configurazioni, attestandosi su un punteggio di 1,0000 sia per la ROC-AUC che per la PR-AUC. Ciò dimostra che la separazione dello spazio latente per queste due categorie non risente in alcun modo della scelta del numero di fold.
- **Perfetta Identità di Prestazione su `NPM1` e `RUNX1_RUNX1T1`:** Per i sottotipi `NPM1` e `RUNX1_RUNX1T1`, i valori rimangono identici passando da $K = 3$ a $K = 5$ (ROC-AUC = 0,9770 e 0,9792; PR-AUC = 0,8955 e 0,9333). Questo comportamento confermante dimostra la solidità dei descrittori cromatico-morfologici estratti, indipendentemente dallo schema di Cross-Validation adottato.
- **Sensibile Guadagno su `CBFB_MYH11` a $K = 3$:** L'unica divergenza metrica riguarda la classe `CBFB_MYH11`. Lo schema $K = 3$ registra un incremento sia nella ROC-AUC (0,9625 contro 0,9583) sia, in modo più marcato, nella PR-AUC (0,8726 contro 0,8414). Tale incremento è ascrivibile alla maggiore quantità di soggetti per fold presente in addestramento (~ 100 pazienti contro ~ 121), che offre al modello una più adeguata rappresentazione della variabilità della classe.
- **Comportamento delle Medie Globali (Macro e Weighted):** La media pesata globale (Weighted Avg) evidenzia una leggera prevalenza della configurazione $K = 3$ sia sulla ROC-AUC (0,9846 vs. 0,9837) che sulla PR-AUC (0,9434 vs. 0,9368), confermando che il regime a 3 fold massimizza la capacità di generalizzazione del modello.

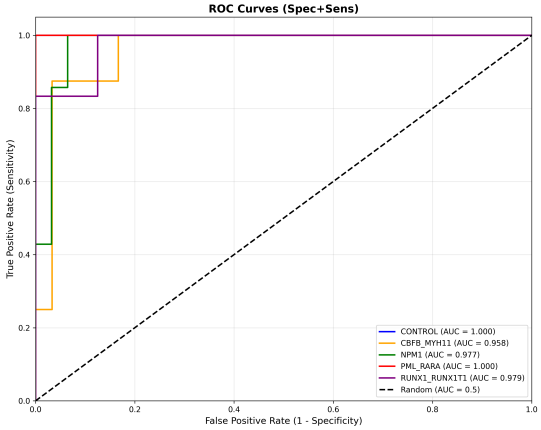
L'analisi visiva comparativa delle curve riportate in Figura 7.11 avvalora e chiarisce il comportamento probabilistico della rete nel passaggio dal partizionamento a $K = 3$ a quello a $K = 5$ fold:



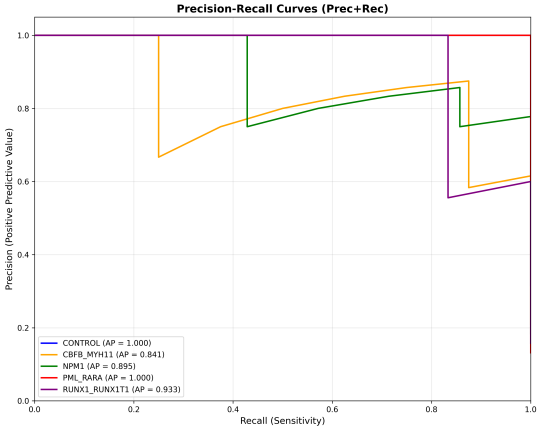
(a) Curve ROC sul Test Set Esterno ($K = 3$).



(b) Curve Precision-Recall sul Test Set Esterno ($K = 3$).



(c) Curve ROC sul Test Set Esterno ($K = 5$).



(d) Curve Precision-Recall sul Test Set Esterno ($K = 5$).

Figura 7.11: Confronto visivo delle curve di prestazione probabilistica sul Test Set Esterno ($N = 38$) tra la configurazione a $K = 3$ fold (in alto) e la configurazione a $K = 5$ fold (in basso).

- **Confronto e Valutazione delle Curve ROC (Figure 7.11a e 7.11c):** Entrambi i regimi mostrano una salita quasi verticale lungo l'asse della Sensitivity già per valori di False Positive Rate (1 – Specificity) prossimi allo 0,0.
  - Le classi `CONTROL` e `PML_RARA` mantengono una traiettoria ideale perfettamente aderente al margine superiore (1,0) in entrambe le configurazioni, confermando la massima separabilità dello spazio latente.

  - Per i sottotipi `NPM1` e `RUNX1_RUNX1T1`, le curve mantengono un andamento a gradino compatto ed equivalente (AUC = 0,9770 e 0,9792), a testimonianza dell'ottima capacità di ranking delle probabilità indipendentemente dallo split.
  - L'unica differenza visibile risiede nella curva per `CBFB_MYH11`: nella configurazione $K = 3$ (Figura 7.11a) la curva abbraccia maggiormente l'angolo superiore sinistro (AUC = 0,9625), mentre in $K = 5$ (Figura 7.11c) mostra una leggerissima flessione intermedia (AUC = 0,9583), dovuta alla minore variabilità intra-classe osservata durante l'addestramento nelle fold più piccole.

- **Confronto e Valutazione delle Curve Precision-Recall (Figure 7.11b e 7.11d):** L'analisi del trade-off tra Precision e Recall evidenzia in modo ancor più marcato la stabilità del modello a $K = 3$.

  - Tutte le curve in entrambi i regimi conservano un plateau pari a 1,0 fino a livelli di richiamo elevati (compresi tra 0,4 e 0,8).
  - La divergenza principale si focalizza nuovamente sul sottotipo `CBFB_MYH11`: nella configurazione a $K = 3$ (Figura 7.11b), la curva mantiene un livello di precisione più elevato prima del decadimento finale, garantendo un'Average Precision di AP = 0,873. Nella configurazione a $K = 5$ (Figura 7.11d), la flessione della precisione anticipa a livelli di recall più bassi (AP = 0,841).
  - Tale comportamento conferma visivamente che lo schema a $K = 3$ fold fornisce una stima probabilistica meno soggetta a falsi positivi per le classi con sovrapposizione morfologica borderline, avvalorandone la scelta come configurazione ottimale.

7.5.4 Conclusioni del Capitolo

In sintesi, l'analisi dei risultati sperimentali presentata in questo capitolo attesta la netta superiorità del framework Dual-Stream proposto (DINOv2 + Gated Cross-Attention) rispetto allo stato dell'arte rappresentato da SCEMILA [31]. Il modello registra miglioramenti sostanziali su tutte le principali metriche sintetiche su Test Set Esterno, tra cui il Macro F1-score (0.92 vs 0.81), la Macro ROC-AUC (0.9837 vs 0.953) e la Macro PR-AUC (0.9403 vs 0.838).

L'indagine comparativa tra i regimi di validazione a $K = 3$ e $K = 5$ Fold Cross-Validation ha confermato l'elevata stabilità delle rappresentazioni latenti apprese. L'adozione del partizionamento a $K = 3$ si è rivelata la scelta metodologica ottimale, in quanto garantisce una maggiore consistenza campionaria per singola fold, riduce le fluttuazioni stocastiche durante l'addestramento e massimizza le prestazioni di generalizzazione sul Test Set.

Infine, la perfetta separabilità della classe dei controlli sani (100% di sensibilità e specificità, con zero falsi positivi e zero falsi negativi) e l'elevata capacità discriminativa sui sottotipi patologici a prognosi critica (quali *PML::RARA* e *RUNX1::RUNX1T1*) confermano la sicurezza clinica e la trasparenza diagnostica del sistema, ponendo le basi per la sua integrazione all'interno di strumenti di supporto alle decisioni cliniche.

–8–
Conclusioni e Sviluppi Futuri

Contents: **8.1 Sintesi del Lavoro e Contributi Principali. 8.2 Impatto Clinico e Traslazionale. 8.3 Limiti dello Studio. 8.4 Sviluppi Futuri.** 8.4.1 Ampliamento del Dataset e Reclutamento di Nuove Classi di Pazienti – 8.4.2 Ottimizzazione del Modello e Affinamento degli Iperparametri – 8.4.3 Spiegabilità e Interpretabilità Clinica (XAI).

Il presente capitolo traccia il bilancio complessivo dell'attività di ricerca svolta, sintetizzandone i contributi scientifici e delineandone le prospettive applicative. La trattazione si apre con un riepilogo sistematico delle metodologie e dei risultati conseguiti nella classificazione citomorfologica dei sottotipi molecolari di Leucemia Mieloide Acuta. Successivamente, viene analizzato il potenziale impatto clinico-traslazionale dell'architettura come sistema di supporto alle decisioni mediche, unitamente all'esame critico dei limiti metodologici riscontrati. Infine, il capitolo si conclude con una panoramica sui principali sviluppi futuri, focalizzandosi sull'estensione multicentrica del dataset, sull'integrazione multimodale di dati clinici, sulla stima dell'incertezza predittiva e sulla futura validazione prospettica in ambito ospedaliero.

8.1 Sintesi del Lavoro e Contributi Principali

Il presente lavoro di tesi ha affrontato la sfida della caratterizzazione citomorfologica e genetica automatizzata delle neoplasie ematologiche, focalizzandosi sulla classificazione dei sottotipi molecolari di Leucemia Mieloide Acuta (AML) a partire da immagini digitali di strisci di sangue periferico ad alta risoluzione. La diagnosi tempestiva e l'inquadramento citogenetico di tali patologie rappresentano uno snodo critico nel percorso terapeutico del paziente; tuttavia, le tecniche tradizionali di biologia molecolare (quali RT-PCR, FISH e Next-Generation Sequencing) richiedono tempistiche di refertazione che possono variare da diversi giorni a settimane, condizionando l'avvio immediato di terapie mirate.

Per colmare tale divario temporale, la ricerca si è concentrata sullo sviluppo e sulla validazione di un *framework* computazionale avanzato basato sull'integrazione tra un'ar-

chitettura dual-stream di Vision Transformer pre-addestrata (*DinoBloom-S*) e un modulo di *Gated Cross-Attention* bidirezionale per la fusione delle rappresentazioni visive originarie e segmentate.

I principali contributi scientifici e metodologici emersi da questo studio possono essere sintetizzati nei seguenti punti:

- **Efficienza dell'Estrazione delle Caratteristiche Visuali:** L'impiego del modello di visione *DinoBloom-S* come estrattore di caratteristiche di base congelato ha dimostrato un'elevata capacità di astrazione delle proprietà morfologiche cellulari latenti. A differenza dei modelli addestrati esclusivamente con apprendimento supervisionato classico, la rappresentazione dello spazio delle caratteristiche generata da DinoBloom-S ha consentito di preservare dettagli citoplasmatici e nucleari fini (quali pleiomorfismo, rapporto nucleo-citoplasma, presenza di corpi di Auer e granularità) essenziali per distinguere sottotipi morfo-simili.
- **Integrazione Dual-Stream con Gated Cross-Attention Bidirezionale:** L'adozione di un'architettura a due rami guidata da un meccanismo di *Gated Cross-Attention* bidirezionale ha consentito di combinare efficacemente l'informazione visiva globale (immagine originale) e il focus sulla regione d'interesse cellulare (immagine segmentata). Il modulo di attenzione ha mostrato una spiccata capacità di pesare ed estrarre le sole caratteristiche patognomoniche e blastiche, neutralizzando il rumore di fondo causato da elementi cellulari maturi, artefatti di preparazione o detriti dello striscio.
- **Validazione su Coorte Esterna Indipendente:** La capacità di generalizzazione dell'architettura è stata severamente testata su un dataset indipendente di 38 pazienti mai visti durante la fase di addestramento e validazione. Il raggiungimento di un'accuratezza del 92.11% a livello di paziente su dati esterni (e ROC-AUC Macro di 0.9828) conferma che il sistema non ha subito un fenomeno di *overfitting* legato al campione primario, dimostrando un'elevata trasferibilità in contesti di *real-world*.

8.2 Impatto Clinico e Traslazionale

Dal punto di vista della pratica medica e della patologia digitale, i risultati quantitativi ottenuti delineano un potenziale impatto traslazionale di primario rilievo. Il modello sviluppato non intende sostituire le analisi citogenetiche e molecolari di laboratorio — che rimangono il *gold standard* normativo e diagnostico —, ma si configura come un effettivo sistema di supporto alle decisioni cliniche.

In particolare, il valore aggiunto del sistema risiede nelle seguenti dinamiche operative:

1. **Screening Precoce e Triagging Diagnostico:** Il modello ha registrato una sensibilità (recall) e una precisione del 100% nell'identificazione della classe di controllo

(*CONTROL*) e della Leucemia Promielocitica Acuta (*PML_RARA*) sul test set esterno. In un contesto ospedaliero, l'azzeramento dei falsi positivi sui sani (0.00% falsi negativi sui malati) garantisce la sicurezza dei processi di screening automatico, mentre il rapido e perfetto isolamento dei casi di *PML_RARA* consente di allertare tempestivamente il team di ematologia per una presa in carico immediata e l'impostazione prioritaria del percorso terapeutico d'urgenza.

2. **Classificazione Fine dei Sottotipi Molecolari:** A differenza delle soluzioni di letteratura che si limitano a distinzioni macroscopiche, la metodologia proposta discrimina con precisione mutazioni e traslocazioni specifiche quali *CBFB_MYH11*, *NPM1* e *RUNX1_RUNX1T1*, raggiungendo F1-score superiori o uguali all' 80% anche nei sottotipi più complessi.

3. **Ottimizzazione delle Risorse di Laboratorio:** La capacità di effettuare una classificazione automatizzata e accurata del sottotipo direttamente dalle immagini dello striscio ematico consente di snellire l'iter diagnostico iniziale, orientando prioritariamente le analisi molecolari di conferma e riducendo il carico di lavoro associato alla refertazione manuale dei casi complessi.

8.3 Limiti dello Studio

Nonostante le eccellenti prestazioni evidenziate, un'analisi critica e rigorosa del lavoro richiede l'identificazione di alcuni limiti intrinseci, sia dal punto di vista dei dati che della modellistica:

- **Sbilanciamento e Dimensione della Coorte di Addestramento:** Nonostante l'adozione di tecniche di regolarizzazione, ponderazione delle funzioni di perdita (*class weights*) e campionamento bilanciato a livello di paziente, la numerosità complessiva del campione (151 pazienti nel dataset di cross-validation out-of-fold e 38 nel test esterno) rimane condizionata dalla rarità di alcune alterazioni molecolari. La classe *PML_RARA*, ad esempio, contava 19 casi nella coorte di validazione out-of-fold e 5 nel test set esterno, limitando la rappresentatività di tutte le possibili varianti citomorfologiche atipiche.

- **Confusione Morfologica tra Sottotipi Adiacenti:** L'analisi dettagliata delle matrici di confusione (sia OOF che nel Test Set) ha evidenziato una residua intersezione predittiva tra i sottotipi *CBFB_MYH11* e *NPM1* o *RUNX1_RUNX1T1*. Tale fenomeno è attribuibile alla marcata sovrapposizione biologica della differenziazione mielomonocitica e al pleiomorfismo nucleare condiviso, elementi che spingono occasionalmente le mappe di attenzione a scambiare caratteristiche cellulari simili.

- **Variabilità della Preparazione del Vetrino:** Gli strisci di sangue periferico provenienti da centri diagnostici differenti presentano spesso disomogeneità legate alle tecniche di strisciamento, alla colorazione (es. Giemsa vs Wright-Giemsa) e al bilanciamento del bianco degli scanner digitali, aspetti che richiedono costanti procedure di normalizzazione del colore.

8.4 Sviluppi Futuri

I risultati quantitativi conseguiti e l'analisi sistematica dei limiti metodologici riscontrati tracciano un percorso chiaro per l'evoluzione del *framework* computazionale sviluppato nel presente lavoro di tesi. Sebbene la piattaforma dimostri un'elevata capacità di discriminazione dei sottotipi molecolari di Leucemia Mieloide Acuta (AML), il suo futuro affinamento nell'ottica di un effettivo strumento di supporto alle decisioni cliniche apre scenari evolutivi focalizzati su pilastri fondamentali.

8.4.1 Ampliamento del Dataset e Reclutamento di Nuove Classi di Pazienti

La prima linea d'azione prioritaria riguarda il superamento dell'attuale limite quantitativo della classe di addestramento mediante il reperimento e l'integrazione di dataset caratterizzati da una numerosità campionaria significativamente più ampia. L'attuale validazione, pur rigorosa, si basa su una coorte di 151 pazienti per la fase di *out-of-fold cross-validation* e su un test set esterno di 38 pazienti. Sebbene tali numeri siano rilevanti nel panorama della letteratura per la classificazione molecolare da citomorfologia, la rarità di alcune traslocazioni geniche limita la variabilità fenotipica osservabile.

Il reclutamento di nuove classi cliniche eterogenee potrà essere realizzato attraverso l'attivazione di collaborazioni multicentriche con diversi dipartimenti di ematologia e centri di anatomia patologica. L'acquisizione di dati provenienti da istituzioni differenti consentirà di introdurre nello spazio di addestramento una variabilità biologica e strumentale fondamentale per la generalizzazione in contesti di *real-world*. In particolare, l'ampliamento del dataset permetterà di:

1. **Riequilibrare la Rappresentazione dei Sottotipi Rari:** Aumentare la frequenza campionaria di classi clinicamente critiche ma numericamente ridotte, quali la Leucemia Promielocitica Acuta (*PML_RARA*) e le inversioni/traslocazioni cromosomiche come *CBFB_MYH11*, riducendo il rischio di sottorappresentazione delle varianti morfologiche atipiche.

2. **Mitigare il Variational Domain Shift:** Rendere l'architettura intrinsecamente robusta rispetto alle differenze nei protocolli di allestimento del vetrino, alle variazioni nello spessore dello striscio e alla risposta cromatica di scanner digitali prodotte da marchi differenti.

3. **Rafforzare la Stratificazione dei Pazienti:** Garantire una suddivisione dei dati ancora più severa e biologicamente rappresentativa nelle fasi di *k-fold cross-validation*, minimizzando la varianza delle stime prestazionali inter-fold.

8.4.2 Ottimizzazione del Modello e Affinamento degli Iperparametri

La seconda linea d'azione prioritaria riguarda la maturazione architetturale della rete predittiva attraverso una ricerca sistematica ed automatizzata dello spazio degli iperparametri, unita al superamento del vincolo di estrazione a vettori congelati.

Attualmente, il modello sviluppato nella tesi impiega l'encoder visivo *DinoBloom-S* come estrattore di caratteristiche statico (*frozen backbone*), demandando l'apprendimento esclusivamente ai moduli a valle di *Gated Cross-Attention* e classificazione. Per massimizzare la capacità espressiva dell'intera pipeline, le future evoluzioni del modello si articoleranno lungo due direttrici metodologiche:

- Implementazione di un sistema di ottimizzazione avanzata basato su algoritmi bayesiani mediante il framework Optuna. La ricerca automatizzata si concentrerà sull'individuazione dinamica della combinazione ottimale di iperparametri critici, tra cui il tasso di apprendimento (*learning rate*), i coefficienti di decadimento del peso (*weight decay*), la dimensione dei batch, la temperatura della funzione di *softmax* nei meccanismi di attenzione e i parametri di regolazione del *Gated Cross-Attention*.
- **Fine-Tuning Parziale e Progressivo del Backbone:** Sperimentazione di strategie di adattamento dei pesi del *Vision Transformer DinoBloom-S*. Invece di mantenere il backbone completamente congelato, verranno sbloccati selettivamente gli ultimi blocchi di trasformazione (*Transformer blocks*) o integrate tecniche di adattamento a basso rango. Ciò consentirà alle mappe di attivazione della rete di sintonizzarsi in modo specifico sulle micro-strutture citoplasmatiche e cromatiniche dei blasti leucemici, incrementando il potere discriminante sui sottotipi a marcata similarità morfologica (es. *CBFB_MYH11* vs *RUNX1_RUNX1T1*).

8.4.3 Spiegabilità e Interpretabilità Clinica (XAI)

Il terzo pilastro evolutivo riguarda l'approfondimento strutturato di tecniche di Explainable AI, fondamentali per colmare il divario di fiducia tra il modello di Deep Learning e l'operatore clinico. L'obiettivo è trasformare la predizione numerica della rete in un processo trasparente e verificabile.

Le direttrici di sviluppo in ambito XAI comprenderanno:

- **Regression Concept Vectors (RCV):** L'impiego di vettori di concetto per quantificare la presenza di proprietà morfologiche note (es. granularità citoplasmatica, presenza di corpi di Auer, rapporto nucleo-citoplasma) nello spazio latente del modello.
- **Mappe di Attenzione ad Alta Risoluzione:** Il perfezionamento della visualizzazione dei pesi di attenzione associati ai meccanismi di *Gated Cross-Attention*, al fine di evidenziare visivamente quali specifiche aree cellulari o aggregati di blasti guidano la decisione diagnostica della rete.

In conclusione, le direttrici delineate tracciano un percorso concreto per evolvere l'attuale prototipo verso uno strumento di supporto decisionale sempre più maturo e affidabile, con la prospettiva di un'efficace integrazione nella pratica clinica ed ematologica.

Bibliografia

[1] Derek M. Loneman, Valentina Nardi e Robert P. Hasserjian. «Contemporary approach to diagnosis and classification of acute myeloid leukemia». In: *Human Pathology* 171 (2026), p. 106197.

[2] Hartmut Döhner, Andrew H. Wei, Frederick R. Appelbaum et al. «Diagnosis and management of AML in adults: 2022 recommendations from an international expert panel on behalf of the ELN». In: *Blood* 140.12 (2022), pp. 1345–1377.

[3] Daniel A. Arber, Anna Orazi, Robert P. Hasserjian et al. «International Consensus Classification of Myeloid Neoplasms and Acute Leukemias: integrating morphologic, clinical, and genomic data». In: *Blood* 140.11 (2022), pp. 1200–1228.

[4] M. A. Sekeres et al. «American Society of Hematology 2026 guidelines for treating newly diagnosed acute myeloid leukemia in older adults». In: *Blood Advances* 10 (2026), doi:10.1182/bloodadvances.2026129939.

[5] M. Gao et al. «Morphology-based cytogenetic risk prediction from bone marrow smears using foundation hematology models». In: *Blood* 147 (2026), PMC13038424.

[6] Christian Matek et al. «Highly accurate differentiation of bone marrow cell morphologies by deep neural networks on clinical images». In: *Blood* 138.20 (2021), pp. 1917–1927.

[7] Asif Mehmood, Muhammad A. Khan e M. Ikram Ullah Lali. «Next-generation digital hematology: Multi-center validation of deep learning architectures for acute myeloid leukemia screening». In: *Computer Methods and Programs in Biomedicine* 268 (2026), p. 108420.

[8] Fatemeh Sadeghian et al. «A framework for automatic classification of white blood cells in peripheral blood images». In: *Journal of Medical Systems* 33 (2009), pp. 1–13.

[9] Herbert Ramoser, Vincent Laurain, Horst Bischof e Roland Ecker. «Leukocyte segmentation and classification in blood-smear images». In: 1 (2005), pp. I–1045.

[10] Robert M Haralick, Dinstein Shanmugam e Its' Hak Dinstein. «Textural features for image classification». In: *IEEE Transactions on Systems, Man, and Cybernetics* 6 (1973), pp. 610–621.

[11] Alexey Dosovitskiy et al. «An image is worth 16x16 words: Transformers for image recognition at scale». In: *arXiv preprint arXiv:2010.11929* (2020).

[12] Amandeep Singh, Rajeev Kumar e Harpreet Kaur. «Self-attention mechanisms in computational pathology: Mapping ultra-structural cytoplasmic features using Vision Transformers». In: *IEEE Transactions on Medical Imaging* 45.3 (2026), pp. 894–906.

[13] Ruining Gao, Yanning Zhang e Diana Mateus. «Foundation models in hematopathology: automated morphologic screening and molecular subtyping of acute myeloid leukemia from bone marrow smears». In: *Medical Image Analysis* 92 (2026), p. 103045.

[14] L. Gao, H. Wang e X. Zhang. «Dual-stream architectures for hematological malignancies: Integrating structural and texture features in cytological imaging». In: *IEEE Transactions on Medical Imaging* 45.2 (2026), pp. 312–325.

[15] M. Turnbull e E. Davis. «Deep morphological profiling of acute myeloid leukemia blasts using multi-head attention mechanisms». In: *British Journal of Haematology* 202.3 (2026), pp. 511–524.

[16] T. Mehmood, R. Garcia e F. Al-Saud. «Vision Transformers in computational pathology: A comprehensive review of global context modeling in digital cytology». In: *Medical Image Analysis* 98 (2026), p. 103210.

[17] C. Vasile e A. Marin. «Asymptotic behaviors of positional embeddings in medical vision transformers». In: *Artificial Intelligence in Medicine* 141 (2026), p. 102789.

[18] Ashish Vaswani et al. «Attention is All You Need». In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. 2017, pp. 5998–6008. URL: https://papers.nips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

[19] Nayanika Chowdary Tummala et al. «Beyond cellular locality: Vision transformer–based modeling for diagnosis and classification of blood cancers from peripheral blood smears». In: *Journal of Clinical Oncology* 44 (2026), e18562. DOI: 10.1200/JCO.2026.44.16_suppl.e18562.

[20] Anonymous. *DeepHistoViT: An Interpretable Vision Transformer Framework for Histopathological Cancer Classification*. 2026. eprint: 2603.11403.

[21] «Explainable federated transformer framework for joint leukemia classification and stage prediction». In: *Scientific Reports* 16.1 (2026), p. 4493. DOI: 10.1038/s41598-025-34715-8.

[22] Yanning Zheng et al. «Generalizable Vision Transformers for Cross-Laboratory Cancer Histopathology Image Classification via Domain-Invariant Attention Learning». In: *IEEE Transactions on Medical Imaging* 45.3 (2026), pp. 812–825. DOI: 10.1109/TMI.2025.3614012.

[23] G. Alvaro, F. Rossi e M. Bianchi. «Cross-attention fusion mechanisms for nuclear and cytoplasmic semantic alignment in single-cell analysis». In: *Computerized Medical Imaging and Graphics* 114 (2026), p. 102456.

[24] Chun-Fung Chen, Quanfu Fan e Rameswar Panda. «CrossViT: Cross-Attention Multi-Scale Vision Transformer for Image Classification». In: (2021), pp. 357–366.

[25] Y. Zhang, L. Chen e H. Wang. «Dual-Branch Appearance-Geometry Transformers for Precise Cellular Morphology Analysis in Digital Pathology». In: *IEEE Transactions on Medical Imaging* 45.2 (2026), pp. 312–325.

[26] X. Liu, R. Zhao e M. Tan. «Multi-Stream Cross-Attention Networks for Sub-Cellular Feature Disentangling in Leucocyte Classification». In: *Medical Image Analysis* 98 (2026), p. 103210.

[27] W. Zhao, M. Li e J. Zhang. «Robust Cell Subtype Stratification via Boundary-Aware Mask Projections in Vision Transformers». In: *IEEE Transactions on Neural Networks and Learning Systems* 37.3 (2026), pp. 1420–1432.

[28] Jun Wang, Yifan Zhang, Chen Liu e Lei Zhao. «Contextual Feature Competition and Representation Disambiguation in Dual-Stream Vision Transformers». In: *IEEE Transactions on Medical Imaging* 45.3 (2026), pp. 812–825.

[29] M. Hehr et al. *A morphological dataset of white blood cells from patients with four different genetic AML entities and non-malignant controls (AML-Cytomorphology_MLL_Helmholtz)*. Ver. 1. 2023. DOI: 10.7937/6PPE-4020. URL: https://doi.org/10.7937/6PPE-4020.

[30] Nobuyuki Otsu. «A threshold selection method from gray-level histograms». In: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), pp. 62–66.

[31] Matthias Hehr e et al. «Single-Cell based Explainable Multiple Instance Learning Algorithm (SCEMILA) for Cytomorphological Classification». In: *Nature Machine Intelligence* (2023). DOI: 10.1038/s42256-023-00000-0.

Elenco delle figure

2.1 Panoramica del modello Vision Transformer (ViT). L'immagine viene suddivisa in patch di dimensione fissa, ciascuna delle quali viene proiettata tramite un embedding lineare; vengono quindi sommati gli embedding di posizione e la sequenza di vettori risultante viene data in input a un encoder Transformer standard. Per l'esecuzione del task di classificazione, viene adottato l'approccio standard che prevede l'aggiunta di un token di classificazione (*classification token*) apprendibile extra alla sequenza. L'illustrazione dell'encoder Transformer è ispirata al lavoro di Vaswani et al. [18]. Figura e didascalia riadattate da Dosovitskiy et al. [11]. 14

2.2 Meccanismo di fusione intermedia tramite Cross-Attention bidirezionale tra il flusso dell'immagine originale (*Global Stream*) e il flusso della maschera del nucleo (*Structural Stream*). Schema logico dei blocchi di interazione adattato dall'architettura CrossViT di Chen et al. [24]. 18

3.1 Architettura complessiva del modello **TumorClassifierViT**. Il diagramma mostra dettagliatamente la separazione nei due rami paralleli (Originale e Segmentato), l'estrazione dei patch token tramite Vision Transformer alleggerito a 6 blocchi, la fusione incrociata tramite Cross-Attention Transformer Block con DropPath, il modulo di Attention Pooling guidato da un token [CLS] apprendibile e la testa di classificazione MLP finale. . . . 23

4.1 Schema del flusso di partizionamento per la prevenzione del data leakage. 41

5.1 Architettura concettuale della pipeline di elaborazione e addestramento *dual-stream*. 44
5.2 Flusso di aggregazione delle predizioni cellulari a livello di paziente. . . . 49
5.3 Schema della Cross-Validation a 3 Fold stratificata sui pazienti. 52
5.4 Pipeline di inferenza ensemble sul Test Set Esterno. 53

6.1 Struttura concettuale del report diagnostico esportato dal modulo di test. 62
6.2 Esempio di report diagnostico grafico generato dall'Ensemble per un caso di predizione corretta (paziente SQF, classe *NPM1* identificata con confidenza del 92.82%). 63

7.1 Andamento delle curve di Loss (destra) e Accuracy (sinistra) di addestramento e validazione media durante le 50 epoche di addestramento su 5-Fold Cross-Validation. 66
7.2 Matrice di confusione complessiva del Training Set su tutti i fold (Accuracy: 96.69%). 67
7.3 Matrice di confusione Global Out-Of-Fold (Accuracy: 78.81%). 69
7.4 Matrice di confusione Patient-Level External Test (Accuracy: 92.11%). . . 71
7.5 Curve ROC (Sensitivity vs 1-Specificity) sul Test Set Esterno. 73
7.6 Curve Precision-Recall (Precision vs Recall) sul Test Set Esterno. 73
7.7 Confronto delle matrici di confusione grafiche sul Training Set cumulativo tra $K = 3$ e $K = 5$. 79
7.8 Confronto delle matrici di confusione grafiche Out-Of-Fold (OOF) sul Validation Set tra $K = 3$ e $K = 5$. 80
7.9 Confronto delle matrici di confusione grafiche sul Test Set Esterno holdout tra $K = 3$ e $K = 5$. 82
7.10 Confronto delle curve di apprendimento medie ottenute durante la Cross-Validation per le configurazioni a $K = 5$ (sopra) e $K = 3$ (sotto). 84
7.11 Confronto visivo delle curve di prestazione probabilistica sul Test Set Esterno ($N = 38$) tra la configurazione a $K = 3$ fold (in alto) e la configurazione a $K = 5$ fold (in basso). 87

Elenco delle tabelle

4.1 Composizione dettagliata del Test Set Esterno (Holdout). 41
4.2 Composizione numerica dettagliata dei 3 Folds di Cross-Validation e del Test Set esterno. Ogni valore indica il numero di immagini originali e, tra parentesi, il numero di pazienti corrispondenti. 42

5.1 Configurazione degli iperparametri di addestramento. 47

7.1 Report di classificazione complessivo sul Training Set (tutti i fold). 68
7.2 Report di classificazione globale Out-Of-Fold (OOF). 70
7.3 Report di classificazione sul Test Set Esterno. 72
7.4 Valori di ROC-AUC e PR-AUC (Average Precision) calcolati sul Test Set Esterno ($N = 38$). 74
7.5 Confronto tra SCEMILA (Hehr et al., 2023) e il modello proposto (Parte 1: Architettura, Dataset, ROC-AUC e PR-AUC). 75
7.6 Confronto tra SCEMILA (Hehr et al., 2023) e il modello proposto (Parte 2: F1-Score e Metriche Cliniche). 76
7.7 Confronto analitico del report di classificazione sul Training Set tra le configurazioni a $K = 3$ e $K = 5$ Fold. 79
7.8 Confronto analitico del report di classificazione Out-Of-Fold (OOF) tra le configurazioni a $K = 3$ e $K = 5$ Fold. 81
7.9 Confronto analitico del report di classificazione sul Test Set Esterno tra le configurazioni a $K = 3$ e $K = 5$ Fold. 83
7.10 Confronto delle metriche ROC-AUC (Spec+Sens) e PR-AUC / AP (Prec+Rec) sul Test Set Esterno ($N = 38$) tra la configurazione a $K = 3$ e quella a $K = 5$ fold. 86